

Estadística

Victoria Torroja Rubio

19/1/2026

Índice general

1. Estadística descriptiva	3
2. Muestreo	7
2.1. Modelos estadísticos	7
2.2. Estadísticos muestrales	8
2.3. Propiedades asintóticas de los momentos muestrales	10
2.4. Distribuciones asociadas a la normal	12
2.5. Teorema de Fisher	12
A. Convergencia de variables aleatorias	13
A.1. Convergencia en probabilidad	13
A.2. Convergencia casi segura	14
A.3. Convergencia en ley	15
A.4. Convergencia en media de orden r	16
A.5. Leyes de los grandes números	17
A.5.1. Ley débil de los grandes números	17
A.5.2. Ley fuerte de los grandes números	18
A.6. Teorema central del límite	19

Despacho: 303E

Correo: beatrizg@ucm.es

Evaluación:

- 80 % examen final
- 20 % evaluación continua (en este caso serán trabajos de R)

Bibliografía:

- 'Interferencia estadística' de M.A. Gómez Villegas
- 'Statistical interference' de Casella Berger

Capítulo 1

Estadística descriptiva

Práctica:

- Hacer en R el ejemplo 1.3.2 (lo del colesterol) del libro (página 11). Lo que hay que hacer aparece en el ejercicio 1.9.3.
- Programar el coeficiente de simetría y de curtosis en R.
- Demostrar todas las cosas del teorema de Fisher.

Ejemplo. Página 44, Ejercicio 1. Consideramos la población dada por la distribución de Bernuilli $B\left(\frac{1}{2}\right)$. Se consideran todas las m.a.s de tamaño 3, es decir,

$$(X_1, X_2, X_3).$$

Recordamos que

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Tendremos que

$$\bar{X} = \begin{cases} 0 \rightarrow \frac{1}{8} \\ \frac{1}{3} \rightarrow \frac{3}{8} \\ \frac{2}{3} \rightarrow \frac{3}{8} \\ 1 \rightarrow \frac{1}{8} \end{cases}.$$

De esta forma tenemos que

$$P_{\bar{X}}(0) = \frac{1}{8}, \quad P_{\bar{X}}\left(\frac{1}{3}\right) = \frac{3}{8}, \text{ etc.}$$

Lo que estamos haciendo es considerar los diferentes casos para X_1, X_2 y X_3 y calcular la media en cada caso. A partir de ahí, estamos tratando a la media como una variable aleatoria discreta.

Ejemplo. Página 44, Ejercicio 2. Una forma de media θ y varianza 1. Se toma una m.a.s de tamaño n . Así, tenemos que $X \sim F_\theta(x) = P_\theta(X \leq x)$. Tendremos que $E_\theta[X] = \theta$ y $V_\theta(X) = 1$. Tenemos que calcular θ para que

$$P_\theta(|\bar{X} - \theta| \leq 0,5) \geq 0,95.$$

Tenemos que aplicar la desigualdad de Chebychev, primer calculamos

$$E_\theta[\bar{X}] = \frac{1}{n} \sum_{i=1}^n E_\theta[X_i] = \theta.$$

Por otro lado, $D_\theta(X) = \sqrt{V_\theta(X)} = 1$, así

$$D_\theta(\bar{X}) = \sqrt{V_\theta(\bar{X})} = \sqrt{V_\theta\left(\frac{1}{n} \sum_{i=1}^n X_i\right)} = ? \frac{1}{n} \sum_{i=1}^n V_\theta(X_i) = \frac{1}{n} \rightarrow 0.$$

Aplicando la desigualdad de Chebychev

$$P_\theta\left(|\bar{X} - \theta| \geq \frac{K}{n}\right) \leq \frac{1}{K^2}.$$

Ejemplo. Página 45, Ejercicio 6. Sea una m.a.s de tamaño n calculamos la distribución de la media muestral \bar{X} , cuando la población:

- (b) $X \sim \gamma(p, a)$. Denotamos $\theta = (p, a) \in \mathbb{R}^+ \times \mathbb{R}^+$ y decimos que $\theta \in \Theta \subset \mathbb{R}^2$. Recordamos que

$$f(x|\theta) = f_\theta(x) = \frac{a^p x^{p-1} e^{-ax}}{\Gamma(p)}, \quad x > 0.$$

Hacemos el ejercicio con la ecuación característica:

$$\varphi_{\bar{X}}(t) = E_\theta[e^{it\bar{X}}] = E_\theta\left[e^{it\frac{1}{n} \sum_{i=1}^n X_i}\right] = \prod_{i=1}^n \varphi_{X_i}\left(\frac{t}{n}\right) = \varphi_X\left(\frac{t}{n}\right)^n = \left(1 - i\frac{t}{na}\right)^{-pn}.$$

La función característica se corresponde con $\gamma(np, na)$.

- (c) Basta con sustituir $\lambda = 1$ en el apartado anterior.

Distribuciones asociadas a la normal

Consideremos que (X_1, \dots, X_n) es una m.a.s con cada variable independientes y siguen una distribución $X \sim N(0, 1)$. Consideremos la variable aleatoria

$$Y := \sum_{i=1}^n X_i^2 = X_1^2 + \dots + X_n^2.$$

Tenemos que

$$\varphi_Y(t) = \prod_{i=1}^n \varphi_{X_i^2}(t).$$

En general, si $Z = X^2$,

$$F_Z(z) = P(Z \leq z) = P(X^2 \leq z) = P(-\sqrt{z} \leq X \leq \sqrt{z}) = F_X(\sqrt{z}) - F_X(-\sqrt{z}).$$

La función de densidad será

$$f_Z(t) = \frac{1}{2\sqrt{z}} f_X(\sqrt{z}) + \frac{1}{2\sqrt{z}} f_X(-\sqrt{t}) = \frac{1}{\sqrt{2\pi}} t^{-\frac{1}{2}} e^{-\frac{1}{2}t}, \quad t > 0.$$

Podemos ver que se trata de la función de densidad de una distribución Gamma, así, $Z \sim \gamma\left(\frac{1}{2}, \frac{1}{2}\right)$. Definimos $\chi_1^2 \sim \gamma\left(\frac{1}{2}, \frac{1}{2}\right)$, el uno viene de que tenemos un grado de libertad (se genera a partir de una normal $N(0, 1)$). Por la propiedad de reproductividad de la distribución Gamma, tenemos que $Y \sim \gamma\left(\frac{n}{2}, \frac{1}{2}\right)$. A esta distribución la llamamos $\chi_n^2 \sim \gamma\left(\frac{n}{2}, \frac{1}{2}\right)$ (decimos que tiene n grados de libertad porque viene de n distribuciones normales $N(0, 1)$). Recordamos que la función característica de una distribución γ es

$$\varphi(t) = \left(1 - \frac{it}{a}\right)^{-p}.$$

Ejemplo. Ejercicio 19. Sea (X_1, \dots, X_n) una m.a.s distribuida idénticamente a X tal que

$$P(X = x_i) = p_i, \quad i \in \mathbb{N}.$$

Sea $(X_{(1)}, \dots, X_{(n)})$ la muestra ordenada de menor a mayor. Demostremos que la distribución para $X_{(k)}$ es discreta y

$$P(X_{(1)} \leq x_i) = \sum_{j=k}^n \binom{n}{j} (F(x_i))^j (1 - F(x_i))^{n-j}.$$

El resto viene dado en el enunciado. Tenemos que $X_{(1)} = \min\{X_1, \dots, X_n\}$ y $X_{(n)} = \max\{X_1, \dots, X_n\}$. Tenemos que

$$F_{X_{(n)}}(t) = P(X_{(n)} \leq t) = P\left(\bigcap_{1 \leq i \leq n} \{X_i \leq t\}\right) = \prod_{i=1}^n P(X_i \leq t) = F_X(t)^n.$$

Por otro lado,

$$F_{X_{(1)}}(t) = 1 - P(X_{(1)} > t) = 1 - P\left(\bigcap_{1 \leq i \leq n} \{X_i > t\}\right) = 1 - \prod_{i=1}^n P(X_i > t) = 1 - (1 - F_X(t))^n.$$

Ahora, buscamos $F_{X_{(k)}}(t)$ para $k \in \{1, \dots, n\}$. Tenemos que

$$F_{X_{(k)}}(t) = P(X_{(k)} \leq t) = \sum_{j=k}^n P(\text{'exactamente } j \text{ por debajo de } t') = \sum_{j=k}^n \binom{n}{j} F_X(t)^j (1 - F_X(t))^{n-j}.$$

Finalmente, recordamos que $P_{X_{(k)}}(x_i) = F_{X_{(k)}}(x_i) - F_{X_{(k)}}(x_{i-1})$.

Teorema 1.1. Es cierto que $\sqrt{n} (b_2 - \sigma^2) \rightarrow N(0, \sqrt{\beta_4 - \sigma^4})$.

Teorema 1.2 (Teorema de Fisher). Sea (X_1, \dots, X_n) una m.a.s idénticamente distribuida a $X \sim N(\mu, \sigma)$. Entonces se cumple que

$$1. \bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right).$$

$$2. \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

$$3. \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}.$$

$$4. \bar{X} \text{ y } S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} \text{ son independientes.}$$

Demostración. Cogemos $Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$ así, tendremos que

$$T = \frac{\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{(n-1)}{\sigma^2} \frac{S^2}{n-1}}} = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}}.$$

En esto último hemos aplicado el punto 2 del teorema de Fisher. Esto es en teoría una demostración del punto 3 del teorema de Fisher. Para demostrar 4 basta con ver que $Cov(\bar{X}, S) = 0$, por ser $X \sim N(\mu, \sigma)$. \square

Definición 1.1. Sea (X_1, \dots, X_n) una m.a.s (n) idénticamente distribuidas a $N(0, 1)$. Tenemos que $\chi_{n-1}^2 := X_1^2 + \dots + X_n^2 \sim \gamma\left(p = \frac{n-1}{2}, a = \frac{1}{2}\right)$.

Definición 1.2 (Distribución t_k -student). Sea $\{X_i\}_{i \in \mathbb{N}}$ una sucesión de variables independientes idénticamente distribuidas que siguen la distribución $X \sim N(0, 1)$. Cogemos las k primeras y definimos

$$Y = \sqrt{\frac{X_1^2 + \dots + X_k^2}{k}} \sim \sqrt{\frac{\chi_k^2}{k}}.$$

Si $Z = X_{k+1} \sim N(0, 1)$, entonces definimos la T de Student como $T = \frac{Z}{Y}$.

Capítulo 2

Muestreo

2.1. Modelos estadísticos

Cada fenómeno aleatorio está gobernado por una función de probabilidad. Para estudiar dicho fenómeno, nos centramos en estudiar su distribución de probabilidad subyacente.

Llamaremos **población** a una variable aleatoria $X \sim F$, donde F es una función de distribución no completamente conocida. Nuestro objetivo será obtener información sobre ciertas características de la distribución de X . Para ello, replicaremos el experimento aleatorio (de forma idéntica e independiente) un número de n veces.

Hay varios tipos de inferencia:

- Inferencia frecuentista: utilizamos información objetiva, es decir, datos de la muestra.
- Inferencia bayesiana: se utiliza información subjetiva.

También podemos diferenciar en función del grado de conocimiento sobre F :

- Inferencia paramétrica: se conoce la forma funcional de F , excepto por ciertas características.
- Inferencia no paramétrica: no se asume una forma funcional para F .

Supongamos por ahora que la verdadera función de distribución F de nuestra población X está contenida en una familia \mathcal{F} de funciones de distribución asociadas a X .

Definición 2.1 (Modelo estadístico). Un **modelo estadístico** es una terna $(\chi, \beta_\chi, \mathcal{F})$, donde

- $\chi \subset \mathbb{R}$ es el espacio muestral.
- β_χ es una σ -álgebra de Borel sobre χ .
- \mathcal{F} es un conjunto de funciones de distribución asociadas a medidas de probabilidad P_X definidas sobre (χ, β_χ) .

En la inferencia paramétrica asumimos que conocemos la forma funcional de la verdadera función de distribución F de la variable aleatoria de interés X , excepto por k parámetros $\theta = (\theta_1, \dots, \theta_k)$. En este caso, la familia \mathcal{F} tiene la forma

$$\mathcal{F} = \{F(\cdot; \theta) : \theta \in \Theta\}.$$

Decimos que $\theta \in \Theta \subset \mathbb{R}^k$, donde Θ es el **espacio paramétrico**. En el caso de inferencia frecuentista consideraremos que θ es un valor fijo y desconocido, por lo que escribiremos $f_\theta(x)$ para designar a la función de masa. Sin embargo, en el planteamiento bayesiano consideraremos que θ es una variable aleatoria, por lo que escribiremos $f(x|\theta)$.

Definición 2.2 (Modelo estadístico paramétrico). Un **modelo estadístico paramétrico** es una terna $(\chi, \beta_\chi, \mathcal{F})$ donde

$$\mathcal{F} = \{F(\cdot; \theta) : \theta \in \Theta\}.$$

Ejemplo. Consideremos los siguientes ejemplos.

- Estimar la probabilidad de que un producto resulte defectuoso en una cadena de producción: $X \sim Bern(\theta)$, $\theta \in [0, 1]$.
- Estimar el tiempo entre llegadas a la cola de un servidor: $X \sim \exp(\lambda)$, $\lambda > 0$.
- Estimar el peso esperado de niños hasta cierta edad en una región determinada: $X \sim N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$.

2.2. Estadísticos muestrales

Consideremos una variable aleatoria X a la que llamaremos **universo** o **población** cuya función de distribución F viene dada por algún elemento de una familia \mathcal{F} de distribuciones de probabilidad.

Definición 2.3 (Muestra aleatoria simple (m.a.s.)). Dada una población X se llama **muestra aleatoria simple (m.a.s.)** de tamaño n a la repetición de X_1, \dots, X_n variables aleatorias independientes con distribución igual a la de X .

Observación. El modelo estadístico asociado a nuestra muestra $\vec{X} = (X_1, \dots, X_n)$ es $(\chi^n, \beta_{\chi^n}, \mathcal{F}^n)$, donde \mathcal{F}^n es el conjunto de funciones de distribución $F_X : \mathbb{R}^n \rightarrow \mathbb{R}$ tales que

$$F_X(x_1, \dots, x_n) = \prod_{i=1}^n F(x_i), \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n.$$

Observación. Por ejemplo, la función de distribución de la muestra (x_1, \dots, x_n) es

$$F(x_1, \dots, x_n) = \prod_{i=1}^n F(x_i),$$

donde $F(x)$ es la función de distribución de X , que viene dada por un elemento de \mathcal{F} .

Observación. Los datos observados (x_1, \dots, x_n) son un resultado o realización de la m.a.s., $X_1 = x_1, \dots, X_n = x_n$.

Definición 2.4 (Estadístico muestral). Dada (X_1, \dots, X_n) una m.a.s. de X , a toda $f : \mathbb{R}^n \rightarrow \mathbb{R}^k$ función conocida medible recibe el nombre de **estadístico muestral**.

Ejemplo. Algunos ejemplos de estadísticos muestrales son la **media muestral** que viene dada como

$$\bar{X} := \frac{1}{n} \sum_{i=1}^n X_i,$$

y la **cuasivarianza muestral**

$$S^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Definición 2.5 (Momentos centrales). Se llama **momento muestral respecto al origen** de orden k a $a_k := \frac{1}{n} \sum_{i=1}^n X_i^k$, con $k > 0$. Análogamente, se llama **momento muestral respecto al centro** de orden k a $b_k := \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$, con $k > 0$.

Ejemplo. Como hemos visto antes, tendremos que $a_1 = \bar{X}$.

Observación. Es sencillo ver que

$$b_k = a_k - \binom{k}{1} \bar{x} a_{k-1} + \cdots + (-1)^k \bar{x}^k,$$

es decir, los momentos muestrales respecto al centro se puede calcular en función de los momentos muestrales respecto al origen. En particular,

$$b_2 = a_2 - a_1^2 = a_2 - \bar{X}^2.$$

Proposición 2.1. Dada una m.a.s. de tamaño n de una población X con momento de segundo orden finito ^a, se tiene que $E[\bar{X}] = \mu$ y $V(\bar{X}) = \frac{\sigma^2}{n}$, donde $\mu = E[X]$ y $\sigma^2 = V(X)$.

^aEsta hipótesis es necesaria para asegurar la existencia de σ^2 y μ .

Demostración. Aplicando las propiedades de la esperanza,

$$E[\bar{X}] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \sum_{i=1}^n \mu = \mu.$$

Por otro lado, aplicando las propiedades de la varianza,

$$\begin{aligned} V(\bar{X}) &= E[(\bar{X} - \mu)^2] = E\left[\left(\frac{1}{n} \sum_{i=1}^n (X_i - \mu)\right)^2\right] \\ &= \frac{1}{n^2} E\left[\sum_{i=1}^n (X_i - \mu)^2 + 2 \sum_{i=1}^n \sum_{j=1, j>i}^n (X_i - \mu)(X_j - \mu)\right] \\ &= \frac{1}{n^2} \left[\sum_{i=1}^n V(X_i) + 2 \sum_{i=1}^n \sum_{j>i} E[X_i - \mu] E[X_j - \mu] \right] = \frac{\sigma^2}{n}. \end{aligned}$$

Podemos observar que el segundo sumando se anula. \square

2.3. Propiedades asintóticas de los momentos muestrales

Sea (X_1, \dots, X_n) una m.a.s (n) de X con $\mu = E[X]$ y $\sigma = \sqrt{V(X)}$.

Proposición 2.2 (Momentos muestrales respecto al origen). Se cumple que si $n \rightarrow \infty$

$$a_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{c.s.} \alpha_k = E[X^k].$$

Particularmente,

$$\bar{X} \xrightarrow{c.s.} \mu \quad (\text{Ley Fuerte de Kintchine}, \mu < \infty).$$

Demostración. Por el teorema de Kintchine, tenemos que para una sucesión de variables aleatorias $\{Y_n\}_{n \in \mathbb{N}}$ independientes e idénticamente distribuidas con $E[Y_i] = \mu < \infty$, $\forall n \in \mathbb{N}$, tenemos que $\bar{Y} \xrightarrow{cs} \mu$. El resultado general lo obtenemos tomando $Y_i = X_i^k$. \square

Proposición 2.3 (Momentos muestrales respecto a la media). Si una población tiene momentos de orden $k > 0$, el momento muestral respecto al centro de orden k , converge, casi seguro, al momento poblacional respecto al centro de orden k , es decir

$$b_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \xrightarrow{cs} \beta_k = E[(X - \mu)^k].$$

En particular,

$$\sigma_n^2 \xrightarrow{cs} \sigma^2 \quad \text{y} \quad S_n^2 \xrightarrow{cs} \sigma^2.$$

Demostración. Hacer en casa. \square

Proposición 2.4. Si la población tiene momentos de orden $2k$ respecto al origen, entonces se tiene la siguiente convergencia en ley

$$\frac{a_k - \alpha_k}{\sqrt{\alpha_{2k} - \alpha_k^2}} \sqrt{n} \xrightarrow{\mathcal{L}} N(0, 1).$$

En particular,

$$\sqrt{n} \frac{\bar{X} - \mu}{\sigma} \xrightarrow{\mathcal{L}} N(0, 1) \text{ (Teorema de Lévy-Lindeberg).}$$

Demostración. Basta con aplicar el teorema central del límite, $\{Y_n\}_{n \in \mathbb{N}}$ con v.a.i.i.d con momento de segundo orden y $E[Y_n] = \mu$ y $V(Y_n) = \sigma^2 < \infty$. Entonces, tendremos que

$$\frac{\bar{Y} - \mu}{\sigma} \sqrt{n} \xrightarrow{\mathcal{L}} N(0, 1).$$

Para obtener el resultado general podemos considerar $Y_n = X_n^k$ y $a_k = \bar{Y}$, de forma que $\mu = \alpha_k$ y $\sigma^2 = \alpha_{2k} - \alpha_k^2$. \square

Proposición 2.5. Si existe el momento poblacional respecto al origen de orden $2k$, entonces

$$\sqrt{n} \frac{b_k - \beta_k}{\sqrt{\beta_{2k} - \beta_k^2 - 2k\beta_{k-1}\beta_{k+1} + k^2\beta_{k-1}^2\beta_2}} \xrightarrow{\mathcal{L}} N(0, 1).$$

En particular,

$$\sqrt{n} \frac{\sigma_n^2 - \sigma^2}{\sqrt{\beta_4 - \sigma^4}} \xrightarrow{\mathcal{L}} N(0, 1).$$

Teorema 2.1 (Teorema de Slutsky). Si $X_n \xrightarrow{\mathcal{L}} X$ e $Y_n \xrightarrow{P} a$, con $a \in \mathbb{R}$, entonces

1. $Y_n X_n \xrightarrow{\mathcal{L}} aX$.
2. $X_n + Y_n \xrightarrow{\mathcal{L}} X + a$.

Lema 2.1. Si $\{a_n\}_{n \in \mathbb{N}} \subset \mathbb{R}$ con $\lim_{n \rightarrow \infty} a_n = \infty$ y $a \in \mathbb{R}$ tal que

$$a_n (X_n - a) \xrightarrow{\mathcal{L}} X,$$

entonces para $g : \mathbb{R} \rightarrow \mathbb{R}$ con derivada continua y no nula en a se tiene que

$$a_n (g(X_n) - g(a)) \xrightarrow{\mathcal{L}} g'(a) X.$$

Otro estadístico muestral importante es la función de distribución empírica o muestral.

Definición 2.6 (Función de distribución empírica). Dada una realización particular de una muestra (x_1, \dots, x_n) , la **función de distribución empírica** viene dada por

$$F_n^*(x) = \begin{cases} 0, & x < x_{(1)} \\ \frac{k}{n}, & x_{(k)} \leq x < x_{(k+1)}, k = 1, \dots, n-1 \\ 1, & x_{(n)} \leq x \end{cases}.$$

Recordamos que $(x_{(1)}, \dots, x_{(n)})$ es la muestra ordenada de menor a mayor.

2.4. Distribuciones asociadas a la normal

Sea (X_1, \dots, X_n) una m.a.s. (n) de $X \sim N(\mu, \sigma)$.

Observación (Distribución de la media muestral). Sabemos que $\varphi_X(t) = e^{it\mu - \frac{1}{2}t^2\sigma^2}$. Por tanto, tendremos que

$$\begin{aligned} \varphi_{\bar{X}}(t) &= E[e^{it\bar{X}}] = E[e^{it\frac{1}{n}\sum_{i=1}^n X_i}] = E\left[\prod_{i=1}^n e^{it\frac{1}{n}X_i}\right] = \prod_{i=1}^n \varphi_{X_i}\left(\frac{t}{n}\right) \\ &= \varphi_X^n\left(\frac{t}{n}\right) = e^{it\mu - \frac{1}{2}\frac{\sigma^2}{n}t^2}. \end{aligned}$$

Por tanto, tenemos que $\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$.

2.5. Teorema de Fisher

En el archivo de Fisher hay que saber deducir todas las identidades que vienen en el documento.

Apéndice A

Convergencia de variables aleatorias

A.1. Convergencia en probabilidad

Definición A.1 (Convergencia en probabilidad). Dada una sucesión de variables aleatorias $\{X_n\}_{n \in \mathbb{N}}$ definidas sobre un mismo espacio de probabilidad (Ω, \mathcal{A}, P) , diremos que $\{X_n\}_{n \in \mathbb{N}}$ **converge en probabilidad** hacia la variable aleatoria X , definida en el mismo espacio de probabilidad, si

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon) = 0.$$

Observación. Una definición equivalente es

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(\omega \in \Omega : |X_n(\omega) - X(\omega)| \leq \varepsilon) = 1.$$

Notación. Si una sucesión $\{X_n\}_{n \in \mathbb{N}}$ converge en probabilidad a X lo escribiremos

$$X_n \xrightarrow{P} X.$$

Proposición A.1 (Propiedades). Si $X_n \xrightarrow{P} X$,

- $X_n - X \xrightarrow{P} 0$.
- Si $c \in \mathbb{R}/\{0\}$, $cX_n \xrightarrow{P} cX$.
- Si Y es una variable aleatoria, $X_n Y \xrightarrow{P} XY$.
- Si $g : \mathbb{R} \rightarrow \mathbb{R}$ es continua, $g(X_n) \xrightarrow{P} g(X)$.
- Si $k \in \mathbb{R}^+$, $X_n^k \xrightarrow{P} X^k$.

Si $X_n \xrightarrow{P} X$ y $Y_n \xrightarrow{P} Y$,

- $X_n \pm Y_n \xrightarrow{P} X \pm Y$.
- $X_n Y_n \xrightarrow{P} XY$.
- Si $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ es real y continua, $g(X_n, Y_n) \xrightarrow{P} g(X, Y)$.
- Si $k, h \in \mathbb{R}^+$, $X_n^k Y_n^h \xrightarrow{P} X^k Y^h$.

Si $X_n \xrightarrow{P} X$ y $X_n \xrightarrow{P} Y$, se tiene que $P(X = Y) = 1$.

Si $X_n \xrightarrow{P} a$ e $Y_n \xrightarrow{P} b$ con $a, b \in \mathbb{R}$,

- $X_n Y_n \xrightarrow{P} ab$.
- $\frac{X_n}{Y_n} \xrightarrow{P} \frac{a}{b}$, si $b \neq 0$.

A.2. Convergencia casi segura

Definición A.2 (Convergencia casi segura). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias, definidas sobre un mismo espacio de probabilidad (Ω, \mathcal{A}, P) . Diremos que $\{X_n\}_{n \in \mathbb{N}}$ **converge casi seguro** a la variable aleatoria X , definida en el mismo espacio de probabilidad, si

$$P\left(\omega \in \Omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right) = 1.$$

Notación. Si la sucesión $\{X_n\}_{n \in \mathbb{N}}$ converge casi seguro a X , escribimos

$$X_n \xrightarrow{cs} X.$$

Proposición A.2 (Propiedades). Si $X_n \xrightarrow{cs} X$,

- $X_n - X \xrightarrow{cs} 0$.
- Si $c \in \mathbb{R}/\{0\}$, $cX_n \xrightarrow{cs} cX$.
- Si $g : \mathbb{R} \rightarrow \mathbb{R}$ es continua, $g(X_n) \xrightarrow{cs} g(X)$.
- Si $k \in \mathbb{R}^+$, $X_n^k \xrightarrow{cs} X^k$.

Si $X_n \xrightarrow{cs} X$ e $Y_n \xrightarrow{cs} Y$,

- $X_n \pm Y_n \xrightarrow{cs} X \pm Y$.
- $X_n Y_n \xrightarrow{cs} XY$.
- Si $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ es continua, $g(X_n, Y_n) \xrightarrow{cs} XY$.
- Si $k, h \in \mathbb{R}^+$, $X_n^k Y_n^h \xrightarrow{cs} X^k Y^h$.
- $\frac{X_n}{Y_n} \xrightarrow{cs} \frac{X}{Y}$, siempre que los cocientes estén bien definidos.

Teorema A.1. Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión estrictamente creciente de variables aleatorias positivas y supongamos que $X_n \xrightarrow{P} 0$, entonces $X_n \xrightarrow{cs} 0$.

Teorema A.2. Si $X_n \xrightarrow{cs} X$, entonces $X_n \xrightarrow{P} X$.

Teorema A.3. Si $\{X_n\}_{n \in \mathbb{N}} \xrightarrow{P} X$, existe $\{X_{n_j}\}_{j \in \mathbb{N}}$ subsucesión tal que $X_{n_j} \xrightarrow{cs} X$.

A.3. Convergencia en ley

Definición A.3 (Convergencia en ley). Dada una sucesión de variables aleatorias $\{X_n\}_{n \in \mathbb{N}}$, definidas sobre el mismo espacio de probabilidad (Ω, \mathcal{A}, P) , diremos que $\{X_n\}_{n \in \mathbb{N}}$ converge en ley a la variable aleatoria X , definida sobre el mismo espacio de probabilidad, si la correspondiente sucesión de funciones de distribución de las X_n , $\{F_n\}_{n \in \mathbb{N}}$ converge puntualmente hacia la función de distribución F de X en todo punto de continuidad de la función. Es decir,

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

para todos los puntos de continuidad de F .

Observación. La convergencia puntual de F_n a F no es suficiente para garantizar la convergencia, es necesario ver que la función límite sea función de distribución.

Notación. Si la sucesión $\{X_n\}_{n \in \mathbb{N}}$ converge en ley a X , lo escribimos

$$X_n \xrightarrow{d} X \quad \text{o} \quad X_n \xrightarrow{\mathcal{L}} X.$$

Proposición A.3 (Propiedades). Si $X_n \xrightarrow{\mathcal{L}} X$,

- $X_n - X \xrightarrow{\mathcal{L}} 0$.
- Si $c \in \mathbb{R}/\{0\}$, $cX_n \xrightarrow{\mathcal{L}} cX$.
- Si $c \in \mathbb{R}$, $X_n + c \xrightarrow{\mathcal{L}} X + c$.
- Si $g : \mathbb{R} \rightarrow \mathbb{R}$ es continua, $g(X_n) \xrightarrow{\mathcal{L}} g(X)$.

Si $X_n \xrightarrow{\mathcal{L}} X$ e $Y_n \xrightarrow{P} c$, con $c \in \mathbb{R}$,

- $X_n \pm Y_n \xrightarrow{\mathcal{L}} X \pm c$.
- Si $c \neq 0$, $X_n Y_n \xrightarrow{\mathcal{L}} cX$.
- Si $c = 0$, $X_n Y_n \xrightarrow{P} 0$.
- Si $c \neq 0$, $\frac{X_n}{Y_n} \xrightarrow{\mathcal{L}} \frac{X}{c}$.

Teorema A.4. Si $X_n \xrightarrow{P} X$, entonces $X_n \xrightarrow{\mathcal{L}} X$.

Teorema A.5. Si $k \in \mathbb{R}$ y $X_n \xrightarrow{\mathcal{L}} k$, entonces $X_n \xrightarrow{P} X$.

Observación (Convergencia de las funciones características). Sabemos que las funciones características proporcionan otro medio para determinar la distribución de una variable aleatoria. También se cumple que

$$X_n \xrightarrow{\mathcal{L}} X \Rightarrow \lim_{n \rightarrow \infty} \varphi_n(t) = \varphi(t), \quad \forall t \in \mathbb{R}.$$

Recíprocamente, si $\lim_{n \rightarrow \infty} \varphi_n(t) = \varphi(t)$, $\forall t \in \mathbb{R}$ y $\varphi(t)$ es continua en el 0, entonces $X_n \xrightarrow{\mathcal{L}} X$ y $\varphi(t)$ es la función característica de X .

A.4. Convergencia en media de orden r

Definición A.4 (Convergencia en media de orden r). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias, diremos que **converge en media de orden r** a la variable aleatoria X si

$$\lim_{n \rightarrow \infty} E(|X_n - X|^r) = 0,$$

siendo $E(|X_n|^r)$ y $E(|X|^r)$ finitas.

Notación. Denotaremos la convergencia en orden r como

$$X_n \xrightarrow{mr} X.$$

Cuando $r = 2$, hablamos de **convergencia en media cuadrática** y escribimos

$$X_n \xrightarrow{mc} X.$$

Observación. Si existe el momento de orden r , sabemos que existen todos los momentos de orden inferior. De esta forma, si $s \leq r$,

$$X_n \xrightarrow{mr} X \Rightarrow X_n \xrightarrow{ms} X.$$

Proposición A.4 (Propiedades). Algunas propiedades son:

- Si $X_n \xrightarrow{mc} X$, entonces $E(X_n) \xrightarrow{mc} E(X)$ y $E(X_n^2) \xrightarrow{mc} E(X^2)$. De ambas se deduce que $V(X_n) \xrightarrow{mc} V(X)$.
- La sucesión $\{X_n\}_{n \in \mathbb{N}}$ converge en media cuadrática a una constante c si y solo si se verifica que $\lim_{n \rightarrow \infty} E(X_n) = c$ y $\lim_{n \rightarrow \infty} V(X_n) = 0$.
- Si $X_n \xrightarrow{mc} X$ e $Y_n \xrightarrow{mc} Y$,
 - $E(X_n Y_n) \xrightarrow{mc} E(XY)$.
 - De esta propiedad y la primera se tiene que $\text{Cov}(X_n, Y_n) \xrightarrow{mc} \text{Cov}(X, Y)$.

Teorema A.6. Si $X_n \xrightarrow{mc} X$, entonces $X_n \xrightarrow{P} X$.

A.5. Leyes de los grandes números

A.5.1. Ley débil de los grandes números

Teorema A.7 (Ley débil de los grandes números). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias, definidas sobre un mismo espacio de probabilidad (Ω, \mathcal{A}, P) . Diremos que obedece la ley débil de los grandes números si existen dos sucesiones $\{A_n\}_{n \in \mathbb{N}}, \{B_n\}_{n \in \mathbb{N}} \subset \mathbb{R}$ con $B_n > 0$ y $B_n \rightarrow \infty$ creciente, tales que

$$\frac{S_n - A_n}{B_n} \xrightarrow{P} 0, \quad n \rightarrow \infty,$$

donde $S_n = \sum_{i=1}^n X_i$.

Teorema A.8 (Teorema de Chebychev). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias independientes con $E(X_n) < \infty, \forall n \in \mathbb{N}$. Supongamos que existe $\gamma > 0$ tal que $V(X_n) \leq \gamma, \forall n \in \mathbb{N}$. Entonces,

$$\frac{S_n - E(S_n)}{n} \xrightarrow{P} 0.$$

Teorema A.9 (Teorema de Markov). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias con $\lim_{n \rightarrow \infty} V(\bar{X}_n) = 0$, donde $\bar{X}_n = \frac{S_n}{n}$. Entonces,

$$\frac{S_n - E(S_n)}{n} \xrightarrow{P} 0.$$

Teorema A.10 (Teorema de Khintchine). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas de media finita μ , entonces

$$\frac{S_n}{n} \xrightarrow{P} \mu.$$

Teorema A.11 (Teorema de Bernoulli). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes tales que $X_n \equiv B(1, p), \forall n \in \mathbb{N}$, entonces

$$\frac{S_n}{n} \xrightarrow{P} p.$$

A.5.2. Ley fuerte de los grandes números

Teorema A.12 (Ley fuerte de los grandes números). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias definidas sobre un mismo espacio de probabilidad (Ω, \mathcal{A}, P) . Diremos que obedece la ley fuerte de los grandes números si existen $\{A_n\}_{n \in \mathbb{N}}, \{B_n\}_{n \in \mathbb{N}} \subset \mathbb{R}$ con $B_n > 0$ y $B_n \rightarrow \infty$ creciente tales que

$$\frac{S_n - A_n}{B_n} \xrightarrow{cs} 0.$$

Teorema A.13 (Teorema de Kolmogorov). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes con $E(X_n) = 0$ y $V(X_n) = \sigma_n^2, \forall n \in \mathbb{N}$, tales que

$$\sum_{i=1}^{\infty} \frac{\sigma_i^2}{i^2} < \infty,$$

entonces

$$\frac{S_n}{n} \xrightarrow{cs} 0.$$

Teorema A.14 (Teorema de Khintchine). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas de media finita μ , entonces

$$\frac{S_n}{n} \xrightarrow{cs} \mu.$$

A.6. Teorema central del límite

Teorema A.15 (Teorema central del límite). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias definidas sobre un mismo espacio de probabilidad (Ω, \mathcal{A}, P) , con media y varianzas finitas. Diremos que obedece el teorema central del límite si

$$Z_n = \frac{S_n - E(S_n)}{\sqrt{V(S_n)}} \xrightarrow{\mathcal{L}} N(0, 1).$$

Teorema A.16 (Teorema de Moivre). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas con distribución de Bernoulli de parámetro p , entonces

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{\mathcal{L}} N(0, 1).$$

Teorema A.17 (Teorema de Lévy-Lindeberg). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas con media μ y varianza σ^2 finitas, entonces

$$\frac{S_n - nm}{\sigma \sqrt{n}} \xrightarrow{\mathcal{L}} N(0, 1).$$