Estadística

Victoria Torroja Rubio

19/1/2026

Índice general

1. Estadística descriptiva **3**
1.1. Tema 3 7

2. Muestreo **8**
2.1. Modelos estadísticos 8
2.2. Estadísticos muestrales 9
2.3. Propiedades asintóticas de los momentos muestrales 11
2.4. Distribuciones asociadas a la normal 13
2.5. Estadísticos de orden 20

3. Reducción de datos **24**
3.1. Estadísticos suficientes y minimal suficientes 24
3.2. Familia exponencial k-paramétrica 29
3.3. Estadísticos ancilario y completos 31
3.4. Principio de reducción de datos 33

4. Estimación puntual paramétrica **34**
4.1. Propiedades de los estimadores 34

A. Convergencia de variables aleatorias **35**
A.1. Convergencia en probabilidad 35
A.2. Convergencia casi segura 36
A.3. Convergencia en ley 37
A.4. Convergencia en media de orden r 38
A.5. Leyes de los grandes números 39
A.5.1. Ley débil de los grándes números 39
A.5.2. Ley fuerte de los grandes números 40
A.6. Teorema central del límite 41

Despacho: 303E
Correo: beatrizg@ucm.es
Evaluación:

- 80 % examen final
- 20 % evaluación continua (en este caso serán trabajos de R)

La estadística descriptiva no entra en el examen. **Bibliografía:**

- 'Interferencia estadística' de M.A. Gómez Villegas
- 'Statistical interference' de Casella Berger

Capítulo 1

Estadística descriptiva

Práctica:

- Hacer en R el ejemplo 1.3.2 (lo del colesterol) del libro (página 11). Lo que hay que hacer aparece en el ejercicio 1.9.3.
- Programar el coeficiente de simetría y de curtosis en R.
- Demostrar todas las cosas del teorema de Fisher.

Ejemplo. Página 44, Ejercicio 1. Consideramos la población dada por la distribución de Bernuilli $B\left(\frac{1}{2}\right)$. Se consideran todas las m.a.s de tamaño 3, es decir,

$$(X_1, X_2, X_3).$$

Recordamos que

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2, \ \overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Tendremos que

$$\overline{X} = \begin{cases} 0 \to \frac{1}{8} \\ \frac{1}{3} \to \frac{3}{8} \\ \frac{2}{3} \to \frac{3}{8} \\ 1 \to \frac{1}{8} \end{cases}.$$

De esta forma tenemos que

$$P_{\overline{X}}(0) = \frac{1}{8}, \quad P_{\overline{X}}\left(\frac{1}{3}\right) = \frac{3}{8}, \text{ etc.}$$

Lo que estamos haciendo es considerar los diferentes casos para X_1, X_2 y X_3 y calcular la media en cada caso. A partir de ahí, estamos tratando a la media como una variable aleatoria discreta.

Ejemplo. Página 44, Ejercicio 2. Una forma de media θ y varianza 1. Se toma una m.a.s de tamaño n. Así, tenemos que $X \sim F_\theta(x) = P_\theta(X \leq x)$. Tendremos que $E_\theta[X] = \theta$ y $V_\theta(X) = 1$. Tenemos que calcular θ para que

$$P_\theta\left(\left|\overline{X} - \theta\right| \leq 0{,}5\right) \geq 0{,}95.$$

Tenemos que aplicar la desigualdad de Chebychev, primer calculamos

$$E_\theta\left[\overline{X}\right] = \frac{1}{n}\sum_{i=1}^{n} E_\theta[X_i] = \theta.$$

Por otro lado, $D_\theta(X) = \sqrt{V_\theta(X)} = 1$, así

$$D_\theta\left(\overline{X}\right) = \sqrt{V_\theta\left(\overline{X}\right)} = \sqrt{V_\theta\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)} =? \frac{1}{n}\sum_{i=1}^{n} V_\theta(X_i) = \frac{1}{n} \to 0.$$

Aplicando la desigualdad de Chebychev

$$P_\theta\left(\left|\overline{X} - \theta\right| \geq \frac{K}{n}\right) \leq \frac{1}{K}.$$

Ejemplo. Página 45, Ejercicio 6. Sea una m.a.s de tamaño n calculamos la distribución de la media muestral $\overline{X}$, cuando la población:

(b) $X \sim \gamma(p, a)$. Denotamos $\theta = (p, a) \in \mathbb{R}^+ \times \mathbb{R}^+$ y decimos que $\theta \in \Theta \subset \mathbb{R}^2$. Recordamos que

$$f(x|_\theta) = f_\theta(x) = \frac{a^p x^{p-1} e^{-ax}}{\Gamma(p)},\ x > 0.$$

Hacemos el ejercicio con la ecuación característica:

$$\varphi_{\overline{X}}(t) = E_\theta\left[e^{it\overline{X}}\right] = E_\theta\left[e^{i\frac{t}{n}\sum_{i=1}^{n} X_i}\right] = \prod_{i=1}^{n} \varphi_{X_i}\left(\frac{t}{n}\right) = \varphi_X\left(\frac{t}{n}\right)^n = \left(1 - i\frac{t}{na}\right)^{-pn}.$$

La función característica se corresponde con $\gamma(np, na)$.

(c) Basta con sustituir $\lambda = 1$ en el apartado anterior.

Distribuciones asociadas a la normal

Consideremos que $(X_1, \ldots, X_n)$ es una m.a.s con cada variable independientes y siguen una distribución $X \sim N(0, 1)$. Consideremos la variable aleatoria

$$Y := \sum_{i=1}^{n} X_i^2 = X_1^2 + \cdots + X_n^2.$$

Tenemos que

$$\varphi_Y(t) = \prod_{i=1}^{n} \varphi_{X_i^2}(t).$$

En general, si $Z = X^2$,

$$F_Z(z) = P(Z \leq z) = P\left(X^2 \leq z\right) = P\left(-\sqrt{z} \leq X \leq \sqrt{z}\right) = F_X\left(\sqrt{z}\right) - F_X\left(-\sqrt{z}\right).$$

La función de densidad será

$$f_Z(t) = \frac{1}{2\sqrt{z}} f_X\left(\sqrt{z}\right) + \frac{1}{2\sqrt{z}} f_X\left(-\sqrt{t}\right) = \frac{1}{\sqrt{2\pi}} t^{-\frac{1}{2}} e^{-\frac{1}{2}t},\ t > 0.$$

Podemos ver que se trata de la función de densidad de una distribución Gamma, así, $Z \sim \gamma\left(\frac{1}{2}, \frac{1}{2}\right)$. Definimos $\chi_1^2 \sim \gamma\left(\frac{1}{2}, \frac{1}{2}\right)$, el uno viene de que tenemos un grado de libertad (se genera a partir de una normal $N(0,1)$). Por la propiedad de reproductividad de la distribución Gamma, tenemos que $Y \sim \gamma\left(\frac{n}{2}, \frac{1}{2}\right)$. A esta distribución la llamamos $\chi_n^2 \sim \gamma\left(\frac{n}{2}, \frac{1}{2}\right)$ (decimos que tiene n grados de libertad porque viene de n distribuciones normales $N(0,1)$). Recordamos que la función característica de una distribución γ es

$$\varphi(t) = \left(1 - \frac{it}{a}\right)^{-p}.$$

Ejemplo. Ejercicio 19. Sea $(X_1, \ldots, X_n)$ una m.a.s distribuida idénticamente a X tal que

$$P(X = x_i) = p_i,\ i \in \mathbb{N}.$$

Sea $\left(X_{(1)}, \ldots, X_{(n)}\right)$ la muestra ordenada de menor a mayor. Demostremos que la distribución para $X_{(k)}$ es discreta y

$$P\left(X_{(1)} \leq x_i\right) = \sum_{j=k}^{n} \binom{n}{j} \left(F(x_i)\right)^j \left(1 - F(x_i)\right)^{n-j}.$$

El resto viene dado en el enunciado. Tenemos que $X_{(1)} = \text{mín}\{X_1, \ldots, X_n\}$ y $X_{(n)} = \text{máx}\{X_1, \ldots, X_n\}$. Tenemos que

$$F_{X_{(n)}}(t) = P\left(X_{(n)} \leq t\right) = P\left(\bigcap_{1 \leq i \leq n} \{X_i \leq t\}\right) = \prod_{i=1}^{n} P(X_i \leq t) = F_X(t)^n.$$

Por otro lado,

$$F_{X_{(1)}}(t) = 1 - P\left(X_{(1)} > t\right) = 1 - P\left(\bigcap_{1 \leq i \leq n} \{X_i > t\}\right) = 1 - \prod_{i=1}^{n} P(X_i > t) = 1 - (1 - F_X(t))^n.$$

Ahora, buscamos $F_{X_{(k)}}(t)$ para $k \in \{1, \ldots, n\}$. Tenemos que

$$F_{X_{(k)}}(t) = P\left(X_{(k)} \leq t\right) = \sum_{j=k}^{n} P(\text{'exactamente } j \text{ por debajo de } t') = \sum_{j=k}^{n} \binom{n}{j} F_X(t)^j \left(1 - F_X(t)\right)^{n-j}.$$

Finalmente, recordamos que $P_{X_{(k)}}(x_i) = F_{X_{(k)}}(x_i) - F_{X_{(k)}}(x_{i-1})$.

Teorema 1.1. Es cierto que $\sqrt{n}\left(b_2-\sigma^2\right)\to N\left(0,\sqrt{\beta_4-\sigma^4}\right)$.

Teorema 1.2 (Teorema de Fisher)**.** Sea $(X_1,\ldots,X_n)$ una m.a.s idénticamente distribuida a $X\sim N(\mu,\sigma)$. Entonces se cumple que

1. $\overline{X}\sim N\left(\mu,\dfrac{\sigma}{\sqrt{n}}\right)$.
2. $\dfrac{(n-1)S^2}{\sigma^2}\sim\chi^2_{n-1}$.
3. $\dfrac{\overline{X}-\mu}{\frac{S}{\sqrt{n}}}\sim t_{n-1}$.
4. $\overline{X}$ y $S=\sqrt{\dfrac{1}{n-1}\displaystyle\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2}$ son independientes.

Demostración. Cogemos $Z=\dfrac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}}$ así, tendremos que

$$T=\frac{\frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{(n-1)}{\sigma^2}\frac{S^2}{n-1}}}=\frac{\overline{X}-\mu}{\frac{S}{\sqrt{n}}}.$$

En esto último hemos aplicado el punto 2 del teorema de Fisher. Esto es en teoría una demostración del punto 3 del teorema de Fisher. Para demostrar 4 basta con ver que $Cov\left(\overline{X},S\right)=0$, por ser $X\sim N(\mu,\sigma)$. □

Definición 1.1. Sea $(X_1,\ldots,X_n)$ una m.a.s (n) idénticamente distribuidas a $N(0,1)$. Tenemos que $\chi^2_{n-1}:=X_1^2+\cdots+X_n^2\sim\gamma\left(p=\dfrac{n-1}{2},a=\dfrac{1}{2}\right)$.

Definición 1.2 (Distribución t_k-student)**.** Sea $\{X_i\}_{i\in\mathbb{N}}$ una sucesión de variables independientes idénticamente distribuidas que siguen la distribución $X\sim N(0,1)$. Cogemos las k primeras y definimos

$$Y=\sqrt{\frac{X_1^2+\cdots+X_k^2}{k}}\sim\sqrt{\frac{\chi^2_k}{k}}.$$

Si $Z=X_{k+1}\sim N(0,1)$, entonces definimos la T de Student como $T=\dfrac{Z}{Y}$.

1.1. Tema 3

Ejemplo (Ejercicio 1)**.** Sea X una observación de una población $N(0,\sigma)$. Tenemos que $\sigma \in \Theta \subset \mathbb{R}^+$. Sabemos que

$$f_\sigma(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}x^2}.$$

Veamos si $|X|$ es un estadístico suficiente. Por el teorema de caracterización de Fisher es fácil ver que $T = |X|$ es suficiente.

Ejemplo (Ejercicio 2)**.** Sea $(X_1, \ldots, X_n)$ una m.a.s. de X.

(a) $Beta(\alpha,\beta)$, $\alpha,\beta > 0$. Tendremos que $\theta = (\alpha,\beta) \in \mathbb{R}^+ \times \mathbb{R}^+$. Tendremos que

$$f_\theta(x) \propto K(\alpha,\beta)\, x^{\alpha-1}(1-x)^{\beta-1} = K(\alpha,\beta)\, e^{(\alpha-1)\ln x + (\beta-1)\ln(1-x)}.$$

Podemos coger $q_1(\theta) = \alpha - 1$ y $t_1(x) = \ln x$ y también $q_2(\theta) = \beta - 1$ y $t_2(x) = \ln(1-x)$. Así, el estadístico suficiente será

$$\left(\sum_{i=1}^n t_1(X_i), \sum_{i=1}^n t_2(X_i)\right) = \left(\sum_{i=1}^n \ln X_i, \sum_{i=1}^n \ln(1-X_i)\right).$$

(b)

Capítulo 2

Muestreo

2.1. Modelos estadísticos

Cada fenómeno aleatorio está gobernado por una función de probabilidad. Para estudiar dicho fenómeno, nos centramos en estudiar su distribución de probabilidad subyacente.

Llamaremos **población** a una variable aleatoria $X \sim F$, donde F es una función de distribución no completamente conocida. Nuestro objetivo será obtener información sobre ciertas características de la distribución de X. Para ello, replicaremos el experimento aleatorio (de forma idéntica e independiente) un número de n veces.

Hay varios tipos de inferencia:

- Inferencia frecuentista: utilizamos información objetiva, es decir, datos de la muestra.
- Inferencia bayesiana: se utiliza información subjetiva.

También podemos diferenciar en función del grado de conocimiento sobre F:

- Inferencia paramétrica: se conoce la forma funcional de F, excepto por ciertas características.
- Inferencia no paramétrica: no se asume una forma funcional para F.

Supongamos por ahora que la verdadera función de distribución F de nuestra población X está contenida en una familia $\mathcal{F}$ de funciones de distribución asociadas a X.

Definición 2.1 (Modelo estadístico). Un **modelo estadístico** es una terna $(\chi, \beta_\chi, \mathcal{F})$, donde

- $\chi \subset \mathbb{R}$ es el espacio muestral.
- β_χ es una σ-álgebra de Borel sobre χ.
- $\mathcal{F}$ es un conjunto de funciones de distribución asociadas a medidas de probabilidad P_X definidas sobre (χ, β_χ).

En la inferencia paramétrica asumimos que conocemos la forma funcional de la verdadera función de distribución F de la variable aleatoria de interés X, excepto por k parámetros $\theta = (\theta_1, \ldots, \theta_k)$. En este caso, la familia $\mathcal{F}$ tiene la forma

$$\mathcal{F} = \{F(\cdot;\theta) \ : \ \theta \in \Theta\}.$$

Decimos que $\theta \in \Theta \subset \mathbb{R}^k$, donde Θ es el **espacio paramétrico**. En el caso de inferencia frecuentista consideraremos que θ es un valor fijo y desconocido, por lo que escribiremos $f_\theta(x)$ para designar a la función de masa. Sin embargo, en el planteamiento bayesiano consideraremos que θ es una variable aleatoria, por lo que escribiremos $f(x|\theta)$.

Definición 2.2 (Modelo estadístico paramétrico). Un **modelo estadístico paramétrico** es una terna $(\chi, \beta_\chi, \mathcal{F})$ donde

$$\mathcal{F} = \{F(\cdot;\theta) \ : \ \theta \in \Theta\}.$$

Ejemplo. Consideremos los siguientes ejemplos.

- Estimar la probabilidad de que un producto resulte defectuoso en una cadena de producción: $X \sim Bern(\theta)$, $\theta \in [0,1]$.
- Estimar el tiempo entre llegadas a la cola de un servidor: $X \sim \exp(\lambda)$, $\lambda > 0$.
- Estimar el peso esperado de niños hasta cierta edad en una región determinada: $X \sim N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$.

2.2. Estadísticos muestrales

Consideremos una variable aleatoria X a la que llamaremos **universo** o **población** cuya función de distribución F viene dada por algún elemento de una familia $\mathcal{F}$ de distribuciones de probabilidad.

Definición 2.3 (Muestra aleatoria simple (m.a.s.)). Dada una población X se llama **muestra aleatoria simple (m.a.s.)** de tamaño n a la repetición de $X_1, \ldots, X_n$ variables aleatorias independientes con distribución igual a la de X.

Observación. El modelo estadístico asociado a nuestra muestra $\overrightarrow{X} = (X_1, \ldots, X_n)$ es $(\chi^n, \beta_{\chi^n}, \mathcal{F}^n)$, donde $\mathcal{F}^n$ es el conjunto de funciones de distribución $F_X : \mathbb{R}^n \to \mathbb{R}$ tales que

$$F_X(x_1, \ldots, x_n) = \prod_{i=1}^{n} F(x_i), \ \forall (x_1, \ldots, x_n) \in \mathbb{R}^n.$$

Observación. Por ejemplo, la función de distribución de la muestra $(x_1, \ldots, x_n)$ es

$$F(x_1, \ldots, x_n) = \prod_{i=1}^{n} F(x_i),$$

donde $F(x)$ es la función de distribución de X, que viene dada por un elemento de $\mathcal{F}$.

Observación. Los datos observados $(x_1, \ldots, x_n)$ son un resultado o realización de la m.a.s., $X_1 = x_1, \ldots, X_n = x_n$.

Definición 2.4 (Estadístico muestral)**.** Dada $(X_1, \ldots, X_n)$ una m.a.s. de X, a toda $f : \mathbb{R}^n \to \mathbb{R}^k$ función conocida medible recible el nombre de **estadístico muestral**.

Ejemplo. Algunos ejemplos de estadíscitos muestrales son la **media muestral** que viene dada como

$$\overline{X} := \frac{1}{n}\sum_{i=1}^{n} X_i,$$

y la **cuasivarianza muestral**

$$S^2 := \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2.$$

Definición 2.5 (Momentos centrales)**.** Se llama **momento muestral respecto al origen** de orden k a $a_k := \frac{1}{n}\sum_{i=1}^{n} X_i^k$, con $k > 0$. Análogamente, se llama **momento muestral respecto al centro** de orden k a $b_k := \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^k$, con $k > 0$.

Ejemplo. Como hemos visto antes, tendremos que $a_1 = \overline{X}$.

Observación. Es sencillo ver que

$$b_k = a_k - \binom{k}{1}\overline{x}a_{k-1} + \cdots + (-1)^k\,\overline{x}^k,$$

es decir, los momentos muestrales respecto al centro se puede calcular en función de los momentos muestrales respecto al origen. En particular,

$$b_2 = a_2 - a_1^2 = a_2 - \overline{X}^2.$$

Proposición 2.1. Dada una m.a.s. de tamaño n de una población X con momento de segundo orden finito [a], se tiene que $E[\overline{X}] = \mu$ y $V\left(\overline{X}\right) = \frac{\sigma^2}{n}$, donde $\mu = E[X]$ y $\sigma^2 = V(X)$.

[a] Esta hipótesis es necesaria para asegurar la existencia de σ^2 y μ.

Demostración. Aplicando las propiedades de la esperanza,

$$E\left[\overline{X}\right] = E\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} E\left[X_i\right] = \frac{1}{n}\sum_{i=1}^{n}\mu = \mu.$$

Por otro lado, aplicando las propiedades de la varianza,

$$\begin{aligned} V\left(\overline{X}\right) =& E\left[\left(\overline{X}-\mu\right)^2\right] = E\left[\left(\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\mu\right)\right)^2\right] \\ =& \frac{1}{n^2}E\left[\sum_{i=1}^{n}\left(X_i-\mu\right)^2 + 2\sum_{i=1}^{n}\sum_{j=1,j>i}^{n}\left(X_i-\mu\right)\left(X_j-\mu\right)\right] \\ =& \frac{1}{n^2}\left[\sum_{i=1}^{n}V\left(X_i\right) + 2\sum_{i=1}^{n}\sum_{j>i}E\left[X_i-\mu\right]E\left[X_j-\mu\right]\right] = \frac{\sigma^2}{n}. \end{aligned}$$

Podemos observar que el segundo sumando se anula. □

2.3. Propiedades asintóticas de los momentos muestrales

Sea $(X_1,\ldots,X_n)$ una m.a.s (n) de X con $\mu = E[X]$ y $\sigma = \sqrt{V(X)}$.

Proposición 2.2 (Momentos muestrales respecto al origen)**.** Se cumple que si $n \to \infty$

$$a_k = \frac{1}{n}\sum_{i=1}^{n}X_i^k \xrightarrow{c.s.} \alpha_k = E\left[X^k\right].$$

Particularmente,

$$\overline{X} \xrightarrow{c.s.} \mu \quad \text{(Ley Fuerte de Kintchine, } \mu < \infty\text{)}.$$

Demostración. Por el teorema de Kintchine, tenemos que para una sucesión de variables aleatorias $\{Y_n\}_{n\in\mathbb{N}}$ independientes e idénticamente distribuidas con $E[Y_i] = \mu < \infty$, $\forall n \in \mathbb{N}$, tenemos que $\overline{Y} \xrightarrow{cs} \mu$. El resultado general lo obtenemos tomando $Y_i = X_i^k$. □

Proposición 2.3 (Momentos muestrales respecto a la media)**.** Si una población tiene momentos de orden $k > 0$, el momento muestral respecto al centro de orden k, converge, casi seguro, al momento poblacional respecto al centro de orden k, es decir

$$b_k = \frac{1}{n}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^k \xrightarrow{cs} \beta_k = E\left[\left(X-\mu\right)^k\right].$$

En particular,

$$\sigma_n^2 \xrightarrow{cs} \sigma^2 \quad \text{y} \quad S_n^2 \xrightarrow{cs} \sigma^2.$$

Demostración. Hacer en casa. □

Proposición 2.4. Si la población tiene momentos de orden $2k$ respecto al origen, entonces se tiene la siguiente convergencia en ley

$$\frac{a_k - \alpha_k}{\sqrt{\alpha_{2k} - \alpha_k^2}}\sqrt{n} \xrightarrow{\mathcal{L}} N(0,1).$$

En particular,

$$\sqrt{n}\frac{\overline{X} - \mu}{\sigma} \xrightarrow{\mathcal{L}} N(0,1) \text{ (Teorema de Lévy-Lindeberg).}$$

Demostración. Basta con aplicar el teorema central del límite, $\{Y_n\}_{n\in\mathbb{N}}$ con v.a.i.i.d con momento de segundo orden y $E[Y_n] = \mu$ y $V(Y_n) = \sigma^2 < \infty$. Entonces, tendremos que

$$\frac{\overline{Y} - \mu}{\sigma}\sqrt{n} \xrightarrow{\mathcal{L}} N(0,1).$$

Para obtener el resultado general podemos considerar $Y_n = X_n^k$ y $a_k = \overline{Y}$, de forma que $\mu = \alpha_k$ y $\sigma^2 = \alpha_{2k} - \alpha_k^2$. □

Proposición 2.5. Si existe el momento poblacional respecto al origen de orden $2k$, entonces

$$\sqrt{n}\frac{b_k - \beta_k}{\sqrt{\beta_{2k} - \beta_k^2 - 2k\beta_{k-1}\beta_{k+1} + k^2\beta_{k-1}^2\beta_2}} \xrightarrow{\mathcal{L}} N(0,1).$$

En particular,

$$\sqrt{n}\frac{\sigma_n^2 - \sigma^2}{\sqrt{\beta_4 - \sigma^4}} \xrightarrow{\mathcal{L}} N(0,1).$$

Teorema 2.1 (Teorema de Slutsky)**.** Si $X_n \xrightarrow{\mathcal{L}} X$ e $Y_n \xrightarrow{P} a$, con $a \in \mathbb{R}$, entonces

1. $Y_n X_n \xrightarrow{\mathcal{L}} aX$.
2. $X_n + Y_n \xrightarrow{\mathcal{L}} X + a$.

Lema 2.1. Si $\{a_n\}_{n\in\mathbb{N}} \subset \mathbb{R}$ con $\lim_{n\to\infty} a_n = \infty$ y $a \in \mathbb{R}$ tal que

$$a_n(X_n - a) \xrightarrow{\mathcal{L}} X,$$

entonces para $g : \mathbb{R} \to \mathbb{R}$ con derivada continua y no nula en a se tiene que

$$a_n(g(X_n) - g(a)) \xrightarrow{\mathcal{L}} g'(a)X.$$

Otro estadístico muestral importante es la función de distribución empírica o muestral.

Definición 2.6 (Función de distribución empírica). Dada una realización particular de una muestra $(x_1, \ldots, x_n)$, la **función de distribución empírica** viene dada por

$$F_n(x) = \begin{cases} 0, \ x < x_{(1)} \\ \frac{k}{n}, \ x_{(k)} \leq x < x_{(k+1)}, \ k = 1, \ldots, n-1 \\ 1, \ x_{(n)} \leq x \end{cases} .$$

Recordamos que $\left(x_{(1)}, \ldots, x_{(n)}\right)$ es la muestra ordenada de menor a mayor.

La función de distribución empírica también se puede escribir de la forma

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} I_{(-\infty, x]}(x_i).$$

Es fácil ver que para $t \in \mathbb{R}$ fijo se verifica que

$$nF_n(t) \sim Bin(n, F(t)).$$

Observación. Para todo x se verifica que

$$F_n(x) \xrightarrow{c.s.} F(x),$$

donde $F(x)$ es la función de distribución de la población. En efecto, si tomamos $Y_i = I_{(-\infty, x]}(x_i)$, tenemos que

$$E[Y_i] = F(x), \quad V(Y_i) = F(x)[1 - F(x)], \quad F_n(x) = \overline{Y}.$$

Aplicando la ley de los grandes números obtenemos la convergencia que hemos mencionado antes. Por otro lado, podemos aplicar el Teorema Central del Límite para obtener que

$$\sqrt{n} \frac{F_n(x) - F(x)}{\sqrt{F(x)[1 - F(x)]}} \xrightarrow{\mathcal{L}} Z \sim N(0, 1).$$

Teorema 2.2 (Teorema central de la estadística). Si se tiene una m.a.s. de tamaño n de una población X con función de distribución $F(x)$, para cualquier $\varepsilon > 0$ se tiene que

$$\lim_{n \to \infty} P\left(\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \geq \varepsilon\right) = 0.$$

Observación. Este teorema nos dice que si se quiere determinar de forma aproximada la función de distribución, se puede obtener una m.a.s. de tamaño n grande, construir a partir de ella la función de distribución empírica y esperar que $F_n(x)$ sea una buena aproximación de $F(x)$.

2.4. Distribuciones asociadas a la normal

Para muchas variables podemos asumir que su distribución pertenece a la familia Gausiana $N(\mu, \sigma)$, donde tendremos que

$$\theta = (\mu, \sigma) \in \Theta = (-\infty, \infty) \times (0, \infty).$$

En esta sección supondremos que $(X_1, \ldots, X_n)$ es una m.a.s. (n) de $X \sim N(\mu, \sigma)$.

Teorema 2.3 (Distribución de la media muestral)**.** Si $(X_1, \ldots, X_n)$ es una m.a.s. (n) de $X \sim N(\mu, \sigma)$, entonces

$$\overline{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right).$$

Demostración. Sabemos que $\varphi_X(t) = e^{it\mu - \frac{1}{2}t^2\sigma^2}$. Por tanto, tendremos que

$$\begin{aligned}\varphi_{\overline{X}}(t) =& E\left[e^{it\overline{X}}\right] = E\left[e^{it\frac{1}{n}\sum_{i=1}^n X_i}\right] = E\left[\prod_{i=1}^n e^{it\frac{1}{n}X_i}\right] = \prod_{i=1}^n \varphi_{X_i}\left(\frac{t}{n}\right)\\ =& \varphi_X^n\left(\frac{t}{n}\right) = e^{it\mu - \frac{1}{2}\frac{\sigma^2}{n}t^2}.\end{aligned}$$

Por tanto, tenemos que $\overline{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$. □

Definición 2.7 (Estadístico Z)**.** El **estadístico** Z se obtiene estandarizando la media muestral

$$Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1).$$

Definición 2.8 (Distribución χ^2)**.** Una **distribución** χ_n^2 con n grados de libertad es la distribución de la suma de n variables aleatorias independientes $Z_1, \ldots, Z_n$ con distribución $N(0, 1)$, es decir

$$Y = \sum_{i=1}^n Z_i^2 \sim \chi_n^2.$$

Proposición 2.6. Se verifica $\chi_n^2 \sim \gamma\left(a = \frac{1}{2}, p = \frac{n}{2}\right)$.

Demostración. Como $Z \sim N(0, 1)$, tenemos que $\varphi_Z(t) = \frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}t^2}$. En primer lugar, calculamos la distribución de Z^2:

$$F_{Z^2}(y) = P\left(Z^2 \leq y\right) = P\left(-\sqrt{y} \leq Z \leq \sqrt{y}\right) = F_Z\left(\sqrt{y}\right) - F_Z\left(-\sqrt{y}\right) = 2F_Z\left(\sqrt{y}\right) - 1.$$

Así, tenemos que

$$f_{Z^2}(y) = 2f_Z\left(\sqrt{y}\right)\frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}y}y^{-\frac{1}{2}}.$$

Por tanto, tenemos que $Z^2 \sim \gamma\left(a = \frac{1}{2}, p = \frac{1}{2}\right)$. Así, tendremos que $\varphi_{Z^2}(t) = (1 - 2it)^{-\frac{1}{2}}$,

por lo que

$$\varphi_{\chi_n^2}(t) = E\left[e^{it\sum_{i=1}^n Z_i^2}\right] = \prod_{i=1}^n \varphi_{Z_i^2}(t) = \varphi_{Z^2}^n(t) = (1-2it)^{-\frac{n}{2}}.$$

Por tanto, tenemos que $\chi_n^2 \sim \gamma\left(a = \frac{1}{2}, p = \frac{n}{2}\right)$. □

Observación (Propiedades de la distribución χ_n^2). Las siguientes propiedades son fáciles de comprobar:

- A partir de la proposición anterior es sencillo ver que la función de densidad de χ_n^2 será
$$f_{\chi_n^2}(x) = \frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)} e^{-\frac{1}{2}y} y^{\frac{n}{2}-1}, x > 0.$$
- Se tiene que $E\left[\chi_n^2\right] = n$ y $V\left(\chi_n^2\right) = 2n$.
- **Propiedad de aditividad.** Si $Y_i \sim \chi_{n_i}^2$, con $i = 1, \ldots, k$, son independientes, entonces
$$Y = \sum_{i=1}^k Y_i \sim \chi_n^2, \quad n = \sum_{i=1}^k n_i.$$

Lema 2.2. Si $Y \sim \gamma(a, p)$, entonces $T = 2aY \sim \gamma\left(a = \frac{1}{2}, p\right)$.

Demostración. Como $Y \sim \gamma(a, p)$ se tiene que

$$f_Y(y) = \frac{a^p}{\Gamma(p)} e^{-ay} y^{p-1}.$$

Por otro lado, como $T = 2aY$, se tiene que $Y = \frac{1}{2a}T$. Así, tenemos que

$$f_T(t) = f_Y\left(\frac{1}{2a}t\right)\frac{1}{2a} = \frac{\left(\frac{1}{2}\right)^p}{\Gamma(p)} e^{-\frac{1}{2}t} t^{p-1}.$$

□

Proposición 2.7. Sea $(X_1, \ldots, X_n)$ una m.a.s. (n) de $X \sim N(0, \sigma)$. Entonces,

$$a_2 = \frac{1}{n}\sum_{i=1}^n X_i^2 \sim \gamma\left(a = \frac{n}{2\sigma^2}, p = \frac{n}{2}\right) \quad \text{y} \quad \sigma^2\sqrt{\frac{n}{2}}\left(a_2 - \sigma^2\right) \xrightarrow{\mathcal{L}} N(0,1).$$

Demostración. Sea $Z_i = \dfrac{X_i}{\sigma} \sim N(0,1)$, para $i \in \{1, \ldots, n\}$. Entonces, tenemos que

$$\sum_{i=1}^{n} Z_i^2 \sim \chi_n^2 \equiv \gamma\left(a = \frac{1}{2}, p = \frac{n}{2}\right).$$

De esta manera, tenemos que

$$a_2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2 = \frac{\sigma^2}{n}\sum_{i=1}^{n} Z_i^2.$$

Por tanto,

$$f_{a_2}(t) = f_{\chi_n^2}\left(\frac{n}{\sigma^2}t\right)\frac{n}{\sigma^2} = \frac{\left(\frac{n}{2\sigma^2}\right)^{\frac{n}{2}}}{\Gamma\left(\frac{n}{2}\right)} e^{-\frac{n}{2\sigma^2}t} t^{\frac{n}{2}-1}.$$

Así, tenemos que $a_2 \sim \Gamma\left(a = \dfrac{n}{2\sigma^2}, p = \dfrac{n}{2}\right)$. □

Definición 2.9 (Distribución t de Student)**.** Dadas las variables independientes $X, X_1, \ldots, X_n$ con distribución $N(0,1)$, la distribución de la variable aleatoria

$$T = \frac{X}{\sqrt{\frac{1}{n}\sum_{i=1}^{n} X_i^2}},$$

es una t **de Student** con n grados de libertad, denotada t_n.

Proposición 2.8 (Función de densidad de la t de Student)**.** La función de densidad de $T \sim t_n$ es

$$f_T(t) = \frac{1}{\sqrt{n\pi}} \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \ t \in \mathbb{R}.$$

Demostración. Sean $X \sim N(0,1)$ e $Y \sim \sqrt{\dfrac{1}{n}\displaystyle\sum_{i=1}^{n} X_i^2}$. Así, $T \sim \dfrac{X}{Y}$ y tendremos que

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}, \ x \in \mathbb{R} \quad \text{y} \quad f_Y(y) = \frac{n^{\frac{n}{2}}}{2^{\frac{n}{2}-1}\Gamma\left(\frac{n}{2}\right)} e^{-\frac{n}{2}y^2} y^{n-1}, \ y > 0.$$

La función de densidad conjunta de X e Y será $f(x,y) = f_X(x) f_Y(y)$. Haciendo el cambio $T = \dfrac{X}{Y}$ y $Z = Y$, obtenemos la función de densidad

$$f(t,u) = k e^{-\frac{1}{2}\left(t^2+n\right)u^2} u^n, \ t \in \mathbb{R}, \ u \geq 0, \quad k = \frac{n^{\frac{n}{2}}}{2^{\frac{n-1}{2}}\Gamma\left(\frac{1}{2}\right)\Gamma\left(\frac{n}{2}\right)}.$$

La función de densidad de T es se obtiene como la marginal de la anterior [a]:

$$f_T(t) = \int_0^\infty f(t,u)\ du = k\int_0^\infty e^{-\frac{1}{2}\left(t^2+n\right)u^2} u^n\ du = \frac{k}{2}\left(\frac{n+t^2}{2}\right)^{-\frac{n+1}{2}} \Gamma\left(\frac{n+1}{2}\right).$$

Sustituyendo el valor de k obtenemos

$$f_T(t) = \frac{n^{\frac{n}{2}}}{2^{\frac{n}{2}-\frac{1}{2}}\Gamma\left(\frac{1}{2}\right)\Gamma\left(\frac{n}{2}\right)}\frac{1}{2}\left(\frac{n+t^2}{2}\right)^{-\frac{n+1}{2}} \Gamma\left(\frac{n+1}{2}\right).$$

Simplificando obtenemos la expresión deseada. □

[a] Para resolver la integral conviene mirar el libro.

Observación (Propiedades de la distribución t de Student). Es fácil de comprobar que:

- La distribución t de Student es simétrica.
- Para $n > 2$ se cumple que $E[T] = 0$ y $V(T) = \dfrac{n}{n-2}$. Para $n \leq 2$ la varianza no existe.
- En el caso $n = 1$ también se llama **distribución de Cauchy**.

Teorema 2.4 (Teorema de Fisher). Sea $(X_1, \ldots, X_n)$ una m.a.s. (n) de $X \sim N(\mu, \sigma)$, con μ y σ desconocidos.

1. La media muestral y la cuasivarianza muestral son variables aleatorias independientes.
2. Se cumple que $\overline{X} \sim N\left(\mu, \dfrac{\sigma}{\sqrt{n}}\right)$ y $\dfrac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$.
3. Se cumple que
$$\frac{\overline{X}-\mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}.$$

Demostración. 1. Basta con demostrar que $\overline{X}$ y $X_h - \overline{X}$ son independientes para $h = 1, \ldots, n$. Una forma de ver esto es que

$$\varphi_{\overline{X}, X_h-\overline{X}}(t_1, t_2) = \varphi_{\overline{X}}(t_1)\,\varphi_{X_h-\overline{X}}(t_2).$$

Tenemos que

$$\begin{aligned}\varphi_{\overline{X}, X_h-\overline{X}}(t_1, t_2) =& E\left[e^{it_1\overline{X}+it_2\left(X_h-\overline{X}\right)}\right] = E\left[e^{i(t_1-t_2)\overline{X}+it_2X_h}\right]\\ =& E\left[e^{i\frac{t_1-t_2}{n}\sum_{i\neq h}X_i}\right] E\left[e^{i\left(\frac{t_1-t_2}{n}+t_2\right)X_h}\right].\end{aligned}$$

Así, como $\sum_{i\neq h} X_i \sim N\left((n-1)\,\mu, \sigma\sqrt{n-1}\right)$ y $X_h \sim N(\mu,\sigma)$, tenemos que

$$\varphi_{\overline{X},X_h-\overline{X}}(t_1,t_2) = \varphi_{N\left(\mu,\frac{\sigma}{\sqrt{n}}\right)}(t_1)\,\varphi_{N\left(0,\sigma\sqrt{1-\frac{1}{n}}\right)}(t_2).$$

Como $\overline{X} \sim N\left(\mu, \dfrac{\sigma}{\sqrt{n}}\right)$ y

$$X_h - \overline{X} = \left(1-\frac{1}{n}\right)X_h - \frac{\sum_{i\neq h} X_i}{n} \sim N\left(0, \sigma\sqrt{1-\frac{1}{n}}\right),$$

hemos terminado.

2. La primera igualdad ya ha sido demostrada. Sea $S_{n+1}^2 = \dfrac{1}{n}\displaystyle\sum_{i=1}^{n+1}\left(X_i - \overline{X}_{n+1}\right)^2$.

   Podemos ver que

$$nS_{n+1}^2 = (n-1)\,S_n^2 + \left(X_{n+1}-\overline{X}_n\right)^2 \frac{n}{n+1}.$$

   En efecto,

$$\begin{aligned} nS_{n+1}^2 &= \sum_{i=1}^{n+1}\left(X_i-\overline{X}_{n+1}\right)^2 = \sum_{i=1}^{n}\left(X_i-\overline{X}_n+\overline{X}_n-\overline{X}_{n+1}\right)^2 + \left(X_{n+1}-\overline{X}_{n+1}\right)^2 \\ &= (n-1)\,S_n^2 + n\left(\overline{X}_n-\overline{X}_{n+1}\right)^2 + \left(X_{n+1}-\overline{X}_{n+1}\right)^2. \end{aligned}$$

   Aplicando que $\overline{X}_{n+1} = \dfrac{n\overline{X}_n + X_{n+1}}{n+1}$, obtenemos la igualdad deseada. Ahora, procedemos por inducción. Para $n+1=2$, tenemos que

$$\frac{S_2^2}{\sigma^2} = \left(\frac{X_2-\overline{X}_1}{\sigma\sqrt{2}}\right)^2 \sim \chi_1^2.$$

   Supongamos ahora que es cierto para n, es decir

$$\frac{(n-1)\,S_n^2}{\sigma^2} \sim \chi_{n-1}^2.$$

   Entonces, en el caso $n+1$ tenemos que

$$\frac{nS_{n+1}^2}{\sigma^2} = \frac{(n-1)\,S_n^2}{\sigma^2} + \left(\frac{X_{n+1}-\overline{X}_n}{\sigma\sqrt{\frac{n+1}{n}}}\right)^2 \sim \chi_{n-1}^2 + \chi_1^2 \sim \chi_n^2.$$

3. La variable $\dfrac{\overline{X}-\mu}{\sigma}\sqrt{n}$ tiene distribución $N(0,1)$ y la variable $(n-1)\dfrac{S^2}{\sigma^2}$ tiene distribución χ^2_{n-1}, como acabamos de ver. Por **(1)** tenemos que ambas son independientes, y de aquí el resultado se obtiene fácilmente.

□

Definición 2.10 (Distribución F de Snedecor). Sean $X_1 \sim \chi^2_{n_1}$ y $X_2 \sim \chi^2_{n_2}$ independientes [a] . La distribución de la variable aleatoria

$$F = \frac{\frac{X_1}{n_1}}{\frac{X_2}{n_2}},$$

es una **distribución F de Snedecor** con n_1 grados de libertad en el numerador y n_2 grados de libertad en el denominador, denotada F_{n_1,n_2}.

[a] También podemos enunciar esto tomando dos m.a.s independientes $(X_1,\ldots,X_{n_1})$ y $(Y_1,\ldots,Y_{n_2})$ de una población $N(0,1)$, entonces $\mathcal{F}_{n_1,n_2} = \dfrac{\frac{1}{n_1}\sum_{i=1}^{n_1} X_i^2}{\frac{1}{n_2}\sum_{i=1}^{n_2} Y_i^2}$.

Proposición 2.9 (Función de densidad de la F de Snedecor). La función de densidad de la F de Snedecor con (n_1,n_2) grados de libertad es

$$f(x) = \frac{\binom{n_1}{n_2}^{\frac{n_1}{2}} \Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} x^{\frac{n_1}{2}-1}\left(1+\frac{n_1}{n_2}x\right)^{-\frac{n_1+n_2}{2}}, \ x>0.$$

Demostración. Sea $F_{n_1,n_2} = \dfrac{U}{V}$. Tenemos que la función de densidad de U será

$$f(u) = \frac{n_1^{\frac{n_1}{2}}}{2^{\frac{n_1}{2}}\Gamma\left(\frac{n_1}{2}\right)} u^{\frac{n_1}{2}-1} e^{-\frac{n_1}{2}u}, \ u \geq 0.$$

De esta forma, la función de densidad conjunta de U y V será, dada su independencia,

$$f(u,v) = ku^{\frac{n_1}{2}-1}v^{\frac{n_2}{2}-1}e^{-\frac{1}{2}(n_1u+n_2v)}, \ u,v \geq 0, \quad k = \frac{n_1^{\frac{n_1}{2}} n_2^{\frac{n_2}{2}}}{2^{\frac{n_1+n_2}{2}}\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)}.$$

Haciendo el cambio $S = \dfrac{U}{V}$ y $T = V$, tenemos que

$$f(s,t) = k(st)^{\frac{n_1}{2}-1} t^{\frac{n_2}{2}} e^{-\frac{n_1 s+n_2}{2}t}.$$

Calculamos la función de densidad de S como la función de densidad marginal y nos

queda [a]

$$f(s) = \frac{\binom{n_1}{n_2}^{\frac{n_1}{2}} \Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} s^{\frac{n_1}{2}-1} \left(1+\frac{n_1}{n_2}s\right)^{-\frac{n_1+n_2}{2}}, \ s>0.$$

□

[a] Si se quiere ver cómo resolver la integral en detalle mirar el libro.

Observación (Propiedades de la F de Snedecor). Se puede observar que:

- Para $n_1 = 1$ se tiene que $F_{1,n} \equiv t_n^2$.
- Si $F \sim F_{n_1,n_2}$, entonces $\dfrac{1}{F} \sim F_{n_2,n_1}$.
- Se cumple que

$$E[F] = \frac{n_2}{n_2-2} \quad \text{y} \quad V(F) = \frac{2n_2^2(n_1+n_2-2)}{n_1(n_2-2)^2(n_2-4)}.$$

Corolario 2.1. Si $(X_1,\ldots,X_m)$ es una m.a.s. de una población $N(\mu_1,\sigma_1)$ e $(Y_1,\ldots,Y_n)$ una m.a.s. de una población $N(\mu_2,\sigma_2)$ y ambas muestras son independientes, la variable aleatoria

$$F_{m-1,n-1} = \frac{S_1^2\sigma_2^2}{S_2^2\sigma_1^2} \sim F_{m-1,n-1},$$

donde S_1^2 y S_2^2 son las cuasivarianzas muestrales respectivas y $\mu_1,\mu_2,\sigma_1,\sigma_2$ son desconocidas.

2.5. Estadísticos de orden

Sea $(X_1,\ldots,X_n)$ una m.a.s. de una variable aleatoria X con función de distribución F. Los **estadísticos de orden** son obtenidos al ordenar la muestra de menor a mayor, es decir

$$\begin{aligned} X_{(1)} &= \text{mín}\{X_1,\ldots,X_n\} \\ X_{(2)} &= \text{mín}\left\{\{X_1,\ldots,X_n\} - X_{(1)}\right\} \\ &\vdots \\ X_{(n)} &= \text{máx}\{X_1,\ldots,X_n\}. \end{aligned}$$

De esta forma, obtenemos la muestra ordenada $\left(X_{(1)},\ldots,X_{(n)}\right)$.

Observación (IMPORTANTE). Para $i = 1,\ldots,n$, las distribuciones de $X_{(i)}$ dependen de F, pero no son independientes y no tienen por qué estar identicamente distribuidos!

Ejemplo (Distribución del mínimo y máximo). Sea $(X_1,\ldots,X_n)$ una m.a.s. de una variable aleatoria X continua con función de distribución F y función de densidad f. Tendremos que

$$\begin{aligned} 1 - F_{X_{(1)}}(t) &= P\left(X_{(1)} > t\right) = P(X_1 > t,\ldots,X_n > t) \\ &= \prod_{i=1}^{n} P(X_i > t) = \prod_{i=1}^{n} [1 - F_{X_i}(t)] = [1 - F(t)]^n. \end{aligned}$$

De esta manera, la función de densidad de $X_{(1)}$ será

$$f_{X_{(1)}}(t) = n\left[1 - F(t)\right]^{n-1} f(t).$$

Análogamente, para $X_{(n)}$ tendremos que

$$\begin{aligned} F_{X_{(n)}}(t) =& P\left(X_{(n)} \leq t\right) = P\left(X_1 \leq t, \ldots, X_n \leq t\right) \\ =& \prod_{i=1}^{n} P\left(X_i \leq t\right) = \prod_{i=1}^{n} F_{X_i}(t) = \left[F(t)\right]^n. \end{aligned}$$

Así, tendremos que la función de densidad de $X_{(n)}$ será

$$f_{X_{(n)}}(t) = n\left[F(t)\right]^{n-1} f(t).$$

Proposición 2.10. Sea $(X_1, \ldots, X_n)$ una m.a.s. de una variable aleatoria X con función de distribución F continua y función de densidad f. Entonces

1. La función de desidad conjunta de $\left(X_{(1)}, \ldots, X_{(n)}\right)$ es

$$g(t_1, \ldots, t_n) = n! \prod_{i=1}^{n} f(t_i), \; t_1 \leq \cdots \leq t_n.$$

2. La función de distribución marginal de $X_{(r)}$ para $r = 1, \ldots, n$ es

$$F_{X_{(r)}}(t) = \sum_{i=r}^{n} \binom{n}{i} \left[F(t)\right]^i \left[1 - F(t)\right]^{n-i}.$$

3. La función de densidad marginal de $X_{(r)}$ para $r = 1, \ldots, n$ es

$$g(t) = \frac{n!}{(r-1)!\,(n-r)!} \left[F(t)\right]^{r-1} \left[1 - F(t)\right]^{n-r} f(t).$$

Demostración. Demostramos **(2)** puesto que **(3)** se deduce fácilmente de este. El suceso $\left\{X_{(r)} \leq t\right\}$ es equivalente a que al menos r valores muestrales sean menores que t. Así, se sigue fácilmente que

$$F_{X_{(r)}}(t) = \sum_{i=r}^{n} \binom{n}{i} \left[F(t)\right]^i \left[1 - F(t)\right]^{n-i}.$$

Como estamos suponiendo que X es una variable aleatoria con función de distribución continua, podemos obtener la función de densidad derivando la expresión anterior. □

Proposición 2.11. La función de densidad conjunta de $\left(X_{(r)}, X_{(s)}\right)$ para $r < s$ es

$$g(t_1, t_2) = \frac{n!}{(r-1)!\,(s-r-1)!\,(n-s)!}\left[F(t_1)\right]^{r-1} f(t_1) \cdot \left[F(t_2) - F(t_1)^{s-r-1}\right]\left[1 - F(t_2)\right]^{n-s},\ t_1 \leq t_2.$$

Corolario 2.2. La función de densidad conjunta de $\left(X_{(1)}, X_{(n)}\right)$ es

$$g(t_1, t_2) = \frac{n!}{(n-2)!} f(t_1)\left[F(t_2) - F(t_1)\right]^{n-2} f(t_2),\ t_1 \leq t_2.$$

Ejemplo (Distribución uniforme)**.** Sea $(X_1, \ldots, X_n)$ una m.a.s. (n) de una población $X \equiv U(0,1)$. Tenemos que la función de distribución de X es

$$F(x) = \begin{cases} 0, & x \leq 0 \\ x, & 0 < x \leq 1 \\ 1, & 1 \leq x \end{cases}.$$

De esta manera, tendremos que la función de distribución de $X_{(n)}$ será

$$f_{X_{(n)}}(x) = nx^{n-1},\ x \in [0,1].$$

De esta forma, tenemos que $X_{(n)} \sim Beta(n,1)$. De forma análoga, tenemos que

$$f_{X_{(1)}}(x) = n(1-x)^{n-1},\ x \in [0,1].$$

Por tanto, $X_{(1)} \sim Beta(1,n)$. En general, para $r \in \{1, \ldots, n\}$ se tiene que

$$f_{X_{(r)}}(x) = \frac{n!}{(r-1)!\,(n-r)!} x^{r-1}(1-x)^{n-r},\ x \in [0,1].$$

Por tanto, $X_{(r)} \sim Beta(r, n-r+1)$. Finalmente, es fácil ver que

$$f_{\left(X_{(1)}, X_{(n)}\right)}(x,y) = n(n-1)(y-x)^{n-2},\ 0 < x < y < 1.$$

Ejemplo (Rango muestral)**.** Calculemos la distribución del rango muestral. Se define rango muestral como $R = X_{(n)} - X_{(1)}$. Sea $H = \dfrac{X_{(n)} + X_{(1)}}{2}$. Tenemos que

$$\begin{cases} R = X_{(n)} - X_{(1)} \\ H = \frac{X_{(n)} + X_{(1)}}{2} \end{cases} \quad \begin{cases} X_{(n)} = H + \frac{R}{2} \\ X_{(1)} = H - \frac{R}{2} \end{cases} \Rightarrow J = \begin{vmatrix} 1 & -\frac{1}{2} \\ 1 & \frac{1}{2} \end{vmatrix} = 1.$$

Por otro lado, si $0 < x < y < 1$ se tiene que $\dfrac{r}{2} < h < 1 - \dfrac{r}{2}$. Así, tenemos que la función de densidad conjunta será

$$g(R,H)(r,h) = f_{\left(X_{(1)}, X_{(n)}\right)}\left(h - \frac{r}{2}, h + \frac{r}{2}\right) = 1 - n(n-1)\,r^{n-2},$$

por lo que la función de densidad marginal de R es

$$g_R(r) = n(n-1)\, r^{n-2}(1-r).$$

Por tanto, tenemos que $R \sim Beta(n-1, 2)$.

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. (n) de una población X tal que $F(x) = P(X \leq x)$. Calculemos la distribución de $U = F(X)$ y de $U_R = F\left(X_{(r)}\right)$. En primer lugar, tendremos que

$$G_U(u) = P(U \leq u) = P(F(x) \leq u) = P\left(X \leq F^{-1}(u)\right) = F\left(F^{-1}(u)\right) = u,\ 0 < u < 1.$$

Así, tendremos que $F(X) \sim U(0,1)$. Por otro lado, se tiene que

$$\begin{aligned} G_{U_R}(u) =& P(U_R \leq u) = P\left(F\left(X_{(r)}\right) \leq u\right) = P\left(X_{(r)} \leq F^{-1}(u)\right) = F_{X_{(r)}}\left(F^{-1}(u)\right) \\ =& \sum_{j=r}^{n} \binom{n}{j} F\left(F^{-1}(u)\right)^j \left(1 - F\left(F^{-1}(u)\right)\right)^{n-j} = \sum_{j=r}^{n} \binom{n}{j} u^j (1-u)^{n-j}. \end{aligned}$$

De esta forma, $U_R = F\left(X_{(r)}\right)$ es el estadístico ordenado de orden r asociado a una m.a.s. (n) de una población $U = F(x) \sim U(0,1)$.

Capítulo 3

Reducción de datos

3.1. Estadísticos suficientes y minimal suficientes

Sea $(\Omega, \mathcal{A}, P)$ el espacio de probabilidad asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X : \Omega \to \mathbb{R}$ y su modelo estadístico asociado $(\chi, \mathcal{B}, F_\theta)_{\theta \in \Theta \subset \mathbb{R}^l}$, $\mathcal{B} = \mathcal{B}(\mathbb{R})$ y $(X_1, \ldots, X_n)$ una m.a.s. (n) de X.

Definición 3.1 (Estadístico suficiente). Decimos que $T = T(X_1, \ldots, X_n) : \mathbb{R}^n \to \mathbb{R}^m$ es un **estadístico suficiente** para θ si la distribución de probabilidad de la muestra condicionada por T es independiente de θ.

Ejemplo. Supongamos que $X \sim Ber(\theta)$. En este caso, tenemos que $f_\theta(x) = \theta^x (1-\theta)^{1-x}$ para $x \in \{0, 1\}$. En nuestro caso tenemos que $\mu = \theta$ y $\sigma^2 = \theta(1-\theta)$. Veamos que $T = \sum_{i=1}^{n} X_i \sim Ber(n, \theta)$ es suficiente para θ. Tenemos que su función de densidad será

$$f_\theta(t) = \binom{n}{t} \theta^t (1-\theta)^{n-t}, \ t \in \{0, \ldots, n\}.$$

De esta forma, tendremos que si $\sum_{i=1}^{n} X_i = t$ entonces

$$\begin{aligned} P_\theta\left(X_1 = x_1, \ldots, X_n = x_n | \sum_{i=1}^{n} X_i = t\right) &= \frac{P_\theta\left(X_1 = x_1, \ldots, X_n = t - \sum_{i=1}^{n-1} x_i\right)}{P\left(\sum_{i=1}^{n} X_i = t\right)} \\ &= \frac{\theta^t (1-\theta)^{n-t}}{\binom{n}{t} \theta^t (1-\theta)^{n-t}} = \frac{1}{\binom{n}{t}}, \ t = 0, \ldots, n. \end{aligned}$$

Teorema 3.1 (Teorema de factorización de Fisher). $T = T(X_1, \ldots, X_n) : \mathbb{R}^n \to \mathbb{R}^m$ es un estadístico suficiente para θ si y solo si existen funciones reales positivas $h : \mathbb{R}^n \to \mathbb{R}$ y $g_\theta : \mathbb{R}^m \to \mathbb{R}$ tales que

$$f_\theta(x_1, \ldots, x_n) = h(x_1, \ldots, x_n)\, g_\theta(T(x_1, \ldots, x_n)),$$

donde $f_\theta(x_1, \ldots, x_n)$ es la función de masa de la muestra.

Demostración. Demostramos solo el caso discreto. En primer lugar, si $T = T(X_1, \ldots, X_n)$ es un estadístico suficiente para θ, entonces $f_\theta(x_1, \ldots, x_n|t)$ es independiente de θ. Así, tendremos que si $T(x_1, \ldots, x_n) = t$, entonces

$$f_\theta(x_1, \ldots, x_n) = f_\theta(x_1, \ldots, x_n|t)\, f_\theta(t) = h(x_1, \ldots, x_n)\, g_\theta(T(x_1, \ldots, x_n)).$$

Recíprocamente, si $T(x_1, \ldots, x_n) = t$, tendremos que

$$\begin{aligned} f_\theta(x_1, \ldots, x_n|t) &= \frac{f_\theta(x_1, \ldots, x_n)}{f_\theta(t)} = \frac{f_\theta(x_1, \ldots, x_n)}{\sum_{(y_1,\ldots,y_n), T(y_1,\ldots,y_n)=1} f_\theta(y_1, \ldots, y_n)} \\ &= \frac{h(x_1, \ldots, x_n)\, g_\theta(t)}{\sum_{(y_1,\ldots,y_n), T(y_1,\ldots,y_n)=1} h(y_1, \ldots, y_n)\, g_\theta(t)} \\ &= \frac{h(x_1, \ldots, x_n)}{\sum_{(y_1,\ldots,y_n), T(y_1,\ldots,y_n)=1} h(y_1, \ldots, y_n)}, \end{aligned}$$

que es independiente de θ. □

Ejemplo (Bernoulli). Encontremos un estadístico suficiente para θ si $X \sim Bin(1, \theta)$. Tenemos que

$$f_\theta(x_1, \ldots, x_n) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i} = g_\theta\left(\sum_{i=1}^n x_i\right) h(x_1, \ldots, x_n).$$

De esta forma, $T = \sum_{i=1}^n X_i$ es un estadístico suficiente para θ, como habíamos visto antes.

Ejemplo (Poisson). Encontramos un estadístico suficiente para θ si $X \sim Poisson(\theta)$. Tenemos que

$$f_\theta(x_1, \ldots, x_n) = \prod_{i=1}^n e^{-\theta} \frac{\theta^{x_i}}{x_i!} = e^{-n\theta} \frac{\theta^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}.$$

Podemos tomar $T = \sum_{i=1}^n X_i$ de forma que

$$g_\theta(t) = e^{-n\theta}\theta^t \quad \text{y} \quad h(x_1, \ldots, x_n) = \left(\prod_{i=1}^n x_i!\right)^{-1}.$$

Observación. La propia muestra y el estadístico ordenado $\left(X_{(1)}, \ldots, X_{(n)}\right)$ son estadísticos suficientes. La primera es trivial. Por otro lado, supongamos que dada una m.a.s. (n) de X,

donde $\tilde{f}_\theta$ es la función de densidad de X, tendremos que

$$f_\theta(x_1,\ldots,x_n) = \prod_{i=1}^{n} \tilde{f}_\theta(x_i) = \frac{1}{n!} g_\theta\left(x_{(1)},\ldots,x_{(n)}\right),$$

donde g_θ es la función de densidad del estadístico ordenado.

Proposición 3.1. Sea $(X_1,\ldots,X_n)$ una m.a.s (n) de X.

1. Si $T = T(X_1,\ldots,X_n)$ es suficiente para θ, entonces cualquier biyección $S = S(T)$ también es suficiente para θ.
2. Si $T = T(X_1,\ldots,X_n)$ y $S = S(X_1,\ldots,X_n)$ son suficientes para θ, entonces también es suficiente para θ el estadístico (T,S).

Demostración. Sea $(X_1,\ldots,X_n)$ una m.a.s (n) de X.

1. Como T es suficiente tendremos que f_θ se puede factorizar de la forma

$$f_\theta(x_1,\ldots,x_n) = h(x_1,\ldots,x_n)\, g_\theta(T(x_1,\ldots,x_n)) = h(x_1,\ldots,x_n)\, g_\theta(S).$$

   Por tanto, obtenemos también la factorización en función de S, por lo que S también es suficiente para θ.

2. Mirar la demostración en el libro.

□

Ejemplo (Normal). Sea $(X_1,\ldots,X_n)$ una m.a.s. de $X \sim N(\theta,\sigma_0)$, con σ_0 conocida. Veamos que $T = \overline{X}$ es un estadístico suficiente para θ:

$$\begin{aligned} f_\theta(x_1,\ldots,x_n) &= \prod_{i=1}^{n} \frac{1}{\sigma_0\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_i-\theta}{\sigma_0}\right)^2} = \frac{1}{\left(\sigma_0\sqrt{2\pi}\right)^n} e^{-\frac{1}{2}\sum_{i=1}^{n}\left(\frac{x_i-\theta}{\sigma_0}\right)^2} \\ &= \frac{1}{\left(\sigma_0\sqrt{2\pi}\right)^n} e^{-\frac{1}{2\sigma_0^2}\sum_{i=1}^{n} x_i^2} e^{\frac{n\theta}{\sigma_0^2}\left(\overline{x}-\frac{\theta}{2}\right)}. \end{aligned}$$

De esta manera, podemos tomar $T = \overline{X}$ y nos queda que

$$h(x_1,\ldots,x_n) = \frac{1}{\left(\sigma_0\sqrt{2\pi}\right)^n} e^{-\frac{1}{2\sigma_0^2}\sum_{i=1}^{n} x_i^2} \quad \text{y} \quad g_\theta(T(x_1,\ldots,x_n)) = e^{\frac{n\theta}{\sigma_0^2}\left(\overline{x}-\frac{\theta}{2}\right)}.$$

Ahora, veamos que $T = \sum_{i=1}^{n} (X_i-\mu_0)^2$ es suficiente para θ si $X \sim N(\mu_0,\theta)$, con μ_0 conocida. Tendremos que

$$f_\theta(x_1,\ldots,x_n) = \prod_{i=1}^{n} \frac{1}{\theta\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_i-\mu_0}{\theta}\right)^2} = \frac{1}{\left(\theta\sqrt{2\pi}\right)^n} e^{-\frac{1}{2\theta^2}\sum_{i=1}^{n}(x_i-\mu_0)^2}.$$

De esta forma, podemos tomar

$$h(x_1,\ldots,x_n) = 1 \quad \text{y} \quad g_\theta(T(x_1,\ldots,x_n)) = \frac{1}{\left(\theta\sqrt{2\pi}\right)^n} e^{-\frac{1}{2\theta^2}\sum_{i=1}^{n}(x_i-\mu_0)^2}.$$

Finalmente, veamos que $T = \left(\sum_{i=1}^{n} X_i, \sum_{i=1}^{n} X_i^2\right)$ es suficiente para $\theta(\mu, \sigma)$, con $X \sim N(\mu, \sigma)$ y μ, σ son desconocidas.

$$\begin{aligned} f_\theta(x_1, \ldots, x_n) &= \prod_{i=1}^{n} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_i-\mu}{\sigma}\right)^2} = \frac{1}{\left(\sigma\sqrt{2\pi}\right)^n} e^{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2} \\ &= \frac{1}{\left(\sigma\sqrt{2\pi}\right)^n} e^{-\frac{1}{2\sigma^2}\sum_{i=1}^{n} x_i^2} e^{\frac{\mu}{\sigma^2}\sum_{i=1}^{n} x_i} e^{-\frac{n\mu^2}{2\sigma^2}}. \end{aligned}$$

De esta forma, podemos tomar

$$h(x_1, \ldots, x_n) = 1 \quad \text{y} \quad g_\theta(T(x_1, \ldots, x_n)) = \frac{1}{\left(\sigma\sqrt{2\pi}\right)^n} e^{-\frac{1}{2\sigma^2}\sum_{i=1}^{n} x_i^2} e^{\frac{\mu}{\sigma^2}\sum_{i=1}^{n} x_i} e^{-\frac{n\mu^2}{2\sigma^2}}.$$

Podemos ver que en este caso $h : \mathbb{R}^n \to \mathbb{R}$ y como $T : \mathbb{R}^n \to \mathbb{R}^2$, tendremos que $g_\theta : \mathbb{R}^2 \to \mathbb{R}$. De esto último que hemos demostrado es fácil deducir que $T = \left(\overline{X}, S_n^2\right)$ también es suficiente.

Ejemplo (Uniforme). Si $X \sim U(0, \theta)$, entonces los estadísticos $\left(X_{(1)}, X_{(n)}\right)$ y $X_{(n)}$ son suficientes para θ. En efecto, tendremos que la función de densidad de X será $\tilde{f}_\theta = \frac{1}{\theta}$, de forma que

$$f_\theta(x_1, \ldots, x_n) = \prod_{i=1}^{n} \frac{1}{\theta} = \frac{1}{\theta^n}.$$

Por otro lado, se puede comprobar que la función de densidad de $X_{(n)}$ será

$$f_{X_{(n)}}(x) = n\frac{x^{n-1}}{\theta^n}.$$

De esta forma,

$$f_\theta(x_1, \ldots, x_n) = \frac{1}{\theta^n} = .$$

También podemos ver que el estadístico $\left(X_{(1)}, X_{(n)}\right)$ es suficiente para θ si $X \sim U\left(-\frac{\theta}{2}, \frac{\theta}{2}\right)$.

Definición 3.2 (Órbita). Dado un estadístico $T = T(X_1, \ldots, X_n)$ se define su **órbita** de $t \in \mathbb{R}^m$ como [a]

$$A_t = \{(x_1, \ldots, x_n) \in \chi^n \ : \ T(x_1, \ldots, x_n) = t\}.$$

[a] Recordamos que χ^n es el espacio muestral.

Observación. Es fácil ver que $K_T = \{A_t \ : \ t \in \mathbb{R}^m\}$ es una partición disjunta de χ^n y la denominamos **partición inducida por el estadístico** T.

Notación. Decimos que K_T es **suficiente** si y solo si T es suficiente.

Definición 3.3 (Subpartición). Dados dos estadísticos $T = T(X_1, \ldots, X_n)$ y $S = S(X_1, \ldots, X_n)$, dedimos que K_S es una **subpartición** de K_T si $\forall B \in K_S$, $\exists A \in K_T$ tal que $B \subset A$. En este caso, se dice que K_T es **menos fina** que K_S.

Definición 3.4 (Estadístico minimal suficiente)**.** Decimos que un estadístico T es **minimal suficiente** si su partición asociada es suficiente y es la menos fina entre todos los estadísticos suficientes.

Proposición 3.2. Ambos enunciados son equivalentes:

1. El estadístico T es minimal suficiente.
2. El estadísitco T es suficiente y $\forall S = S(X_1, \ldots, X_n)$ suficiente, $\exists \varphi$ tal que $\varphi(S) = T$.

Demostración. Demostramos (1)$\Rightarrow$(2). Sea S suficiente. Si $S(x_1, \ldots, x_n) = S(y_1, \ldots, y_n) = s$, entonces tendremos que $(x_1, \ldots, x_n), (y_1, \ldots, y_n) \in B_s$. De esta forma, existe $A_t \in K_T$ tal que $B_s \subset A_t$, por lo que $T(x_1, \ldots, x_n) = T(y_1, \ldots, y_n) = t$. Así, existe φ tal que $\varphi(S) = T$ y T es suficiente.
Ahora demostramos (2)$\Rightarrow$(1), sea S suficiente y $\varphi(S)$ tal que $\varphi(S) = T$. Tendremos que T es suficiente y si $S(x_1, \ldots, x_n) = S(y_1, \ldots, y_n) = s$, entonces

$$T(x_1, \ldots, x_n) = \varphi(S(x_1, \ldots, x_n)) = \varphi(s) = \varphi(S(y_1, \ldots, y_n)) = T(y_1, \ldots, y_n).$$

De esta forma, como $B_s \subset A_{\varphi(s)}$ tendremos que K_S es una subpartición de K_T. $\square$

Consideremos la siguiente relación de equivalencia

$$(x_1, \ldots, x_n) \sim (y_1, \ldots, y_n) \iff \frac{f_\theta(x_1, \ldots, x_n)}{f_\theta(y_1, \ldots, y_n)} \text{ es independiente de } \theta.$$

Teorema 3.2 (Teorema de caracterización de estadísticos suficientes)**.** La relación de equivalencia $\sim$ induce una partición minimal suficiente y por tanto determina un estadístico minimal suficiente.

Demostración. Asignemos a cada clase del conjunto cociente un valor t y definamos el estadístico $T = T(X_1, \ldots, X_1)$ tal que $(x_1, \ldots, x_n) \sim (y_1, \ldots, x_n)$ cuando $T(x_1, \ldots, x_n) = T(y_1, \ldots, y_n) = t$. Demostremos que T es suficiente [a]. Si $T(x_1, \ldots, x_n) = t$, tendremos que

$$\begin{aligned} f_\theta(x_1, \ldots, x_n | t) &= \frac{f_\theta(x_1, \ldots, x_n)}{f_\theta(t)} = \frac{f_\theta(x_1, \ldots, x_n)}{\sum_{(y_1, \ldots, y_n), T(y_1, \ldots, y_n)=1} f_\theta(y_1, \ldots, y_n)} \\ &= \frac{1}{\sum_{(y_1, \ldots, y_n) \in A_t} \frac{f_\theta(y_1, \ldots, y_n)}{f_\theta(x_1, \ldots, x_n)}}. \end{aligned}$$

Como este valor es independiente de θ, tenemos que T es suficiente para θ. Ahora demostramos que T es minimal. Sea $S = S(X_1, \ldots, X_n)$ suficiente y $(x_1, \ldots, x_n), (y_1, \ldots, y_n) \in B_s$. Entonces,

$$\frac{f_\theta(x_1, \ldots, x_n)}{f_\theta(y_1, \ldots, y_n)} = \frac{h(x_1, \ldots, x_n) g_\theta(s)}{h(y_1, \ldots, y_n) g_\theta(s)} = \frac{h(x_1, \ldots, x_n)}{h(y_1, \ldots, y_n)}.$$

Como este valor no depende de θ, existe t tal que $(x_1, \ldots, x_n), (y_1, \ldots, y_n) \in A_t$, por lo que K_S es una subpartición de K_T. □

[a] Lo hacemos solo en el caso discreto.

Observación. Podemos enunciar este teorema de una forma más entendible: un estadístico T es minimal suficiente si y solo si

$$\frac{f_\theta(x_1, \ldots, x_n)}{f_\theta(y_1, \ldots, y_n)} \text{ no depende de } \theta \iff T(x_1, \ldots, x_n) = T(y_1, \ldots, y_n).$$

Ejemplo. Veamos que $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i$ es minimal suficiente para θ si $X \sim Bin(1, \theta)$.

En efecto, tenemos que

$$f_\theta(x_1, \ldots, x_n) = \prod_{i=1}^{n} \theta^{x_i} (1-\theta)^{1-x_i} = \theta^{\sum_{i=1}^{n} x_i} (1-\theta)^{n-\sum_{i=1}^{n} x_i}.$$

Tenemos que

$$\frac{f_\theta(x_1, \ldots, x_n)}{f_\theta(y_1, \ldots, y_n)} = \left(\frac{\theta}{1-\theta}\right)^{\sum_{i=1}^{n} x_i - \sum_{i=1}^{n} y_i}$$

es independiente de θ sólamente cuando $\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} y_i$.

3.2. Familia exponencial k-paramétrica

Sea $(\Omega, \mathcal{A}, P)$ es espacio probabilístico asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X : \Omega \to \mathbb{R}$ y su modelo estadístico asociado $(\chi, \mathcal{B}, F_\theta)_{\theta \in \Theta \subset \mathbb{R}^l}$, $\mathcal{B} = \mathcal{B}(\mathbb{R})$ y $(X_1, \ldots, X_n)$ una m.a.s. (n) de X.

Definición 3.5 (Familia exponencial k-paramétrica)**.** La distribución de X pertenece a la **familia exponencial k-paramétrica** si

$$f_\theta(x) = c(\theta)\, h(x)\, e^{\sum_{j=1}^{k} q_j(\theta) T_j(x)}.$$

Observación. Si X pertenece a la familia exponencial k-paramétrica, tendremos que

$$f_\theta(x_1, \ldots, x_n) = c(\theta)^n \prod_{i=1}^{n} h(x_i)\, e^{\sum_{j=1}^{k} q_j(\theta) \sum_{i=1}^{n} T_j(x_i)}.$$

Por el teorema de factorización, $\left(\sum_{i=1}^{n} T_1(X_i), \ldots, \sum_{i=1}^{n} T_k(X_i)\right)$ es suficiente para θ y se le denomina el **estadístico natural suficiente**.

Teorema 3.3. Si existen $\theta_1, \ldots, \theta_k \in \Theta \subset \mathbb{R}^l$ tales que los vectores $c_r = (q_1(\theta_r), \ldots, q_k(\theta_r))$, $r = 1, \ldots, k$, son linealmente independientes. Entonces, el estadístico natural suficiente de la familia exponencial k-paramétrica es minimal.

Demostración. Tenemos que

$$\begin{aligned}\frac{f_\theta(x_1,\ldots,x_n)}{f_\theta(y_1,\ldots,y_n)} &= \frac{c(\theta)^n \prod_{i=1}^n h(x_i)\, e^{\sum_{j=1}^k q_j(\theta)\sum_{i=1}^n T_j(x_i)}}{c(\theta)^n \prod_{i=1}^n h(y_i)\, e^{\sum_{j=1}^k q_j(\theta)\sum_{i=1}^n T_j(y_i)}} \\ &= \frac{\prod_{i=1}^n h(x_i)}{\prod_{i=1}^n h(y_i)} e^{\sum_{j=1}^k q_j(\theta)\left(\sum_{i=1}^n T_j(x_i)-\sum_{i=1}^n T_j(y_j)\right)}.\end{aligned}$$

Este valor es independiente de θ si y solo si

$$\sum_{j=1}^k q_j(\theta)\left(\sum_{i=1}^n T_j(x_i) - \sum_{i=1}^n T_j(y_j)\right) = 0.$$

En este caso, el sistema homogéneo

$$\sum_{j=1}^k q_j(\theta_r)\left(\sum_{i=1}^n T_j(x_i) - \sum_{i=1}^n T_j(y_i)\right) = 0,\ r = 1,\ldots,k$$

solo ademite la solución $\sum_{i=1}^n T_j(x_i) - \sum_{i=1}^n T_j(y_i) = 0$. Por el teorema de caracterización de estadísticos minimales suficientes, $\left(\sum_{i=1}^n T_1(X_i),\ldots,\sum_{i=1}^n T_k(X_i)\right)$ es minimal. □

Ejemplo. Antes vimos que $T = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2\right)$ era suficiente para $\theta = (\mu,\sigma)$ si $X \sim N(\mu,\sigma)$. Veamos ahora que es minimal y que $\left(\overline{X}, S_n^2\right)$ también es minimal suficiente. Tenemos que $N(\mu,\sigma)$ pertenece a la familia exponencial k-paramétrica con $k = 2$. En efecto, tenemos que

$$f_\theta(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} = c(\theta)\, h(x)\, e^{-\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x}.$$

De esta forma, el estadístico $T = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2\right)$ es natural suficiente para θ. Además, tenemos que $q_1(\theta) = \dfrac{\mu}{\sigma^2}$ y $q_2(\theta) = -\dfrac{1}{2\sigma^2}$. Tomando $\theta_1 = (0,1)$ y $\theta_2 = (1,1)$, tendremos que

$$c_1 = (q_1(\theta_1), q_2(\theta_1)) = \left(0, -\frac{1}{2}\right) \quad \text{y} \quad c_2 = (q_1(\theta_2), q_2(\theta_2)) = \left(1, -\frac{1}{2}\right).$$

Como c_1 y c_2 son linealmente independientes, tenemos que T es minimal.
Veamos ahora que $\left(\overline{X}, S_n^2\right)$ también es minimal suficiente. Tenemos que

$$S_n^2 = \frac{n}{n-1}\left(\sum_{i=1}^n X_i^2 - n\overline{X}_i^2\right).$$

Denotamos por $(W,Z)=\left(\sum_{i=1}^{n}X_i,\sum_{i=1}^{n}X_i^2\right)$ y

$$(F,G)=\left(\overline{X},S_n^2\right)=\left(\frac{W}{n},\frac{n}{n-1}\left(Z-\frac{W^2}{n}\right)\right).$$

La transformación inversa es $\left(W=nF,Z=\frac{n-1}{n}G+nF^2\right)$, por lo que

$$J=\begin{vmatrix} n & 0 \\ 2nF & \frac{n-1}{n}\end{vmatrix}=n-1\neq 0,\ n\geq 2.$$

De esta forma, existe ψ_1 biyectiva tal que $(F,G)=\psi_1(W,Z)$ y como (W,Z) es minimal suficiente, $\forall S$ suficiente existe ψ_2 tal que $\psi_2(S)=(W,Z)$. Por tanto,

$$\psi_1\circ\psi_2(S)=\psi_1(W,Z)=(F,G)$$

y (F,G) es minimal suficiente.

3.3. Estadísticos ancilario y completos

Sea $(\Omega,\mathcal{A},P)$ es espacio probabilístico asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X:\Omega\to\mathbb{R}$ y su modelo estadístico asociado $(\chi,\mathcal{B},F_\theta)_{\theta\in\Theta\subset\mathbb{R}^l}$, $\mathcal{B}=\mathcal{B}(\mathbb{R})$, y $(X_1,\ldots,X_n)$ una m.a.s. (n) de X.

Definición 3.6 (Estadístico ancilario). Un estadístico $U=U(X_1,\ldots,X_n)$ es **ancilario** para θ si su distribución en el muestreo es independiente de θ.

Ejemplo. Si $(X_1,\ldots,X_n)$ es una m.a.s. (n) de $X\sim N(\mu,\sigma_0)$, con σ_0 conocida, entonces $U(X_1,\ldots,X_n)=X_1-X_2\sim N\left(0,\sigma_0\sqrt{2}\right)$, que no depende de μ, por lo que U es un estadístico ancilario para μ.

Definición 3.7 (Familia de distribuciones completa). La familia de distribuciones de probabilidad $\{G_\theta(y_1,\ldots,y_m)\}_{\theta\in\Theta\subset\mathbb{R}^l}$ es **completa** si para cualquier función real $h(y_1,\ldots,y_m)$ con $h(Y_1,\ldots,Y_m)$ medible y tal que $E_\theta[h(Y_1,\ldots,Y_m)]=0$, $\forall\theta\in\Theta$, se tiene que $h(Y_1,\ldots,Y_m)=^{cs}0$ [a].

[a] Esto quiere decir que $h(y_1,\ldots,y_m)=0$ salvo en un conjunto de probabilidad cero, calculada a partir de $G_\theta(y_1,\ldots,y_m)$, $\forall\theta\in\Theta$.

Ejemplo. La familia de distribuciones de probabilidad $Bin(n,\theta)$ es completa. En efecto, sea $Y\sim Bin(n,\theta)$ y $h(Y)$ una función real como se describe en la definición. Entonces,

$$E_\theta[h(Y)]=\sum_{i=1}^{n}h(i)\binom{n}{i}\theta^i(1-\theta)^{n-i}=(1-\theta)^n\sum_{i=1}^{n}h(i)\binom{n}{i}\left(\frac{\theta}{1-\theta}\right)^i=0,\ \forall\theta\in(0,1).$$

Esto es un polinomio de grado n en $\frac{\theta}{1-\theta}\in(0,\infty)$, por lo que para que sea nulo debe ser que $h(i)=0$, $\forall i=1,\ldots,n$. De esta forma, $h(Y)=^{cs}0$.

Ejemplo. La familia de distribuciones de probabilidad $N(0,\theta)$ no es completa. En efecto, sea $Y \sim N(0,\theta)$ y $h(Y) = Y$. Entonces,

$$E_\theta[h(Y)] = E_\theta[Y] = 0, \ \forall \theta > 0.$$

Sin embargo, $h(Y) = Y$ no es idénticamente nula casi seguro.

Definición 3.8 (Estadístico completo). Decimos que el estadístico $T = T(X_1, \ldots, X_n)$ es **completo** si su distribución en el muestreo es una familia de distribuciones de probabilidad completa.

Ejemplo. Si $X \sim Bin(1,\theta)$, entonces $T = \sum_{i=1}^{n} X_i \sim Bin(n,\theta)$ es completo, por lo que hemos visto anteriormente.

Ejemplo. Si $X \sim N(\theta,\theta)$, el estadístico $T = \left(\sum_{i=1}^{n} X_i, \sum_{i=1}^{n} X_i^2\right)$ no es completo. En efecto, podemos ver que

$$h(T) = 2\left(\sum_{i=1}^{n} X_i\right)^2 - (n+1)\sum_{i=1}^{n} X_i^2,$$

cumple que

$$E_\theta[h(T)] = 2E_\theta\left[\left(\sum_{i=1}^{n} X_i\right)^2\right] - (n+1)\,E_\theta\left[\sum_{i=1}^{n} X_i^2\right] = 2n\theta^2(1+n) - (n+1)\,2n\theta^2 = 0, \ \forall \theta \in \Theta.$$

Hemos usado que $E_\theta\left[\left(\sum_{i=1}^{n} X_i\right)^2\right] = n\theta^2(1+n)$, puesto que

$$\frac{\left(\sum_{i=1}^{n} X_i - n\theta\right)^2}{n\theta^2} \sim \chi_1^2.$$

También hemos usado que $E_\theta\left[\sum_{i=1}^{n} X_i^2\right] = 2n\theta^2$, puesto que

$$\sum_{i=1}^{n} \frac{(X_i - \theta)^2}{\theta^2} \sim \chi_n^2.$$

De esta forma, tenemos que $E_\theta[h(T)] = 0$, $\forall \theta \in \Theta$, pero no se cumple que $h(T) = 0$ casi seguro.

Proposición 3.3. Si $S = S(X_1, \ldots, X_n)$ es suficiente y completo, entonces es minimal suficiente.

Demostración. Supongamos que $T = T(X_1, \ldots, X_n)$ se minimal suficiente, entonces tendremos que por ser S completo, $S =^{cs} E[S|T]$, por lo que S es función de T. □

Teorema 3.4 (Existencia de estadísticos completos). El estadístico natural

$$\left(\sum_{i=1}^{n} T_1(X_i), \ldots, \sum_{i=1}^{n} T_k(X_i)\right)$$

de la familia de distribuciones exponencial k-paramétrica,

$$\left\{f_\theta(x) = c(\theta)\, h(x)\, e^{\sum_{j=1}^{k} q_j(\theta) T_j(x)}\right\}_{\theta \in \Theta \subset \mathbb{R}^l},$$

es completo si la imagen de la aplicación $q = (q_1(\theta), \ldots, q_k(\theta)) : \Theta \to \mathbb{R}^k$ contiene un rectángulo abierto de $\mathbb{R}^k$.

Ejemplo. Si $X \sim N(\theta, \theta)$, tenemos que $q = (q_1(\theta), q_2(\theta)) = \left(\frac{1}{\theta}, -\frac{1}{2\theta^2}\right)$. Entonces,

$$q_2(\theta) = -\frac{1}{2} q_1(\theta)^2, \ \forall \theta > 0.$$

Al tratarse de una rama de una parábola, tenemos que no contiene ningún abierto de $\mathbb{R}^2$.

Teorema 3.5 (Teorema de Basu). Si $T = T(X_1, \ldots, X_n)$ es un estadístico suficiente y completo, y $U = U(X_1, \ldots, X_n)$ es un estadístico ancilario, entonces T y U son independientes.

Demostración. Como $T = T(X_1, \ldots, X_n)$ es suficiente, tenemos que $f(x_1, \ldots, x_n|t)$ es independiente de θ. Así, tenemos que

$$f(u|t) = \sum_{(x_1,\ldots,x_n):U(x_1,\ldots,x_n)=u} f(x_1, \ldots, x_n|t)$$

es independiente de θ. Además, como $T = T(X_1, \ldots, X_n)$ es completo y la función $h(t) = f(u|t) - f(u)$ tiene media 0, $\forall \theta \in \Theta$, tendremos que respecto a la distribución de $T \sim f_\theta(t)$, $f(u|t) =^{cs} f(u)$. □

Ejemplo. Si $X \sim U(0, \theta)$, entonces $X_{(n)}$ y $\frac{X_{(1)}}{X_{(n)}}$ son independientes.

3.4. Principio de reducción de datos

Sea $(\Omega, \mathcal{A}, P)$ es espacio probabilístico asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X : \Omega \to \mathbb{R}$ y su modelo estadístico asociado $(\chi, \mathcal{B}, F_\theta)_{\theta \in \Theta \subset \mathbb{R}^l}$, $\mathcal{B} = \mathcal{B}(\mathbb{R})$, y $(X_1, \ldots, X_n)$ una m.a.s. (n).

Capítulo 4

Estimación puntual paramétrica

4.1. Propiedades de los estimadores

Sea $(\Omega, \mathcal{A}, P)$ el espacio probabilístico asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X : \Omega \to \mathbb{R}$ y su modelo estadístico asociado $(\chi, \mathcal{B}, F_\theta)_{\theta \in \Theta \subset \mathbb{R}^l}$, $\mathcal{B} = \mathcal{B}(\mathbb{R})$ y $(X_1, \ldots, X_n)$ una m.a.s. (n) de X.

Definición 4.1 (Estimador). Un **estimador** del parámetro θ es un estadístico $T = T(X_1, \ldots, X_n) : \chi^n \to \Theta$ que se utiliza para determinar el valor desconocido θ.

Definición 4.2 (Sesgo). En general, se llama **sesgo** de un estimador a la diferencia $b(T, \theta) = E_\theta[T] - \theta$.

Definición 4.3 (Estimador centrado). Decimos que un estadístico $T = T(X_1, \ldots, X_n) : \chi^n \to \Theta$ es un **estimador centrado** para θ cuando $E_\theta[T] = \theta$.

Observación. En el caso de los estimadore scentrados tendremos que el sesgo es $b(T, \theta) = 0$.

Ejemplo. Es fácil comprobar que $\left(\overline{X}, S^2\right)$ es un estimador centrado de $\theta = \left(\mu, \sigma^2\right)$.

Ejemplo. Es fácil ver que $\sigma_n^2 = b_2 = \dfrac{1}{n} \displaystyle\sum_{i=1}^{n} \left(X_i - \overline{X}\right)^2$ es un estimador centrado de $h(\theta) = \dfrac{n-1}{n}\sigma^2$ y $b\left(\sigma_n^2, \sigma^2\right) = -\dfrac{\sigma^2}{n}$.

Observación. Podemos hacer un par de observaciones.

1. Puede que no exista un estimador centrado de θ.
2. Si T es un estimador centraod para θ, en general $h(T)$, con h medible, no tiene por qué ser centrado para $h(\theta)$.
3. A pesar de que exista un estimador centrado para θ, puede ser que no tenga sentido.
4. A pesar de que exista un estimador centrado para θ, puede que su varianza sea muy grande y no sea adecuado para la estimación.

Apéndice A

Convergencia de variables aleatorias

A.1. Convergencia en probabilidad

Definición A.1 (Convergencia en probabilidad). Dada una sucesión de variables aleatorias $\{X_n\}_{n\in\mathbb{N}}$ definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$, diremos que $\{X_n\}_{n\in\mathbb{N}}$ **converge en probabilidad** hacia la variable aleatoria X, definida en el mismo espacio de probabilidad, si

$$\forall \varepsilon > 0, \ \lim_{n\to\infty} P\left(\omega \in \Omega \ : \ |X_n(\omega) - X(\omega)| > \varepsilon\right) = 0.$$

Observación. Una definición equivalente es

$$\forall \varepsilon > 0, \ \lim_{n\to\infty} P\left(\omega \in \Omega \ : \ |X_n(\omega) - X(\omega)| \leq \varepsilon\right) = 1.$$

Notación. Si una sucesión $\{X_n\}_{n\in\mathbb{N}}$ converge en probabilidad a X lo escribiremos

$$X_n \xrightarrow{P} X.$$

Proposición A.1 (Propiedades). Si $X_n \xrightarrow{P} X$,

- $X_n - X \xrightarrow{P} 0$.
- Si $c \in \mathbb{R}/\{0\}$, $cX_n \xrightarrow{P} cX$.
- Si Y es una variable aleatoria, $X_n Y \xrightarrow{P} XY$.
- Si $g : \mathbb{R} \to \mathbb{R}$ es continua, $g(X_n) \xrightarrow{P} g(X)$.
- Si $k \in \mathbb{R}^+$, $X_n^k \xrightarrow{P} X^k$.

Si $X_n \xrightarrow{P} X$ y $Y_n \xrightarrow{P} Y$,

- $X_n \pm Y_n \xrightarrow{P} X \pm Y$.
- $X_n Y_n \xrightarrow{P} XY$.
- Si $g : \mathbb{R}^2 \to \mathbb{R}$ es real y continua, $g(X_n, Y_n) \xrightarrow{P} g(X, Y)$.
- Si $k, h \in \mathbb{R}^+$, $X_n^k Y_n^h \xrightarrow{P} X^k Y^h$.

Si $X_n \xrightarrow{P} X$ y $X_n \xrightarrow{P} Y$, se tiene que $P(X = Y) = 1$.
Si $X_n \xrightarrow{P} a$ e $Y_n \xrightarrow{P} b$ con $a, b \in \mathbb{R}$,

- $X_n Y_n \xrightarrow{P} ab$.
- $\dfrac{X_n}{Y_n} \xrightarrow{P} \dfrac{a}{b}$, si $b \neq 0$.

A.2. Convergencia casi segura

Definición A.2 (Convergencia casi segura). Sea $\{X_n\}_{n\in\mathbb{N}}$ una sucesión de variables aleatorias, definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$. Diremos que $\{X_n\}_{n\in\mathbb{N}}$ **converge casi seguro** a la variable aleatoria X, definida en el mismo espacio de probabilidad, si

$$P\left(\omega \in \Omega \ : \ \lim_{n\to\infty} X_n(\omega) = X(\omega)\right) = 1.$$

Notación. Si la sucesión $\{X_n\}_{n\in\mathbb{N}}$ converge casi seguro a X, escribimos

$$X_n \xrightarrow{cs} X.$$

Proposición A.2 (Propiedades). Si $X_n \xrightarrow{cs} X$,

- $X_n - X \xrightarrow{cs} 0$.
- Si $c \in \mathbb{R}/\{0\}$, $cX_n \xrightarrow{cs} cX$.
- Si $g : \mathbb{R} \to \mathbb{R}$ es continua, $g(X_n) \xrightarrow{cs} g(X)$.
- Si $k \in \mathbb{R}^+$, $X_n^k \xrightarrow{cs} X^k$.

Si $X_n \xrightarrow{cs} X$ e $Y_n \xrightarrow{cs} Y$,

- $X_n \pm Y_n \xrightarrow{cs} X \pm Y$.
- $X_n Y_n \xrightarrow{cs} XY$.
- Si $g : \mathbb{R}^2 \to \mathbb{R}$ es continua, $g(X_n, Y_n) \xrightarrow{cs} XY$.
- Si $k, h \in \mathbb{R}^+$, $X_n^k Y_n^h \xrightarrow{cs} X^k Y^h$.
- $\dfrac{X_n}{Y_n} \xrightarrow{cs} \dfrac{X}{Y}$, siempre que los cocientes estén bien definidos.

Teorema A.1. Sea $\{X_n\}_{n\in\mathbb{N}}$ una sucesión estríctamente creciente de variables aleatorias positivas y supongamos que $X_n \xrightarrow{P} 0$, entonces $X_n \xrightarrow{cs} 0$.

Teorema A.2. Si $X_n \xrightarrow{cs} X$, entonces $X_n \xrightarrow{P} X$.

Teorema A.3. Si $\{X_n\}_{n\in\mathbb{N}} \xrightarrow{P} X$, existe $\{X_{n_j}\}_{j\in\mathbb{N}}$ subsucesión tal que $X_{n_j} \xrightarrow{cs} X$.

A.3. Convergencia en ley

Definición A.3 (Convergencia en ley). Dada una sucesión de variables aleatorias $\{X_n\}_{n\in\mathbb{N}}$, definidas sobre el mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$, diremos que $\{X_n\}_{n\in\mathbb{N}}$ **converge en ley** a la variable aleatoria X, definida sobre el mismo espacio de probabilidad, si la correspondiente sucesión de funciones de distribución de las X_n, $\{F_n\}_{n\in\mathbb{N}}$ converge puntualmente hacia la función de distribución F de X en todo punto de continuidad de la función. Es decir,

$$\lim_{n\to\infty} F_n(x) = F(x),$$

para todos los puntos de continuidad de F.

Observación. La convergencia puntual de F_n a F no es suficiente para garantizar la convergencia, es necesario ver que la función límite sea función de distribución.

Notación. Si la sucesión $\{X_n\}_{n\in\mathbb{N}}$ converge en ley a X, lo escribimos

$$X_n \xrightarrow{d} X \quad \text{o} \quad X_n \xrightarrow{\mathcal{L}} X.$$

Proposición A.3 (Propiedades)**.** Si $X_n \xrightarrow{\mathcal{L}} X$,

- $X_n - X \xrightarrow{\mathcal{L}} 0$.
- Si $c \in \mathbb{R}/\{0\}$, $cX_n \xrightarrow{\mathcal{L}} cX$.
- Si $c \in \mathbb{R}$, $X_n + c \xrightarrow{\mathcal{L}} X + c$.
- Si $g : \mathbb{R} \to \mathbb{R}$ es continua, $g(X_n) \xrightarrow{\mathcal{L}} g(X)$.

Si $X_n \xrightarrow{\mathcal{L}} X$ e $Y_n \xrightarrow{P} c$, con $c \in \mathbb{R}$,

- $X_n \pm Y_n \xrightarrow{\mathcal{L}} X \pm c$.
- Si $c \neq 0$, $X_nY_n \xrightarrow{\mathcal{L}} cX$.
- Si $c = 0$, $X_nY_n \xrightarrow{P} 0$.
- Si $c \neq 0$, $\dfrac{X_n}{Y_n} \xrightarrow{\mathcal{L}} \dfrac{X}{c}$.

Teorema A.4. Si $X_n \xrightarrow{P} X$, entonces $X_n \xrightarrow{\mathcal{L}} X$.

Teorema A.5. Si $k \in \mathbb{R}$ y $X_n \xrightarrow{\mathcal{L}} k$, entonces $X_n \xrightarrow{P} X$.

Observación (Convergencia de las funciones características)**.** Sabemos que las funciones características proporcionan otro medio para determinar la distribución de una variable aleatoria. También se cumple que

$$X_n \xrightarrow{\mathcal{L}} X \Rightarrow \lim_{n\to\infty} \varphi_n(t) = \varphi(t), \ \forall t \in \mathbb{R}.$$

Recíprocamente, si $\lim\limits_{n\to\infty} \varphi_n(t) = \varphi(t)$, $\forall t \in \mathbb{R}$ y $\varphi(t)$ es continua en el 0, entonces $X_n \xrightarrow{\mathcal{L}} X$ y $\varphi(t)$ es la función característica de X.

A.4. Convergencia en media de orden r

Definición A.4 (Convergencia en media de orden r). Sea $\{X_n\}_{n\in\mathbb{N}}$ una sucesión de variables aleatorias, diremos que **converge en media de orden** r a la variable aleatoria X si

$$\lim_{n\to\infty} E\left(|X_n - X|^r\right) = 0,$$

siendo $E\left(|X_n|^r\right)$ y $E\left(|X|^r\right)$ finitas.

Notación. Denotaremos la convergencia en orden r como

$$X_n \xrightarrow{mr} X.$$

Cuando $r = 2$, hablamos de **convergencia en media cuadrática** y escribimos

$$X_n \xrightarrow{mc} X.$$

Observación. Si existe el momento de orden r, sabemos que existen todos los momentos de orden inferior. De esta forma, si $s \leq r$,

$$X_n \xrightarrow{mr} X \Rightarrow X_n \xrightarrow{ms} X.$$

Proposición A.4 (Propiedades). Algunas propiedades son:

- Si $X_n \xrightarrow{mc} X$, entonces $E\left(X_n\right) \xrightarrow{mc} E\left(X\right)$ y $E\left(X_n^2\right) \xrightarrow{mc} E\left(X^2\right)$. De ambas se deduce que $V\left(X_n\right) \xrightarrow{mc} V\left(X\right)$.
- La sucesión $\{X_n\}_{n\in\mathbb{N}}$ converge en media cuadrática a una constante c si y solo si se verifica que $\lim\limits_{n\to\infty} E\left(X_n\right) = c$ y $\lim\limits_{n\to\infty} V\left(X_n\right) = 0$.
- Si $X_n \xrightarrow{mc} X$ e $Y_n \xrightarrow{mc} Y$,
  - $E\left(X_n Y_n\right) \xrightarrow{mc} E\left(XY\right)$.
  - De esta propiedad y la primera se tiene que $\mathrm{Cov}\left(X_n, Y_n\right) \xrightarrow{mc} \mathrm{Cov}\left(X, Y\right)$.

Teorema A.6. Si $X_n \xrightarrow{mc} X$, entonces $X_n \xrightarrow{P} X$.

A.5. Leyes de los grandes números

A.5.1. Ley débil de los grándes números

Teorema A.7 (Ley débil de los grandes números). Sea $\{X_n\}_{n\in\mathbb{N}}$ una sucesión de variables aleatorias, definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$. Diremos que obedece la ley débil de los grandes números si existen dos sucesiones $\{A_n\}_{n\in\mathbb{N}}, \{B_n\}_{n\in\mathbb{N}} \subset \mathbb{R}$ con $B_n > 0$ y $B_n \to \infty$ creciente, tales que

$$\frac{S_n - A_n}{B_n} \xrightarrow{P} 0, \ n \to \infty,$$

donde $S_n = \sum_{i=1}^{n} X_i$.

Teorema A.8 (Teorema de Chebychev). Sea $\{X_n\}_{n\in\mathbb{N}}$ una sucesión de variables aleatorias independientes con $E(X_n) < \infty$, $\forall n \in \mathbb{N}$. Supongamos que existe $\gamma > 0$ tal que $V(X_n) \leq \gamma$, $\forall n \in \mathbb{N}$. Entonces,

$$\frac{S_n - E(S_n)}{n} \xrightarrow{P} 0.$$

Teorema A.9 (Teorema de Markov). Sea $\{X_n\}_{n\in\mathbb{N}}$ una sucesión de variables aleatorias con $\lim_{n\to\infty} V(\overline{X}_n) = 0$, donde $\overline{X}_n = \frac{S_n}{n}$. Entonces,

$$\frac{S_n - E(S_n)}{n} \xrightarrow{P} 0.$$

Teorema A.10 (Teorema de Khintchine). Si $\{X_n\}_{n\in\mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas de media finita μ, entonces

$$\frac{S_n}{n} \xrightarrow{P} \mu.$$

Teorema A.11 (Teorema de Bernoulli). Si $\{X_n\}_{n\in\mathbb{N}}$ es una sucesión de variables aleatorias independientes tales que $X_n \equiv B(1, p)$, $\forall n \in \mathbb{N}$, entonces

$$\frac{S_n}{n} \xrightarrow{P} p.$$

A.5.2. Ley fuerte de los grandes números

Teorema A.12 (Ley fuerte de los grandes números). Sea $\{X_n\}_{n\in\mathbb{N}}$ una sucesión de variables aleatorias definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$. Diremos que obedece la ley fuerte de los grandes números si existen $\{A_n\}_{n\in\mathbb{N}}, \{B_n\}_{n\in\mathbb{N}} \subset \mathbb{R}$ con $B_n > 0$ y $B_n \to \infty$ creciente tales que

$$\frac{S_n - A_n}{B_n} \xrightarrow{cs} 0.$$

Teorema A.13 (Teorema de Kolmogorov). Si $\{X_n\}_{n\in\mathbb{N}}$ es una sucesión de variables aleatorias independientes con $E(X_n) = 0$ y $V(X_n) = \sigma_n^2$, $\forall n \in \mathbb{N}$, tales que

$$\sum_{i=1}^{\infty} \frac{\sigma_i^2}{i^2} < \infty,$$

entonces

$$\frac{S_n}{n} \xrightarrow{cs} 0.$$

Teorema A.14 (Teorema de Khintchine). Si $\{X_n\}_{n\in\mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas de media finita μ, entonces

$$\frac{S_n}{n} \xrightarrow{cs} \mu.$$

A.6. Teorema central del límite

Teorema A.15 (Teorema central del límite). Sea $\{X_n\}_{n\in\mathbb{N}}$ una sucesión de variables aleatorias definidas sobre un mismo espaico de probabilidad $(\Omega, \mathcal{A}, P)$, con media y varianzas finitas. Diremos que obedece el teorema central del límite si

$$Z_n = \frac{S_n - E(S_n)}{\sqrt{V(S_n)}} \xrightarrow{\mathcal{L}} N(0,1).$$

Teorema A.16 (Teorema de Moivre). Si $\{X_n\}_{n\in\mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas con distribución de Bernoulli de parámetro p, entonces

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{\mathcal{L}} N(0,1).$$

Teorema A.17 (Teorema de Lévy-Lindeberg)**.** Si $\{X_n\}_{n\in\mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas con media μ y varianza σ^2 finitas, entonces

$$\frac{S_n - nm}{\sigma\sqrt{n}} \xrightarrow{\mathcal{L}} N(0,1).$$