

Estadística

Victoria Torroja Rubio

19/1/2026

Índice general

1. Estadística descriptiva	3
1.1. Tema 3	7
2. Muestreo	8
2.1. Modelos estadísticos	8
2.2. Estadísticos muestrales	9
2.3. Propiedades asintóticas de los momentos muestrales	11
2.4. Distribuciones asociadas a la normal	13
2.5. Estadísticos de orden	20
3. Reducción de datos	24
3.1. Estadísticos suficientes y minimal suficientes	24
3.2. Familia exponencial k -paramétrica	29
3.3. Estadísticos ancilario y completos	31
3.4. Principio de reducción de datos	33
4. Estimación puntual paramétrica	36
4.1. Propiedades de los estimadores	36
4.1.1. Estimadores centrados	36
4.1.2. Estimadores consistentes	37
4.1.3. Estimadores bayesianos	38
A. Convergencia de variables aleatorias	40
A.1. Convergencia en probabilidad	40
A.2. Convergencia casi segura	41
A.3. Convergencia en ley	42
A.4. Convergencia en media de orden r	43
A.5. Leyes de los grandes números	44
A.5.1. Ley débil de los grandes números	44
A.5.2. Ley fuerte de los grandes números	45
A.6. Teorema central del límite	46

Despacho: 303E

Correo: beatrizg@ucm.es

Evaluación:

- 80 % examen final
- 20 % evaluación continua (en este caso serán trabajos de R)

La estadística descriptiva no entra en el examen. **Bibliografía:**

- 'Interferencia estadística' de M.A. Gómez Villegas
- 'Statistical interference' de Casella Berger

Capítulo 1

Estadística descriptiva

Práctica:

- Hacer en R el ejemplo 1.3.2 (lo del colesterol) del libro (página 11). Lo que hay que hacer aparece en el ejercicio 1.9.3.
- Programar el coeficiente de simetría y de curtosis en R.
- Demostrar todas las cosas del teorema de Fisher.

Ejemplo. Página 44, Ejercicio 1. Consideramos la población dada por la distribución de Bernuilli $B\left(\frac{1}{2}\right)$. Se consideran todas las m.a.s de tamaño 3, es decir,

$$(X_1, X_2, X_3).$$

Recordamos que

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Tendremos que

$$\bar{X} = \begin{cases} 0 \rightarrow \frac{1}{8} \\ \frac{1}{3} \rightarrow \frac{3}{8} \\ \frac{2}{3} \rightarrow \frac{3}{8} \\ 1 \rightarrow \frac{1}{8} \end{cases}.$$

De esta forma tenemos que

$$P_{\bar{X}}(0) = \frac{1}{8}, \quad P_{\bar{X}}\left(\frac{1}{3}\right) = \frac{3}{8}, \text{ etc.}$$

Lo que estamos haciendo es considerar los diferentes casos para X_1, X_2 y X_3 y calcular la media en cada caso. A partir de ahí, estamos tratando a la media como una variable aleatoria discreta.

Ejemplo. Página 44, Ejercicio 2. Una forma de media θ y varianza 1. Se toma una m.a.s de tamaño n . Así, tenemos que $X \sim F_\theta(x) = P_\theta(X \leq x)$. Tendremos que $E_\theta[X] = \theta$ y $V_\theta(X) = 1$. Tenemos que calcular θ para que

$$P_\theta(|\bar{X} - \theta| \leq 0,5) \geq 0,95.$$

Tenemos que aplicar la desigualdad de Chebychev, primer calculamos

$$E_\theta[\bar{X}] = \frac{1}{n} \sum_{i=1}^n E_\theta[X_i] = \theta.$$

Por otro lado, $D_\theta(X) = \sqrt{V_\theta(X)} = 1$, así

$$D_\theta(\bar{X}) = \sqrt{V_\theta(\bar{X})} = \sqrt{V_\theta\left(\frac{1}{n} \sum_{i=1}^n X_i\right)} = \frac{1}{n} \sum_{i=1}^n V_\theta(X_i) = \frac{1}{n} \rightarrow 0.$$

Aplicando la desigualdad de Chebychev

$$P_\theta\left(|\bar{X} - \theta| \geq \frac{K}{n}\right) \leq \frac{1}{K}.$$

Ejemplo. Página 45, Ejercicio 6. Sea una m.a.s de tamaño n calculamos la distribución de la media muestral $\bar{X}$, cuando la población:

(b) $X \sim \gamma(p, a)$. Denotamos $\theta = (p, a) \in \mathbb{R}^+ \times \mathbb{R}^+$ y decimos que $\theta \in \Theta \subset \mathbb{R}^2$. Recordamos que

$$f(x|\theta) = f_\theta(x) = \frac{a^p x^{p-1} e^{-ax}}{\Gamma(p)}, \quad x > 0.$$

Hacemos el ejercicio con la ecuación característica:

$$\varphi_{\bar{X}}(t) = E_\theta[e^{it\bar{X}}] = E_\theta\left[e^{i\frac{t}{n} \sum_{i=1}^n X_i}\right] = \prod_{i=1}^n \varphi_{X_i}\left(\frac{t}{n}\right) = \varphi_X\left(\frac{t}{n}\right)^n = \left(1 - i\frac{t}{na}\right)^{-pn}.$$

La función característica se corresponde con $\gamma(np, na)$.

(c) Basta con sustituir $\lambda = 1$ en el apartado anterior.

Distribuciones asociadas a la normal

Consideremos que $(X_1, \dots, X_n)$ es una m.a.s con cada variable independientes y siguen una distribución $X \sim N(0, 1)$. Consideremos la variable aleatoria

$$Y := \sum_{i=1}^n X_i^2 = X_1^2 + \dots + X_n^2.$$

Tenemos que

$$\varphi_Y(t) = \prod_{i=1}^n \varphi_{X_i^2}(t).$$

En general, si $Z = X^2$,

$$F_Z(z) = P(Z \leq z) = P(X^2 \leq z) = P(-\sqrt{z} \leq X \leq \sqrt{z}) = F_X(\sqrt{z}) - F_X(-\sqrt{z}).$$

La función de densidad será

$$f_Z(t) = \frac{1}{2\sqrt{z}} f_X(\sqrt{z}) + \frac{1}{2\sqrt{z}} f_X(-\sqrt{z}) = \frac{1}{\sqrt{2\pi}} t^{-\frac{1}{2}} e^{-\frac{1}{2}t}, \quad t > 0.$$

Podemos ver que se trata de la función de densidad de una distribución Gamma, así, $Z \sim \gamma\left(\frac{1}{2}, \frac{1}{2}\right)$. Definimos $\chi_1^2 \sim \gamma\left(\frac{1}{2}, \frac{1}{2}\right)$, el uno viene de que tenemos un grado de libertad (se genera a partir de una normal $N(0, 1)$). Por la propiedad de reproductividad de la distribución Gamma, tenemos que $Y \sim \gamma\left(\frac{n}{2}, \frac{1}{2}\right)$. A esta distribución la llamamos $\chi_n^2 \sim \gamma\left(\frac{n}{2}, \frac{1}{2}\right)$ (decimos que tiene n grados de libertad porque viene de n distribuciones normales $N(0, 1)$). Recordamos que la función característica de una distribución γ es

$$\varphi(t) = \left(1 - \frac{it}{a}\right)^{-p}.$$

Ejemplo. Ejercicio 19. Sea $(X_1, \dots, X_n)$ una m.a.s distribuida idénticamente a X tal que

$$P(X = x_i) = p_i, \quad i \in \mathbb{N}.$$

Sea $(X_{(1)}, \dots, X_{(n)})$ la muestra ordenada de menor a mayor. Demostremos que la distribución para $X_{(k)}$ es discreta y

$$P(X_{(1)} \leq x_i) = \sum_{j=k}^n \binom{n}{j} (F(x_i))^j (1 - F(x_i))^{n-j}.$$

El resto viene dado en el enunciado. Tenemos que $X_{(1)} = \min\{X_1, \dots, X_n\}$ y $X_{(n)} = \max\{X_1, \dots, X_n\}$. Tenemos que

$$F_{X_{(n)}}(t) = P(X_{(n)} \leq t) = P\left(\bigcap_{1 \leq i \leq n} \{X_i \leq t\}\right) = \prod_{i=1}^n P(X_i \leq t) = F_X(t)^n.$$

Por otro lado,

$$F_{X_{(1)}}(t) = 1 - P(X_{(1)} > t) = 1 - P\left(\bigcap_{1 \leq i \leq n} \{X_i > t\}\right) = 1 - \prod_{i=1}^n P(X_i > t) = 1 - (1 - F_X(t))^n.$$

Ahora, buscamos $F_{X_{(k)}}(t)$ para $k \in \{1, \dots, n\}$. Tenemos que

$$F_{X_{(k)}}(t) = P(X_{(k)} \leq t) = \sum_{j=k}^n P(\text{'exactamente } j \text{ por debajo de } t') = \sum_{j=k}^n \binom{n}{j} F_X(t)^j (1 - F_X(t))^{n-j}.$$

Finalmente, recordamos que $P_{X_{(k)}}(x_i) = F_{X_{(k)}}(x_i) - F_{X_{(k)}}(x_{i-1})$.

Teorema 1.1. Es cierto que $\sqrt{n} (b_2 - \sigma^2) \rightarrow N(0, \sqrt{\beta_4 - \sigma^4})$.

Teorema 1.2 (Teorema de Fisher). Sea $(X_1, \dots, X_n)$ una m.a.s idénticamente distribuida a $X \sim N(\mu, \sigma)$. Entonces se cumple que

1. $\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$.
2. $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$.
3. $\frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}$.
4. $\bar{X}$ y $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$ son independientes.

Demostración. Cogemos $Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$ así, tendremos que

$$T = \frac{\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{(n-1)S^2}{\sigma^2} \frac{1}{n-1}}} = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}}.$$

En esto último hemos aplicado el punto 2 del teorema de Fisher. Esto es en teoría una demostración del punto 3 del teorema de Fisher. Para demostrar 4 basta con ver que $Cov(\bar{X}, S) = 0$, por ser $X \sim N(\mu, \sigma)$. $\square$

Definición 1.1. Sea $(X_1, \dots, X_n)$ una m.a.s (n) idénticamente distribuidas a $N(0, 1)$. Tenemos que $\chi_{n-1}^2 := X_1^2 + \dots + X_n^2 \sim \gamma\left(p = \frac{n-1}{2}, a = \frac{1}{2}\right)$.

Definición 1.2 (Distribución t_k -student). Sea $\{X_i\}_{i \in \mathbb{N}}$ una sucesión de variables independientes idénticamente distribuidas que siguen la distribución $X \sim N(0, 1)$. Cogemos las k primeras y definimos

$$Y = \sqrt{\frac{X_1^2 + \dots + X_k^2}{k}} \sim \sqrt{\frac{\chi_k^2}{k}}.$$

Si $Z = X_{k+1} \sim N(0, 1)$, entonces definimos la T de Student como $T = \frac{Z}{Y}$.

1.1. Tema 3

Ejemplo (Ejercicio 1). Sea X una observación de una población $N(0, \sigma)$. Tenemos que $\sigma \in \Theta \subset \mathbb{R}^+$. Sabemos que

$$f_{\sigma}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}x^2}.$$

Veamos si $|X|$ es un estadístico suficiente. Por el teorema de caracterización de Fisher es fácil ver que $T = |X|$ es suficiente.

Ejemplo (Ejercicio 2). Sea $(X_1, \dots, X_n)$ una m.a.s. de X .

(a) *Beta* (α, β) , $\alpha, \beta > 0$. Tendremos que $\theta = (\alpha, \beta) \in \mathbb{R}^+ \times \mathbb{R}^+$. Tendremos que

$$f_{\theta}(x) \propto K(\alpha, \beta) x^{\alpha-1} (1-x)^{\beta-1} = K(\alpha, \beta) e^{(\alpha-1)\ln x + (\beta-1)\ln(1-x)}.$$

Podemos coger $q_1(\theta) = \alpha - 1$ y $t_1(x) = \ln x$ y también $q_2(\theta) = \beta - 1$ y $t_2(x) = \ln(1-x)$. Así, el estadístico suficiente será

$$\left(\sum_{i=1}^n t_1(X_i), \sum_{i=1}^n t_2(X_i) \right) = \left(\sum_{i=1}^n \ln X_i, \sum_{i=1}^n \ln(1-X_i) \right).$$

(b)

Ejemplo (Ejercicio 10). Cogemos

$$T_1 = T_1(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \text{y} \quad T_2 = T_2(X_1, \dots, X_n) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

(a) Tenemos que $E_{\theta}[T_2] = E_{\theta}[S^2] = \sigma^2$.

Capítulo 2

Muestreo

2.1. Modelos estadísticos

Cada fenómeno aleatorio está gobernado por una función de probabilidad. Para estudiar dicho fenómeno, nos centramos en estudiar su distribución de probabilidad subyacente.

Llamaremos **población** a una variable aleatoria $X \sim F$, donde F es una función de distribución no completamente conocida. Nuestro objetivo será obtener información sobre ciertas características de la distribución de X . Para ello, replicaremos el experimento aleatorio (de forma idéntica e independiente) un número de n veces.

Hay varios tipos de inferencia:

- Inferencia frecuentista: utilizamos información objetiva, es decir, datos de la muestra.
- Inferencia bayesiana: se utiliza información subjetiva.

También podemos diferenciar en función del grado de conocimiento sobre F :

- Inferencia paramétrica: se conoce la forma funcional de F , excepto por ciertas características.
- Inferencia no paramétrica: no se asume una forma funcional para F .

Supongamos por ahora que la verdadera función de distribución F de nuestra población X está contenida en una familia $\mathcal{F}$ de funciones de distribución asociadas a X .

Definición 2.1 (Modelo estadístico). Un **modelo estadístico** es una terna $(\chi, \beta_\chi, \mathcal{F})$, donde

- $\chi \subset \mathbb{R}$ es el espacio muestral.
- β_χ es una σ -álgebra de Borel sobre χ .
- $\mathcal{F}$ es un conjunto de funciones de distribución asociadas a medidas de probabilidad P_X definidas sobre (χ, β_χ) .

En la inferencia paramétrica asumimos que conocemos la forma funcional de la verdadera función de distribución F de la variable aleatoria de interés X , excepto por k parámetros $\theta = (\theta_1, \dots, \theta_k)$. En este caso, la familia $\mathcal{F}$ tiene la forma

$$\mathcal{F} = \{F(\cdot; \theta) : \theta \in \Theta\}.$$

Decimos que $\theta \in \Theta \subset \mathbb{R}^k$, donde Θ es el **espacio paramétrico**. En el caso de inferencia frecuentista consideraremos que θ es un valor fijo y desconocido, por lo que escribiremos $f_\theta(x)$ para designar a la función de masa. Sin embargo, en el planteamiento bayesiano consideraremos que θ es una variable aleatoria, por lo que escribiremos $f(x|\theta)$.

Definición 2.2 (Modelo estadístico paramétrico). Un **modelo estadístico paramétrico** es una terna $(\chi, \beta_\chi, \mathcal{F})$ donde

$$\mathcal{F} = \{F(\cdot; \theta) : \theta \in \Theta\}.$$

Ejemplo. Consideremos los siguientes ejemplos.

- Estimar la probabilidad de que un producto resulte defectuoso en una cadena de producción: $X \sim \text{Bern}(\theta)$, $\theta \in [0, 1]$.
- Estimar el tiempo entre llegadas a la cola de un servidor: $X \sim \exp(\lambda)$, $\lambda > 0$.
- Estimar el peso esperado de niños hasta cierta edad en una región determinada: $X \sim N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$.

2.2. Estadísticos muestrales

Consideremos una variable aleatoria X a la que llamaremos **universo** o **población** cuya función de distribución F viene dada por algún elemento de una familia $\mathcal{F}$ de distribuciones de probabilidad.

Definición 2.3 (Muestra aleatoria simple (m.a.s.)). Dada una población X se llama **muestra aleatoria simple (m.a.s.)** de tamaño n a la repetición de $X_1, \dots, X_n$ variables aleatorias independientes con distribución igual a la de X .

Observación. El modelo estadístico asociado a nuestra muestra $\vec{X} = (X_1, \dots, X_n)$ es $(\chi^n, \beta_{\chi^n}, \mathcal{F}^n)$, donde $\mathcal{F}^n$ es el conjunto de funciones de distribución $F_X : \mathbb{R}^n \rightarrow \mathbb{R}$ tales que

$$F_X(x_1, \dots, x_n) = \prod_{i=1}^n F(x_i), \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n.$$

Observación. Por ejemplo, la función de distribución de la muestra $(x_1, \dots, x_n)$ es

$$F(x_1, \dots, x_n) = \prod_{i=1}^n F(x_i),$$

donde $F(x)$ es la función de distribución de X , que viene dada por un elemento de $\mathcal{F}$.

Observación. Los datos observados $(x_1, \dots, x_n)$ son un resultado o realización de la m.a.s., $X_1 = x_1, \dots, X_n = x_n$.

Definición 2.4 (Estadístico muestral). Dada $(X_1, \dots, X_n)$ una m.a.s. de X , a toda $f : \mathbb{R}^n \rightarrow \mathbb{R}^k$ función conocida medible recibe el nombre de **estadístico muestral**.

Ejemplo. Algunos ejemplos de estadísticos muestrales son la **media muestral** que viene dada como

$$\bar{X} := \frac{1}{n} \sum_{i=1}^n X_i,$$

y la **cuasivarianza muestral**

$$S^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Definición 2.5 (Momentos centrales). Se llama **momento muestral respecto al origen** de orden k a $a_k := \frac{1}{n} \sum_{i=1}^n X_i^k$, con $k > 0$. Análogamente, se llama **momento muestral respecto al centro** de orden k a $b_k := \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$, con $k > 0$.

Ejemplo. Como hemos visto antes, tendremos que $a_1 = \bar{X}$.

Observación. Es sencillo ver que

$$b_k = a_k - \binom{k}{1} \bar{X} a_{k-1} + \dots + (-1)^k \bar{X}^k,$$

es decir, los momentos muestrales respecto al centro se puede calcular en función de los momentos muestrales respecto al origen. En particular,

$$b_2 = a_2 - a_1^2 = a_2 - \bar{X}^2.$$

Proposición 2.1. Dada una m.a.s. de tamaño n de una población X con momento de segundo orden finito ^a, se tiene que $E[\bar{X}] = \mu$ y $V(\bar{X}) = \frac{\sigma^2}{n}$, donde $\mu = E[X]$ y $\sigma^2 = V(X)$.

^aEsta hipótesis es necesaria para asegurar la existencia de σ^2 y μ .

Demostración. Aplicando las propiedades de la esperanza,

$$E[\bar{X}] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \sum_{i=1}^n \mu = \mu.$$

Por otro lado, aplicando las propiedades de la varianza,

$$\begin{aligned} V(\bar{X}) &= E[(\bar{X} - \mu)^2] = E\left[\left(\frac{1}{n} \sum_{i=1}^n (X_i - \mu)\right)^2\right] \\ &= \frac{1}{n^2} E\left[\sum_{i=1}^n (X_i - \mu)^2 + 2 \sum_{i=1}^n \sum_{j=1, j>i}^n (X_i - \mu)(X_j - \mu)\right] \\ &= \frac{1}{n^2} \left[\sum_{i=1}^n V(X_i) + 2 \sum_{i=1}^n \sum_{j>i}^n E[X_i - \mu] E[X_j - \mu] \right] = \frac{\sigma^2}{n}. \end{aligned}$$

Podemos observar que el segundo sumando se anula. $\square$

2.3. Propiedades asintóticas de los momentos muestrales

Sea $(X_1, \dots, X_n)$ una m.a.s (n) de X con $\mu = E[X]$ y $\sigma = \sqrt{V(X)}$.

Proposición 2.2 (Momentos muestrales respecto al origen). Se cumple que si $n \rightarrow \infty$

$$a_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{c.s.} \alpha_k = E[X^k].$$

Particularmente,

$$\bar{X} \xrightarrow{c.s.} \mu \quad (\text{Ley Fuerte de Kintchine, } \mu < \infty).$$

Demostración. Por el teorema de Kintchine, tenemos que para una sucesión de variables aleatorias $\{Y_n\}_{n \in \mathbb{N}}$ independientes e idénticamente distribuidas con $E[Y_i] = \mu < \infty$, $\forall n \in \mathbb{N}$, tenemos que $\bar{Y} \xrightarrow{cs} \mu$. El resultado general lo obtenemos tomando $Y_i = X_i^k$. $\square$

Proposición 2.3 (Momentos muestrales respecto a la media). Si una población tiene momentos de orden $k > 0$, el momento muestral respecto al centro de orden k , converge, casi seguro, al momento poblacional respecto al centro de orden k , es decir

$$b_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \xrightarrow{cs} \beta_k = E[(X - \mu)^k].$$

En particular,

$$\sigma_n^2 \xrightarrow{cs} \sigma^2 \quad \text{y} \quad S_n^2 \xrightarrow{cs} \sigma^2.$$

Demostración. Hacer en casa. $\square$

Proposición 2.4. Si la población tiene momentos de orden $2k$ respecto al origen, entonces se tiene la siguiente convergencia en ley

$$\frac{a_k - \alpha_k}{\sqrt{\alpha_{2k} - \alpha_k^2}} \sqrt{n} \xrightarrow{\mathcal{L}} N(0, 1).$$

En particular,

$$\sqrt{n} \frac{\bar{X} - \mu}{\sigma} \xrightarrow{\mathcal{L}} N(0, 1) \text{ (Teorema de Lévy-Lindeberg).}$$

Demostración. Basta con aplicar el teorema central del límite, $\{Y_n\}_{n \in \mathbb{N}}$ con v.a.i.i.d con momento de segundo orden y $E[Y_n] = \mu$ y $V(Y_n) = \sigma^2 < \infty$. Entonces, tendremos que

$$\frac{\bar{Y} - \mu}{\sigma} \sqrt{n} \xrightarrow{\mathcal{L}} N(0, 1).$$

Para obtener el resultado general podemos considerar $Y_n = X_n^k$ y $a_k = \bar{Y}$, de forma que $\mu = \alpha_k$ y $\sigma^2 = \alpha_{2k} - \alpha_k^2$. $\square$

Proposición 2.5. Si existe el momento poblacional respecto al origen de orden $2k$, entonces

$$\sqrt{n} \frac{b_k - \beta_k}{\sqrt{\beta_{2k} - \beta_k^2 - 2k\beta_{k-1}\beta_{k+1} + k^2\beta_{k-1}^2\beta_2}} \xrightarrow{\mathcal{L}} N(0, 1).$$

En particular,

$$\sqrt{n} \frac{\sigma_n^2 - \sigma^2}{\sqrt{\beta_4 - \sigma^4}} \xrightarrow{\mathcal{L}} N(0, 1).$$

Teorema 2.1 (Teorema de Slutsky). Si $X_n \xrightarrow{\mathcal{L}} X$ e $Y_n \xrightarrow{P} a$, con $a \in \mathbb{R}$, entonces

1. $Y_n X_n \xrightarrow{\mathcal{L}} aX$.
2. $X_n + Y_n \xrightarrow{\mathcal{L}} X + a$.

Lema 2.1. Si $\{a_n\}_{n \in \mathbb{N}} \subset \mathbb{R}$ con $\lim_{n \rightarrow \infty} a_n = \infty$ y $a \in \mathbb{R}$ tal que

$$a_n (X_n - a) \xrightarrow{\mathcal{L}} X,$$

entonces para $g : \mathbb{R} \rightarrow \mathbb{R}$ con derivada continua y no nula en a se tiene que

$$a_n (g(X_n) - g(a)) \xrightarrow{\mathcal{L}} g'(a) X.$$

Otro estadístico muestral importante es la función de distribución empírica o muestral.

Definición 2.6 (Función de distribución empírica). Dada una realización particular de una muestra $(x_1, \dots, x_n)$, la **función de distribución empírica** viene dada por

$$F_n(x) = \begin{cases} 0, & x < x_{(1)} \\ \frac{k}{n}, & x_{(k)} \leq x < x_{(k+1)}, \quad k = 1, \dots, n-1 \\ 1, & x_{(n)} \leq x \end{cases}.$$

Recordamos que $(x_{(1)}, \dots, x_{(n)})$ es la muestra ordenada de menor a mayor.

La función de distribución empírica también se puede escribir de la forma

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(x_i).$$

Es fácil ver que para $t \in \mathbb{R}$ fijo se verifica que

$$nF_n(t) \sim \text{Bin}(n, F(t)).$$

Observación. Para todo x se verifica que

$$F_n(x) \xrightarrow{c.s.} F(x),$$

donde $F(x)$ es la función de distribución de la población. En efecto, si tomamos $Y_i = I_{(-\infty, x]}(x_i)$, tenemos que

$$E[Y_i] = F(x), \quad V(Y_i) = F(x)[1 - F(x)], \quad F_n(x) = \bar{Y}.$$

Aplicando la ley de los grandes números obtenemos la convergencia que hemos mencionado antes. Por otro lado, podemos aplicar el Teorema Central del Límite para obtener que

$$\sqrt{n} \frac{F_n(x) - F(x)}{\sqrt{F(x)[1 - F(x)]}} \xrightarrow{\mathcal{L}} Z \sim N(0, 1).$$

Teorema 2.2 (Teorema central de la estadística). Si se tiene una m.a.s. de tamaño n de una población X con función de distribución $F(x)$, para cualquier $\varepsilon > 0$ se tiene que

$$\lim_{n \rightarrow \infty} P\left(\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \geq \varepsilon\right) = 0.$$

Observación. Este teorema nos dice que si se quiere determinar de forma aproximada la función de distribución, se puede obtener una m.a.s. de tamaño n grande, construir a partir de ella la función de distribución empírica y esperar que $F_n(x)$ sea una buena aproximación de $F(x)$.

2.4. Distribuciones asociadas a la normal

Para muchas variables podemos asumir que su distribución pertenece a la familia Gaussiana $N(\mu, \sigma)$, donde tendremos que

$$\theta = (\mu, \sigma) \in \Theta = (-\infty, \infty) \times (0, \infty).$$

En esta sección supondremos que $(X_1, \dots, X_n)$ es una m.a.s. (n) de $X \sim N(\mu, \sigma)$.

Teorema 2.3 (Distribución de la media muestral). Si $(X_1, \dots, X_n)$ es una m.a.s. (n) de $X \sim N(\mu, \sigma)$, entonces

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right).$$

Demostración. Sabemos que $\varphi_X(t) = e^{it\mu - \frac{1}{2}t^2\sigma^2}$. Por tanto, tendremos que

$$\begin{aligned}\varphi_{\bar{X}}(t) &= E\left[e^{it\bar{X}}\right] = E\left[e^{it\frac{1}{n}\sum_{i=1}^n X_i}\right] = E\left[\prod_{i=1}^n e^{it\frac{1}{n}X_i}\right] = \prod_{i=1}^n \varphi_{X_i}\left(\frac{t}{n}\right) \\ &= \varphi_X^n\left(\frac{t}{n}\right) = e^{it\mu - \frac{1}{2}\frac{\sigma^2}{n}t^2}.\end{aligned}$$

Por tanto, tenemos que $\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$. □

Definición 2.7 (Estadístico Z). El **estadístico** Z se obtiene estandarizando la media muestral

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1).$$

Definición 2.8 (Distribución χ^2). Una **distribución** χ_n^2 con n grados de libertad es la distribución de la suma de n variables aleatorias independientes $Z_1, \dots, Z_n$ con distribución $N(0, 1)$, es decir

$$Y = \sum_{i=1}^n Z_i^2 \sim \chi_n^2.$$

Proposición 2.6. Se verifica $\chi_n^2 \sim \gamma\left(a = \frac{1}{2}, p = \frac{n}{2}\right)$.

Demostración. Como $Z \sim N(0, 1)$, tenemos que $\varphi_Z(t) = \frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}t^2}$. En primer lugar, calculamos la distribución de Z^2 :

$$F_{Z^2}(y) = P(Z^2 \leq y) = P(-\sqrt{y} \leq Z \leq \sqrt{y}) = F_Z(\sqrt{y}) - F_Z(-\sqrt{y}) = 2F_Z(\sqrt{y}) - 1.$$

Así, tenemos que

$$f_{Z^2}(y) = 2f_Z(\sqrt{y}) \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}y}y^{-\frac{1}{2}}.$$

Por tanto, tenemos que $Z^2 \sim \gamma\left(a = \frac{1}{2}, p = \frac{1}{2}\right)$. Así, tendremos que $\varphi_{Z^2}(t) = (1 - 2it)^{-\frac{1}{2}}$,

por lo que

$$\varphi_{\chi_n^2}(t) = E \left[e^{it \sum_{i=1}^n Z_i^2} \right] = \prod_{i=1}^n \varphi_{Z_i^2}(t) = \varphi_{Z^2}^n(t) = (1 - 2it)^{-\frac{n}{2}}.$$

Por tanto, tenemos que $\chi_n^2 \sim \gamma \left(a = \frac{1}{2}, p = \frac{n}{2} \right)$. $\square$

Observación (Propiedades de la distribución χ_n^2). Las siguientes propiedades son fáciles de comprobar:

- A partir de la proposición anterior es sencillo ver que la función de densidad de χ_n^2 será

$$f_{\chi_n^2}(x) = \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} e^{-\frac{1}{2}x} x^{\frac{n}{2}-1}, x > 0.$$

- Se tiene que $E[\chi_n^2] = n$ y $V(\chi_n^2) = 2n$.
- **Propiedad de aditividad.** Si $Y_i \sim \chi_{n_i}^2$, con $i = 1, \dots, k$, son independientes, entonces

$$Y = \sum_{i=1}^k Y_i \sim \chi_n^2, \quad n = \sum_{i=1}^k n_i.$$

Lema 2.2. Si $Y \sim \gamma(a, p)$, entonces $T = 2aY \sim \gamma\left(a = \frac{1}{2}, p\right)$.

Demostración. Como $Y \sim \gamma(a, p)$ se tiene que

$$f_Y(y) = \frac{a^p}{\Gamma(p)} e^{-ay} y^{p-1}.$$

Por otro lado, como $T = 2aY$, se tiene que $Y = \frac{1}{2a}T$. Así, tenemos que

$$f_T(t) = f_Y\left(\frac{1}{2a}t\right) \frac{1}{2a} = \frac{\left(\frac{1}{2}\right)^p}{\Gamma(p)} e^{-\frac{1}{2}t} t^{p-1}.$$

$\square$

Proposición 2.7. Sea $(X_1, \dots, X_n)$ una m.a.s. (n) de $X \sim N(0, \sigma)$. Entonces,

$$a_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \sim \gamma\left(a = \frac{n}{2\sigma^2}, p = \frac{n}{2}\right) \quad \text{y} \quad \sigma^2 \sqrt{\frac{n}{2}} (a_2 - \sigma^2) \xrightarrow{\mathcal{L}} N(0, 1).$$

Demostración. Sea $Z_i = \frac{X_i}{\sigma} \sim N(0, 1)$, para $i \in \{1, \dots, n\}$. Entonces, tenemos que

$$\sum_{i=1}^n Z_i^2 \sim \chi_n^2 \equiv \gamma\left(a = \frac{1}{2}, p = \frac{n}{2}\right).$$

De esta manera, tenemos que

$$a_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{\sigma^2}{n} \sum_{i=1}^n Z_i^2.$$

Por tanto,

$$f_{a_2}(t) = f_{\chi_n^2}\left(\frac{n}{\sigma^2}t\right) \frac{n}{\sigma^2} = \frac{\left(\frac{n}{2\sigma^2}\right)^{\frac{n}{2}}}{\Gamma\left(\frac{n}{2}\right)} e^{-\frac{n}{2\sigma^2}t} t^{\frac{n}{2}-1}.$$

Así, tenemos que $a_2 \sim \Gamma\left(a = \frac{n}{2\sigma^2}, p = \frac{n}{2}\right)$. □

Definición 2.9 (Distribución t de Student). Dadas las variables independientes $X, X_1, \dots, X_n$ con distribución $N(0, 1)$, la distribución de la variable aleatoria

$$T = \frac{X}{\sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2}},$$

es una t **de Student** con n grados de libertad, denotada t_n .

Proposición 2.8 (Función de densidad de la t de Student). La función de densidad de $T \sim t_n$ es

$$f_T(t) = \frac{1}{\sqrt{n\pi}} \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad t \in \mathbb{R}.$$

Demostración. Sean $X \sim N(0, 1)$ e $Y \sim \sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2}$. Así, $T \sim \frac{X}{Y}$ y tendremos que

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}, \quad x \in \mathbb{R} \quad \text{y} \quad f_Y(y) = \frac{n^{\frac{n}{2}}}{2^{\frac{n}{2}-1} \Gamma\left(\frac{n}{2}\right)} e^{-\frac{n}{2}y^2} y^{n-1}, \quad y > 0.$$

La función de densidad conjunta de X e Y será $f(x, y) = f_X(x) f_Y(y)$. Haciendo el cambio $T = \frac{X}{Y}$ y $Z = Y$, obtenemos la función de densidad

$$f(t, u) = k e^{-\frac{1}{2}(t^2+n)u^2} u^n, \quad t \in \mathbb{R}, \quad u \geq 0, \quad k = \frac{n^{\frac{n}{2}}}{2^{\frac{n-1}{2}} \Gamma\left(\frac{1}{2}\right) \Gamma\left(\frac{n}{2}\right)}.$$

La función de densidad de T es se obtiene como la marginal de la anterior ^a:

$$f_T(t) = \int_0^\infty f(t, u) du = k \int_0^\infty e^{-\frac{1}{2}(t^2+n)u^2} u^n du = \frac{k}{2} \left(\frac{n+t^2}{2} \right)^{-\frac{n+1}{2}} \Gamma\left(\frac{n+1}{2}\right).$$

Sustituyendo el valor de k obtenemos

$$f_T(t) = \frac{n^{\frac{n}{2}}}{2^{\frac{n}{2}-\frac{1}{2}} \Gamma\left(\frac{1}{2}\right) \Gamma\left(\frac{n}{2}\right)} \frac{1}{2} \left(\frac{n+t^2}{2} \right)^{-\frac{n+1}{2}} \Gamma\left(\frac{n+1}{2}\right).$$

Simplificando obtenemos la expresión deseada. $\square$

^aPara resolver la integral conviene mirar el libro.

Observación (Propiedades de la distribución t de Student). Es fácil de comprobar que:

- La distribución t de Student es simétrica.
- Para $n > 2$ se cumple que $E[T] = 0$ y $V(T) = \frac{n}{n-2}$. Para $n \leq 2$ la varianza no existe.
- En el caso $n = 1$ también se llama **distribución de Cauchy**.

Teorema 2.4 (Teorema de Fisher). Sea $(X_1, \dots, X_n)$ una m.a.s. (n) de $X \sim N(\mu, \sigma)$, con μ y σ desconocidos.

1. La media muestral y la cuasivarianza muestral son variables aleatorias independientes.
2. Se cumple que $\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$ y $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$.
3. Se cumple que

$$\frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}.$$

Demostración. 1. Basta con demostrar que $\bar{X}$ y $X_h - \bar{X}$ son independientes para $h = 1, \dots, n$. Una forma de ver esto es que

$$\varphi_{\bar{X}, X_h - \bar{X}}(t_1, t_2) = \varphi_{\bar{X}}(t_1) \varphi_{X_h - \bar{X}}(t_2).$$

Tenemos que

$$\begin{aligned} \varphi_{\bar{X}, X_h - \bar{X}}(t_1, t_2) &= E \left[e^{it_1 \bar{X} + it_2 (X_h - \bar{X})} \right] = E \left[e^{i(t_1 - t_2) \bar{X} + it_2 X_h} \right] \\ &= E \left[e^{i \frac{t_1 - t_2}{n} \sum_{i \neq h} X_i} \right] E \left[e^{i \left(\frac{t_1 - t_2}{n} + t_2 \right) X_h} \right]. \end{aligned}$$

Así, como $\sum_{i \neq h} X_i \sim N((n-1)\mu, \sigma\sqrt{n-1})$ y $X_h \sim N(\mu, \sigma)$, tenemos que

$$\varphi_{\overline{X}, X_h - \overline{X}}(t_1, t_2) = \varphi_{N(\mu, \frac{\sigma}{\sqrt{n}})}(t_1) \varphi_{N(0, \sigma\sqrt{1-\frac{1}{n}})}(t_2).$$

Como $\overline{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$ y

$$X_h - \overline{X} = \left(1 - \frac{1}{n}\right) X_h - \frac{\sum_{i \neq h} X_i}{n} \sim N\left(0, \sigma\sqrt{1 - \frac{1}{n}}\right),$$

hemos terminado.

2. La primera igualdad ya ha sido demostrada. Sea $S_{n+1}^2 = \frac{1}{n} \sum_{i=1}^{n+1} (X_i - \overline{X}_{n+1})^2$.

Podemos ver que

$$nS_{n+1}^2 = (n-1)S_n^2 + (X_{n+1} - \overline{X}_n)^2 \frac{n}{n+1}.$$

En efecto,

$$\begin{aligned} nS_{n+1}^2 &= \sum_{i=1}^{n+1} (X_i - \overline{X}_{n+1})^2 = \sum_{i=1}^n (X_i - \overline{X}_n + \overline{X}_n - \overline{X}_{n+1})^2 + (X_{n+1} - \overline{X}_{n+1})^2 \\ &= (n-1)S_n^2 + n(\overline{X}_n - \overline{X}_{n+1})^2 + (X_{n+1} - \overline{X}_{n+1})^2. \end{aligned}$$

Aplicando que $\overline{X}_{n+1} = \frac{n\overline{X}_n + X_{n+1}}{n+1}$, obtenemos la igualdad deseada. Ahora, procedemos por inducción. Para $n+1=2$, tenemos que

$$\frac{S_2^2}{\sigma^2} = \left(\frac{X_2 - \overline{X}_1}{\sigma\sqrt{2}}\right)^2 \sim \chi_1^2.$$

Supongamos ahora que es cierto para n , es decir

$$\frac{(n-1)S_n^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Entonces, en el caso $n+1$ tenemos que

$$\frac{nS_{n+1}^2}{\sigma^2} = \frac{(n-1)S_n^2}{\sigma^2} + \left(\frac{X_{n+1} - \overline{X}_n}{\sigma\sqrt{\frac{n+1}{n}}}\right)^2 \sim \chi_{n-1}^2 + \chi_1^2 \sim \chi_n^2.$$

3. La variable $\frac{\bar{X} - \mu}{\sigma} \sqrt{n}$ tiene distribución $N(0, 1)$ y la variable $(n-1) \frac{S^2}{\sigma^2}$ tiene distribución χ_{n-1}^2 , como acabamos de ver. Por (1) tenemos que ambas son independientes, y de aquí el resultado se obtiene fácilmente. $\square$

Definición 2.10 (Distribución F de Snedecor). Sean $X_1 \sim \chi_{n_1}^2$ y $X_2 \sim \chi_{n_2}^2$ independientes^a. La distribución de la variable aleatoria

$$F = \frac{\frac{X_1}{n_1}}{\frac{X_2}{n_2}},$$

es una **distribución F de Snedecor** con n_1 grados de libertad en el numerador y n_2 grados de libertad en el denominador, denotada F_{n_1, n_2} .

^aTambién podemos enunciar esto tomando dos m.a.s independientes $(X_1, \dots, X_{n_1})$ y $(Y_1, \dots, Y_{n_2})$ de una población $N(0, 1)$, entonces $F_{n_1, n_2} = \frac{\frac{1}{n_1} \sum_{i=1}^{n_1} X_i^2}{\frac{1}{n_2} \sum_{i=1}^{n_2} Y_i^2}$.

Proposición 2.9 (Función de densidad de la F de Snedecor). La función de densidad de la F de Snedecor con (n_1, n_2) grados de libertad es

$$f(x) = \frac{\binom{n_1}{n_2}^{\frac{n_1}{2}} \Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right) \Gamma\left(\frac{n_2}{2}\right)} x^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2} x\right)^{-\frac{n_1+n_2}{2}}, \quad x > 0.$$

Demostración. Sea $F_{n_1, n_2} = \frac{U}{V}$. Tenemos que la función de densidad de U será

$$f(u) = \frac{n_1^{\frac{n_1}{2}}}{2^{\frac{n_1}{2}} \Gamma\left(\frac{n_1}{2}\right)} u^{\frac{n_1}{2}-1} e^{-\frac{n_1}{2}u}, \quad u \geq 0.$$

De esta forma, la función de densidad conjunta de U y V será, dada su independencia,

$$f(u, v) = k u^{\frac{n_1}{2}-1} v^{\frac{n_2}{2}-1} e^{-\frac{1}{2}(n_1 u + n_2 v)}, \quad u, v \geq 0, \quad k = \frac{n_1^{\frac{n_1}{2}} n_2^{\frac{n_2}{2}}}{2^{\frac{n_1+n_2}{2}} \Gamma\left(\frac{n_1}{2}\right) \Gamma\left(\frac{n_2}{2}\right)}.$$

Haciendo el cambio $S = \frac{U}{V}$ y $T = V$, tenemos que

$$f(s, t) = k (st)^{\frac{n_1}{2}-1} t^{\frac{n_2}{2}} e^{-\frac{n_1 s + n_2}{2} t}.$$

Calculamos la función de densidad de S como la función de densidad marginal y nos

queda ^a

$$f(s) = \frac{\binom{n_1}{n_2}^{\frac{n_1}{2}} \Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right) \Gamma\left(\frac{n_2}{2}\right)} s^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2} s\right)^{-\frac{n_1+n_2}{2}}, \quad s > 0.$$

□

^aSi se quiere ver cómo resolver la integral en detalle mirar el libro.

Observación (Propiedades de la F de Snedecor). Se puede observar que:

- Para $n_1 = 1$ se tiene que $F_{1,n} \equiv t_n^2$.
- Si $F \sim F_{n_1, n_2}$, entonces $\frac{1}{F} \sim F_{n_2, n_1}$.
- Se cumple que

$$E[F] = \frac{n_2}{n_2 - 2} \quad \text{y} \quad V(F) = \frac{2n_2^2(n_1 + n_2 - 2)}{n_1(n_2 - 2)^2(n_2 - 4)}.$$

Corolario 2.1. Si $(X_1, \dots, X_m)$ es una m.a.s. de una población $N(\mu_1, \sigma_1)$ e $(Y_1, \dots, Y_n)$ una m.a.s. de una población $N(\mu_2, \sigma_2)$ y ambas muestras son independientes, la variable aleatoria

$$F_{m-1, n-1} = \frac{S_1^2 \sigma_2^2}{S_2^2 \sigma_1^2} \sim F_{m-1, n-1},$$

donde S_1^2 y S_2^2 son las cuasivarianzas muestrales respectivas y $\mu_1, \mu_2, \sigma_1, \sigma_2$ son desconocidas.

2.5. Estadísticos de orden

Sea $(X_1, \dots, X_n)$ una m.a.s. de una variable aleatoria X con función de distribución F . Los **estadísticos de orden** son obtenidos al ordenar la muestra de menor a mayor, es decir

$$\begin{aligned} X_{(1)} &= \min \{X_1, \dots, X_n\} \\ X_{(2)} &= \min \{\{X_1, \dots, X_n\} - X_{(1)}\} \\ &\vdots \\ X_{(n)} &= \max \{X_1, \dots, X_n\}. \end{aligned}$$

De esta forma, obtenemos la muestra ordenada $(X_{(1)}, \dots, X_{(n)})$.

Observación (IMPORTANTE). Para $i = 1, \dots, n$, las distribuciones de $X_{(i)}$ dependen de F , pero no son independientes y no tienen por qué estar idénticamente distribuidos!

Ejemplo (Distribución del mínimo y máximo). Sea $(X_1, \dots, X_n)$ una m.a.s. de una variable aleatoria X continua con función de distribución F y función de densidad f . Tendremos que

$$\begin{aligned} 1 - F_{X_{(1)}}(t) &= P(X_{(1)} > t) = P(X_1 > t, \dots, X_n > t) \\ &= \prod_{i=1}^n P(X_i > t) = \prod_{i=1}^n [1 - F_{X_i}(t)] = [1 - F(t)]^n. \end{aligned}$$

De esta manera, la función de densidad de $X_{(1)}$ será

$$f_{X_{(1)}}(t) = n[1 - F(t)]^{n-1} f(t).$$

Análogamente, para $X_{(n)}$ tendremos que

$$\begin{aligned} F_{X_{(n)}}(t) &= P(X_{(n)} \leq t) = P(X_1 \leq t, \dots, X_n \leq t) \\ &= \prod_{i=1}^n P(X_i \leq t) = \prod_{i=1}^n F_{X_i}(t) = [F(t)]^n. \end{aligned}$$

Así, tendremos que la función de densidad de $X_{(n)}$ será

$$f_{X_{(n)}}(t) = n[F(t)]^{n-1} f(t).$$

Proposición 2.10. Sea $(X_1, \dots, X_n)$ una m.a.s. de una variable aleatoria X con función de distribución F continua y función de densidad f . Entonces

1. La función de densidad conjunta de $(X_{(1)}, \dots, X_{(n)})$ es

$$g(t_1, \dots, t_n) = n! \prod_{i=1}^n f(t_i), \quad t_1 \leq \dots \leq t_n.$$

2. La función de distribución marginal de $X_{(r)}$ para $r = 1, \dots, n$ es

$$F_{X_{(r)}}(t) = \sum_{i=r}^n \binom{n}{i} [F(t)]^i [1 - F(t)]^{n-i}.$$

3. La función de densidad marginal de $X_{(r)}$ para $r = 1, \dots, n$ es

$$g(t) = \frac{n!}{(r-1)!(n-r)!} [F(t)]^{r-1} [1 - F(t)]^{n-r} f(t).$$

Demostración. Demostramos (2) puesto que (3) se deduce fácilmente de este. El suceso $\{X_{(r)} \leq t\}$ es equivalente a que al menos r valores muestrales sean menores que t . Así, se sigue fácilmente que

$$F_{X_{(r)}}(t) = \sum_{i=r}^n \binom{n}{i} [F(t)]^i [1 - F(t)]^{n-i}.$$

Como estamos suponiendo que X es una variable aleatoria con función de distribución continua, podemos obtener la función de densidad derivando la expresión anterior. $\square$

Proposición 2.11. La función de densidad conjunta de $(X_{(r)}, X_{(s)})$ para $r < s$ es

$$g(t_1, t_2) = \frac{n!}{(r-1)!(s-r-1)!(n-s)!} [F(t_1)]^{r-1} f(t_1) \cdot [F(t_2) - F(t_1)]^{s-r-1} [1 - F(t_2)]^{n-s}, \quad t_1 \leq t_2.$$

Corolario 2.2. La función de densidad conjunta de $(X_{(1)}, X_{(n)})$ es

$$g(t_1, t_2) = \frac{n!}{(n-2)!} f(t_1) [F(t_2) - F(t_1)]^{n-2} f(t_2), \quad t_1 \leq t_2.$$

Ejemplo (Distribución uniforme). Sea $(X_1, \dots, X_n)$ una m.a.s. (n) de una población $X \equiv U(0, 1)$. Tenemos que la función de distribución de X es

$$F(x) = \begin{cases} 0, & x \leq 0 \\ x, & 0 < x \leq 1 \\ 1, & 1 \leq x \end{cases}.$$

De esta manera, tendremos que la función de distribución de $X_{(n)}$ será

$$f_{X_{(n)}}(x) = nx^{n-1}, \quad x \in [0, 1].$$

De esta forma, tenemos que $X_{(n)} \sim \text{Beta}(n, 1)$. De forma análoga, tenemos que

$$f_{X_{(1)}}(x) = n(1-x)^{n-1}, \quad x \in [0, 1].$$

Por tanto, $X_{(1)} \sim \text{Beta}(1, n)$. En general, para $r \in \{1, \dots, n\}$ se tiene que

$$f_{X_{(r)}}(x) = \frac{n!}{(r-1)!(n-r)!} x^{r-1} (1-x)^{n-r}, \quad x \in [0, 1].$$

Por tanto, $X_{(r)} \sim \text{Beta}(r, n-r+1)$. Finalmente, es fácil ver que

$$f_{(X_{(1)}, X_{(n)})}(x, y) = n(n-1)(y-x)^{n-2}, \quad 0 < x < y < 1.$$

Ejemplo (Rango muestral). Calculemos la distribución del rango muestral. Se define rango muestral como $R = X_{(n)} - X_{(1)}$. Sea $H = \frac{X_{(n)} + X_{(1)}}{2}$. Tenemos que

$$\begin{cases} R = X_{(n)} - X_{(1)} \\ H = \frac{X_{(n)} + X_{(1)}}{2} \end{cases} \quad \begin{cases} X_{(n)} = H + \frac{R}{2} \\ X_{(1)} = H - \frac{R}{2} \end{cases} \quad \Rightarrow J = \begin{vmatrix} 1 & -\frac{1}{2} \\ 1 & \frac{1}{2} \end{vmatrix} = 1.$$

Por otro lado, si $0 < x < y < 1$ se tiene que $\frac{r}{2} < h < 1 - \frac{r}{2}$. Así, tenemos que la función de densidad conjunta será

$$g(R, H)(r, h) = f_{(X_{(1)}, X_{(n)})}\left(h - \frac{r}{2}, h + \frac{r}{2}\right) = 1 - n(n-1)r^{n-2},$$

por lo que la función de densidad marginal de R es

$$g_R(r) = n(n-1)r^{n-2}(1-r).$$

Por tanto, tenemos que $R \sim \text{Beta}(n-1, 2)$.

Ejemplo. Sea $(X_1, \dots, X_n)$ una m.a.s. (n) de una población X tal que $F(x) = P(X \leq x)$. Calculemos la distribución de $U = F(X)$ y de $U_R = F(X_{(r)})$. En primer lugar, tendremos que

$$G_U(u) = P(U \leq u) = P(F(x) \leq u) = P(X \leq F^{-1}(u)) = F(F^{-1}(u)) = u, \quad 0 < u < 1.$$

Así, tendremos que $F(X) \sim U(0, 1)$. Por otro lado, se tiene que

$$\begin{aligned} G_{U_R}(u) &= P(U_R \leq u) = P(F(X_{(r)}) \leq u) = P(X_{(r)} \leq F^{-1}(u)) = F_{X_{(r)}}(F^{-1}(u)) \\ &= \sum_{j=r}^n \binom{n}{j} F(F^{-1}(u))^j (1 - F(F^{-1}(u)))^{n-j} = \sum_{j=r}^n \binom{n}{j} u^j (1-u)^{n-j}. \end{aligned}$$

De esta forma, $U_R = F(X_{(r)})$ es el estadístico ordenado de orden r asociado a una m.a.s. (n) de una población $U = F(x) \sim U(0, 1)$.

Capítulo 3

Reducción de datos

3.1. Estadísticos suficientes y minimal suficientes

Sea $(\Omega, \mathcal{A}, P)$ el espacio de probabilidad asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X : \Omega \rightarrow \mathbb{R}$ y su modelo estadístico asociado $(\chi, \mathcal{B}, F_\theta)_{\theta \in \Theta \subset \mathbb{R}^t}$, $\mathcal{B} = \mathcal{B}(\mathbb{R})$ y $(X_1, \dots, X_n)$ una m.a.s. (n) de X .

Definición 3.1 (Estadístico suficiente). Decimos que $T = T(X_1, \dots, X_n) : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es un **estadístico suficiente** para θ si la distribución de probabilidad de la muestra condicionada por T es independiente de θ .

Ejemplo. Supongamos que $X \sim \text{Ber}(\theta)$. En este caso, tenemos que $f_\theta(x) = \theta^x (1 - \theta)^{1-x}$ para $x \in \{0, 1\}$. En nuestro caso tenemos que $\mu = \theta$ y $\sigma^2 = \theta(1 - \theta)$. Veamos que $T = \sum_{i=1}^n X_i \sim \text{Ber}(n, \theta)$ es suficiente para θ . Tenemos que su función de densidad será

$$f_\theta(t) = \binom{n}{t} \theta^t (1 - \theta)^{n-t}, \quad t \in \{0, \dots, n\}.$$

De esta forma, tendremos que si $\sum_{i=1}^n X_i = t$ entonces

$$\begin{aligned} P_\theta \left(X_1 = x_1, \dots, X_n = x_n \mid \sum_{i=1}^n X_i = t \right) &= \frac{P_\theta \left(X_1 = x_1, \dots, X_n = t - \sum_{i=1}^{n-1} x_i \right)}{P \left(\sum_{i=1}^n X_i = t \right)} \\ &= \frac{\theta^t (1 - \theta)^{n-t}}{\binom{n}{t} \theta^t (1 - \theta)^{n-t}} = \frac{1}{\binom{n}{t}}, \quad t = 0, \dots, n. \end{aligned}$$

Teorema 3.1 (Teorema de factorización de Fisher). $T = T(X_1, \dots, X_n) : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es un estadístico suficiente para θ si y solo si existen funciones reales positivas $h : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g_\theta : \mathbb{R}^m \rightarrow \mathbb{R}$ tales que

$$f_\theta(x_1, \dots, x_n) = h(x_1, \dots, x_n) g_\theta(T(x_1, \dots, x_n)),$$

donde $f_\theta(x_1, \dots, x_n)$ es la función de masa de la muestra.

Demostración. Demostramos solo el caso discreto. En primer lugar, si $T = T(X_1, \dots, X_n)$ es un estadístico suficiente para θ , entonces $f_\theta(x_1, \dots, x_n | t)$ es independiente de θ . Así, tendremos que si $T(x_1, \dots, x_n) = t$, entonces

$$f_\theta(x_1, \dots, x_n) = f_\theta(x_1, \dots, x_n | t) f_\theta(t) = h(x_1, \dots, x_n) g_\theta(T(x_1, \dots, x_n)).$$

Recíprocamente, si $T(x_1, \dots, x_n) = t$, tendremos que

$$\begin{aligned} f_\theta(x_1, \dots, x_n | t) &= \frac{f_\theta(x_1, \dots, x_n)}{f_\theta(t)} = \frac{f_\theta(x_1, \dots, x_n)}{\sum_{(y_1, \dots, y_n), T(y_1, \dots, y_n)=1} f_\theta(y_1, \dots, y_n)} \\ &= \frac{h(x_1, \dots, x_n) g_\theta(t)}{\sum_{(y_1, \dots, y_n), T(y_1, \dots, y_n)=1} h(y_1, \dots, y_n) g_\theta(t)} \\ &= \frac{h(x_1, \dots, x_n)}{\sum_{(y_1, \dots, y_n), T(y_1, \dots, y_n)=1} h(y_1, \dots, y_n)}, \end{aligned}$$

que es independiente de θ . $\square$

Ejemplo (Bernoulli). Encontremos un estadístico suficiente para θ si $X \sim \text{Bin}(1, \theta)$. Tenemos que

$$f_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} = g_\theta\left(\sum_{i=1}^n x_i\right) h(x_1, \dots, x_n).$$

De esta forma, $T = \sum_{i=1}^n X_i$ es un estadístico suficiente para θ , como habíamos visto antes.

Ejemplo (Poisson). Encontramos un estadístico suficiente para θ si $X \sim \text{Poisson}(\theta)$. Tenemos que

$$f_\theta(x_1, \dots, x_n) = \prod_{i=1}^n e^{-\theta} \frac{\theta^{x_i}}{x_i!} = e^{-n\theta} \frac{\theta^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}.$$

Podemos tomar $T = \sum_{i=1}^n X_i$ de forma que

$$g_\theta(t) = e^{-n\theta} \theta^t \quad \text{y} \quad h(x_1, \dots, x_n) = \left(\prod_{i=1}^n x_i! \right)^{-1}.$$

Observación. La propia muestra y el estadístico ordenado $(X_{(1)}, \dots, X_{(n)})$ son estadísticos suficientes. La primera es trivial. Por otro lado, supongamos que dada una m.a.s. (n) de X ,

donde $\tilde{f}_\theta$ es la función de densidad de X , tendremos que

$$f_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \tilde{f}_\theta(x_i) = \frac{1}{n!} g_\theta(x_{(1)}, \dots, x_{(n)}),$$

donde g_θ es la función de densidad del estadístico ordenado.

Proposición 3.1. Sea $(X_1, \dots, X_n)$ una m.a.s (n) de X .

1. Si $T = T(X_1, \dots, X_n)$ es suficiente para θ , entonces cualquier biyección $S = S(T)$ también es suficiente para θ .
2. Si $T = T(X_1, \dots, X_n)$ y $S = S(X_1, \dots, X_n)$ son suficientes para θ , entonces también es suficiente para θ el estadístico (T, S) .

Demostración. Sea $(X_1, \dots, X_n)$ una m.a.s (n) de X .

1. Como T es suficiente tendremos que f_θ se puede factorizar de la forma

$$f_\theta(x_1, \dots, x_n) = h(x_1, \dots, x_n) g_\theta(T(x_1, \dots, x_n)) = h(x_1, \dots, x_n) g_\theta(S).$$

Por tanto, obtenemos también la factorización en función de S , por lo que S también es suficiente para θ .

2. Mirar la demostración en el libro.

□

Ejemplo (Normal). Sea $(X_1, \dots, X_n)$ una m.a.s. de $X \sim N(\theta, \sigma_0)$, con σ_0 conocida. Veamos que $T = \bar{X}$ es un estadístico suficiente para θ :

$$\begin{aligned} f_\theta(x_1, \dots, x_n) &= \prod_{i=1}^n \frac{1}{\sigma_0 \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x_i - \theta}{\sigma_0} \right)^2} = \frac{1}{(\sigma_0 \sqrt{2\pi})^n} e^{-\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \theta}{\sigma_0} \right)^2} \\ &= \frac{1}{(\sigma_0 \sqrt{2\pi})^n} e^{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n x_i^2} e^{\frac{n\theta}{\sigma_0^2} (\bar{x} - \frac{\theta}{2})}. \end{aligned}$$

De esta manera, podemos tomar $T = \bar{X}$ y nos queda que

$$h(x_1, \dots, x_n) = \frac{1}{(\sigma_0 \sqrt{2\pi})^n} e^{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n x_i^2} \quad \text{y} \quad g_\theta(T(x_1, \dots, x_n)) = e^{\frac{n\theta}{\sigma_0^2} (\bar{x} - \frac{\theta}{2})}.$$

Ahora, veamos que $T = \sum_{i=1}^n (X_i - \mu_0)^2$ es suficiente para θ si $X \sim N(\mu_0, \theta)$, con μ_0 conocida. Tendremos que

$$f_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\theta \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x_i - \mu_0}{\theta} \right)^2} = \frac{1}{(\theta \sqrt{2\pi})^n} e^{-\frac{1}{2\theta^2} \sum_{i=1}^n (x_i - \mu_0)^2}.$$

De esta forma, podemos tomar

$$h(x_1, \dots, x_n) = 1 \quad \text{y} \quad g_\theta(T(x_1, \dots, x_n)) = \frac{1}{(\theta \sqrt{2\pi})^n} e^{-\frac{1}{2\theta^2} \sum_{i=1}^n (x_i - \mu_0)^2}.$$

Finalmente, veamos que $T = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$ es suficiente para $\theta(\mu, \sigma)$, con $X \sim N(\mu, \sigma)$ y μ, σ son desconocidas.

$$\begin{aligned} f_{\theta}(x_1, \dots, x_n) &= \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_i-\mu}{\sigma}\right)^2} = \frac{1}{(\sigma\sqrt{2\pi})^n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i-\mu)^2} \\ &= \frac{1}{(\sigma\sqrt{2\pi})^n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2} e^{\frac{\mu}{\sigma^2} \sum_{i=1}^n x_i} e^{-\frac{n\mu^2}{2\sigma^2}}. \end{aligned}$$

De esta forma, podemos tomar

$$h(x_1, \dots, x_n) = 1 \quad \text{y} \quad g_{\theta}(T(x_1, \dots, x_n)) = \frac{1}{(\sigma\sqrt{2\pi})^n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2} e^{\frac{\mu}{\sigma^2} \sum_{i=1}^n x_i} e^{-\frac{n\mu^2}{2\sigma^2}}.$$

Podemos ver que en este caso $h: \mathbb{R}^n \rightarrow \mathbb{R}$ y como $T: \mathbb{R}^n \rightarrow \mathbb{R}^2$, tendremos que $g_{\theta}: \mathbb{R}^2 \rightarrow \mathbb{R}$. De esto último que hemos demostrado es fácil deducir que $T = (\bar{X}, S_n^2)$ también es suficiente.

Ejemplo (Uniforme). Si $X \sim U(0, \theta)$, entonces los estadísticos $(X_{(1)}, X_{(n)})$ y $X_{(n)}$ son suficientes para θ . En efecto, tendremos que la función de densidad de X será $\tilde{f}_{\theta} = \frac{1}{\theta}$, de forma que

$$f_{\theta}(x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\theta} = \frac{1}{\theta^n}.$$

Por otro lado, se puede comprobar que la función de densidad de $X_{(n)}$ será

$$f_{X_{(n)}}(x) = n \frac{x^{n-1}}{\theta^n}.$$

De esta forma,

$$f_{\theta}(x_1, \dots, x_n) = \frac{1}{\theta^n} = .$$

También podemos ver que el estadístico $(X_{(1)}, X_{(n)})$ es suficiente para θ si $X \sim U\left(-\frac{\theta}{2}, \frac{\theta}{2}\right)$.

Definición 3.2 (Órbita). Dado un estadístico $T = T(X_1, \dots, X_n)$ se define su **órbita** de $t \in \mathbb{R}^m$ como ^a

$$A_t = \{(x_1, \dots, x_n) \in \chi^n : T(x_1, \dots, x_n) = t\}.$$

^aRecordamos que χ^n es el espacio muestral.

Observación. Es fácil ver que $K_T = \{A_t : t \in \mathbb{R}^m\}$ es una partición disjunta de χ^n y la denominamos **partición inducida por el estadístico T** .

Notación. Decimos que K_T es **suficiente** si y solo si T es suficiente.

Definición 3.3 (Subpartición). Dados dos estadísticos $T = T(X_1, \dots, X_n)$ y $S = S(X_1, \dots, X_n)$, dedimos que K_S es una **subpartición** de K_T si $\forall B \in K_S, \exists A \in K_T$ tal que $B \subset A$. En este caso, se dice que K_T es **menos fina** que K_S .

Definición 3.4 (Estadístico minimal suficiente). Decimos que un estadístico T es **minimal suficiente** si su partición asociada es suficiente y es la menos fina entre todos los estadísticos suficientes.

Proposición 3.2. Ambos enunciados son equivalentes:

1. El estadístico T es minimal suficiente.
2. El estadístico T es suficiente y $\forall S = S(X_1, \dots, X_n)$ suficiente, $\exists \varphi$ tal que $\varphi(S) = T$.

Demostración. Demostramos $(1) \Rightarrow (2)$. Sea S suficiente. Si $S(x_1, \dots, x_n) = S(y_1, \dots, y_n) = s$, entonces tendremos que $(x_1, \dots, x_n), (y_1, \dots, y_n) \in B_s$. De esta forma, existe $A_t \in K_T$ tal que $B_s \subset A_t$, por lo que $T(x_1, \dots, x_n) = T(y_1, \dots, y_n) = t$. Así, existe φ tal que $\varphi(S) = T$ y T es suficiente.

Ahora demostramos $(2) \Rightarrow (1)$, sea S suficiente y $\varphi(S)$ tal que $\varphi(S) = T$. Tendremos que T es suficiente y si $S(x_1, \dots, x_n) = S(y_1, \dots, y_n) = s$, entonces

$$T(x_1, \dots, x_n) = \varphi(S(x_1, \dots, x_n)) = \varphi(s) = \varphi(S(y_1, \dots, y_n)) = T(y_1, \dots, y_n).$$

De esta forma, como $B_s \subset A_{\varphi(s)}$ tendremos que K_S es una subpartición de K_T . $\square$

Consideremos la siguiente relación de equivalencia

$$(x_1, \dots, x_n) \sim (y_1, \dots, y_n) \iff \frac{f_\theta(x_1, \dots, x_n)}{f_\theta(y_1, \dots, y_n)} \text{ es independiente de } \theta.$$

Teorema 3.2 (Teorema de caracterización de estadísticos suficientes). La relación de equivalencia $\sim$ induce una partición minimal suficiente y por tanto determina un estadístico minimal suficiente.

Demostración. Asignemos a cada clase del conjunto cociente un valor t y definamos el estadístico $T = T(X_1, \dots, X_n)$ tal que $(x_1, \dots, x_n) \sim (y_1, \dots, y_n)$ cuando $T(x_1, \dots, x_n) = T(y_1, \dots, y_n) = t$. Demostremos que T es suficiente^a. Si $T(x_1, \dots, x_n) = t$, tendremos que

$$\begin{aligned} f_\theta(x_1, \dots, x_n | t) &= \frac{f_\theta(x_1, \dots, x_n)}{f_\theta(t)} = \frac{f_\theta(x_1, \dots, x_n)}{\sum_{(y_1, \dots, y_n), T(y_1, \dots, y_n)=t} f_\theta(y_1, \dots, y_n)} \\ &= \frac{1}{\sum_{(y_1, \dots, y_n) \in A_t} \frac{f_\theta(y_1, \dots, y_n)}{f_\theta(x_1, \dots, x_n)}}. \end{aligned}$$

Como este valor es independiente de θ , tenemos que T es suficiente para θ . Ahora demostramos que T es minimal. Sea $S = S(X_1, \dots, X_n)$ suficiente y $(x_1, \dots, x_n), (y_1, \dots, y_n) \in B_s$. Entonces,

$$\frac{f_\theta(x_1, \dots, x_n)}{f_\theta(y_1, \dots, y_n)} = \frac{h(x_1, \dots, x_n) g_\theta(s)}{h(y_1, \dots, y_n) g_\theta(s)} = \frac{h(x_1, \dots, x_n)}{h(y_1, \dots, y_n)}.$$

Como este valor no depende de θ , existe t tal que $(x_1, \dots, x_n), (y_1, \dots, y_n) \in A_t$, por lo que K_S es una subpartición de K_T . $\square$

^aLo hacemos solo en el caso discreto.

Observación. Podemos enunciar este teorema de una forma más entendible: un estadístico T es minimal suficiente si y solo si

$$\frac{f_\theta(x_1, \dots, x_n)}{f_\theta(y_1, \dots, y_n)} \text{ no depende de } \theta \iff T(x_1, \dots, x_n) = T(y_1, \dots, y_n).$$

Ejemplo. Veamos que $T(X_1, \dots, X_n) = \sum_{i=1}^n X_i$ es minimal suficiente para θ si $X \sim \text{Bin}(1, \theta)$.

En efecto, tenemos que

$$f_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i}.$$

Tenemos que

$$\frac{f_\theta(x_1, \dots, x_n)}{f_\theta(y_1, \dots, y_n)} = \left(\frac{\theta}{1-\theta} \right)^{\sum_{i=1}^n x_i - \sum_{i=1}^n y_i}$$

es independiente de θ sólomente cuando $\sum_{i=1}^n x_i = \sum_{i=1}^n y_i$.

3.2. Familia exponencial k -paramétrica

Sea $(\Omega, \mathcal{A}, P)$ es espacio probabilístico asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X : \Omega \rightarrow \mathbb{R}$ y su modelo estadístico asociado $(\chi, \mathcal{B}, F_\theta)_{\theta \in \Theta \subset \mathbb{R}^l}$, $\mathcal{B} = \mathcal{B}(\mathbb{R})$ y $(X_1, \dots, X_n)$ una m.a.s. (n) de X .

Definición 3.5 (Familia exponencial k -paramétrica). La distribución de X pertenece a la familia exponencial k -paramétrica si

$$f_\theta(x) = c(\theta) h(x) e^{\sum_{j=1}^k q_j(\theta) T_j(x)}.$$

Observación. Si X pertenece a la familia exponencial k -paramétrica, tendremos que

$$f_\theta(x_1, \dots, x_n) = c(\theta)^n \prod_{i=1}^n h(x_i) e^{\sum_{j=1}^k q_j(\theta) \sum_{i=1}^n T_j(x_i)}.$$

Por el teorema de factorización, $\left(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i) \right)$ es suficiente para θ y se le denomina el **estadístico natural suficiente**.

Teorema 3.3. Si existen $\theta_1, \dots, \theta_k \in \Theta \subset \mathbb{R}^l$ tales que los vectores $c_r = (q_1(\theta_r), \dots, q_k(\theta_r))$, $r = 1, \dots, k$, son linealmente independientes. Entonces, el estadístico natural suficiente de la familia exponencial k -paramétrica es minimal.

Demostración. Tenemos que

$$\begin{aligned} \frac{f_{\theta}(x_1, \dots, x_n)}{f_{\theta}(y_1, \dots, y_n)} &= \frac{c(\theta)^n \prod_{i=1}^n h(x_i) e^{\sum_{j=1}^k q_j(\theta) \sum_{i=1}^n T_j(x_i)}}{c(\theta)^n \prod_{i=1}^n h(y_i) e^{\sum_{j=1}^k q_j(\theta) \sum_{i=1}^n T_j(y_i)}} \\ &= \frac{\prod_{i=1}^n h(x_i)}{\prod_{i=1}^n h(y_i)} e^{\sum_{j=1}^k q_j(\theta) (\sum_{i=1}^n T_j(x_i) - \sum_{i=1}^n T_j(y_i))}. \end{aligned}$$

Este valor es independiente de θ si y solo si

$$\sum_{j=1}^k q_j(\theta) \left(\sum_{i=1}^n T_j(x_i) - \sum_{i=1}^n T_j(y_i) \right) = 0.$$

En este caso, el sistema homogéneo

$$\sum_{j=1}^k q_j(\theta_r) \left(\sum_{i=1}^n T_j(x_i) - \sum_{i=1}^n T_j(y_i) \right) = 0, \quad r = 1, \dots, k$$

solo admite la solución $\sum_{i=1}^n T_j(x_i) - \sum_{i=1}^n T_j(y_i) = 0$. Por el teorema de caracterización

de estadísticos minimales suficientes, $\left(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i) \right)$ es minimal. $\square$

Ejemplo. Antes vimos que $T = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$ era suficiente para $\theta = (\mu, \sigma)$ si $X \sim N(\mu, \sigma)$. Veamos ahora que es minimal y que $(\bar{X}, S_n^2)$ también es minimal suficiente. Tenemos que $N(\mu, \sigma)$ pertenece a la familia exponencial k -paramétrica con $k = 2$. En efecto, tenemos que

$$f_{\theta}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} = c(\theta) h(x) e^{-\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x}.$$

De esta forma, el estadístico $T = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$ es natural suficiente para θ . Además,

tenemos que $q_1(\theta) = \frac{\mu}{\sigma^2}$ y $q_2(\theta) = -\frac{1}{2\sigma^2}$. Tomando $\theta_1 = (0, 1)$ y $\theta_2 = (1, 1)$, tendremos que

$$c_1 = (q_1(\theta_1), q_2(\theta_1)) = \left(0, -\frac{1}{2} \right) \quad \text{y} \quad c_2 = (q_1(\theta_2), q_2(\theta_2)) = \left(1, -\frac{1}{2} \right).$$

Como c_1 y c_2 son linealmente independientes, tenemos que T es minimal.

Veamos ahora que $(\bar{X}, S_n^2)$ también es minimal suficiente. Tenemos que

$$S_n^2 = \frac{n}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}_i^2 \right).$$

Denotamos por $(W, Z) = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$ y

$$(F, G) = (\bar{X}, S_n^2) = \left(\frac{W}{n}, \frac{n}{n-1} \left(Z - \frac{W^2}{n} \right) \right).$$

La transformación inversa es $\left(W = nF, Z = \frac{n-1}{n}G + nF^2 \right)$, por lo que

$$J = \begin{vmatrix} n & 0 \\ 2nF & \frac{n-1}{n} \end{vmatrix} = n-1 \neq 0, \quad n \geq 2.$$

De esta forma, existe ψ_1 biyectiva tal que $(F, G) = \psi_1(W, Z)$ y como (W, Z) es minimal suficiente, $\forall S$ suficiente existe ψ_2 tal que $\psi_2(S) = (W, Z)$. Por tanto,

$$\psi_1 \circ \psi_2(S) = \psi_1(W, Z) = (F, G)$$

y (F, G) es minimal suficiente.

3.3. Estadísticos ancilario y completos

Sea $(\Omega, \mathcal{A}, P)$ es espacio probabilístico asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X : \Omega \rightarrow \mathbb{R}$ y su modelo estadístico asociado $(\chi, \mathcal{B}, F_\theta)_{\theta \in \Theta \subset \mathbb{R}^t}$, $\mathcal{B} = \mathcal{B}(\mathbb{R})$, y $(X_1, \dots, X_n)$ una m.a.s. (n) de X .

Definición 3.6 (Estadístico ancilario). Un estadístico $U = U(X_1, \dots, X_n)$ es **ancilario** para θ si su distribución en el muestreo es independiente de θ .

Ejemplo. Si $(X_1, \dots, X_n)$ es una m.a.s. (n) de $X \sim N(\mu, \sigma_0)$, con σ_0 conocida, entonces $U(X_1, \dots, X_n) = X_1 - X_2 \sim N(0, \sigma_0\sqrt{2})$, que no depende de μ , por lo que U es un estadístico ancilario para μ .

Definición 3.7 (Familia de distribuciones completa). La familia de distribuciones de probabilidad $\{G_\theta(y_1, \dots, y_m)\}_{\theta \in \Theta \subset \mathbb{R}^t}$ es **completa** si para cualquier función real $h(y_1, \dots, y_m)$ con $h(Y_1, \dots, Y_m)$ medible y tal que $E_\theta[h(Y_1, \dots, Y_m)] = 0, \forall \theta \in \Theta$, se tiene que $h(Y_1, \dots, Y_m) =^{cs} 0$ ^a.

^aEsto quiere decir que $h(y_1, \dots, y_m) = 0$ salvo en un conjunto de probabilidad cero, calculada a partir de $G_\theta(y_1, \dots, y_m), \forall \theta \in \Theta$.

Ejemplo. La familia de distribuciones de probabilidad $Bin(n, \theta)$ es completa. En efecto, sea $Y \sim Bin(n, \theta)$ y $h(Y)$ una función real como se describe en la definición. Entonces,

$$E_\theta[h(Y)] = \sum_{i=1}^n h(i) \binom{n}{i} \theta^i (1-\theta)^{n-i} = (1-\theta)^n \sum_{i=1}^n h(i) \binom{n}{i} \left(\frac{\theta}{1-\theta} \right)^i = 0, \quad \forall \theta \in (0, 1).$$

Esto es un polinomio de grado n en $\frac{\theta}{1-\theta} \in (0, \infty)$, por lo que para que sea nulo debe ser que $h(i) = 0, \forall i = 1, \dots, n$. De esta forma, $h(Y) =^{cs} 0$.

Ejemplo. La familia de distribuciones de probabilidad $N(0, \theta)$ no es completa. En efecto, sea $Y \sim N(0, \theta)$ y $h(Y) = Y$. Entonces,

$$E_\theta[h(Y)] = E_\theta[Y] = 0, \forall \theta > 0.$$

Sin embargo, $h(Y) = Y$ no es idénticamente nula casi seguro.

Definición 3.8 (Estadístico completo). Decimos que el estadístico $T = T(X_1, \dots, X_n)$ es **completo** si su distribución en el muestreo es una familia de distribuciones de probabilidad completa.

Ejemplo. Si $X \sim \text{Bin}(1, \theta)$, entonces $T = \sum_{i=1}^n X_i \sim \text{Bin}(n, \theta)$ es completo, por lo que hemos visto anteriormente.

Ejemplo. Si $X \sim N(\theta, \theta)$, el estadístico $T = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$ no es completo. En efecto, podemos ver que

$$h(T) = 2 \left(\sum_{i=1}^n X_i \right)^2 - (n+1) \sum_{i=1}^n X_i^2,$$

cumple que

$$E_\theta[h(T)] = 2E_\theta \left[\left(\sum_{i=1}^n X_i \right)^2 \right] - (n+1) E_\theta \left[\sum_{i=1}^n X_i^2 \right] = 2n\theta^2(1+n) - (n+1)2n\theta^2 = 0, \forall \theta \in \Theta.$$

Hemos usado que $E_\theta \left[\left(\sum_{i=1}^n X_i \right)^2 \right] = n\theta^2(1+n)$, puesto que

$$\frac{(\sum_{i=1}^n X_i - n\theta)^2}{n\theta^2} \sim \chi_1^2.$$

También hemos usado que $E_\theta \left[\sum_{i=1}^n X_i^2 \right] = 2n\theta^2$, puesto que

$$\sum_{i=1}^n \frac{(X_i - \theta)^2}{\theta^2} \sim \chi_n^2.$$

De esta forma, tenemos que $E_\theta[h(T)] = 0, \forall \theta \in \Theta$, pero no se cumple que $h(T) = 0$ casi seguro.

Proposición 3.3. Si $S = S(X_1, \dots, X_n)$ es suficiente y completo, entonces es minimal suficiente.

Demostración. Supongamos que $T = T(X_1, \dots, X_n)$ es minimal suficiente, entonces tendremos que por ser S completo, $S \stackrel{cs}{=} E[S|T]$, por lo que S es función de T . $\square$

Teorema 3.4 (Existencia de estadísticos completos). El estadístico natural

$$\left(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i) \right)$$

de la familia de distribuciones exponencial k -paramétrica,

$$\left\{ f_\theta(x) = c(\theta) h(x) e^{\sum_{j=1}^k q_j(\theta) T_j(x)} \right\}_{\theta \in \Theta \subset \mathbb{R}^l},$$

es completo si la imagen de la aplicación $q = (q_1(\theta), \dots, q_k(\theta)) : \Theta \rightarrow \mathbb{R}^k$ contiene un rectángulo abierto de $\mathbb{R}^k$.

Ejemplo. Si $X \sim N(\theta, \theta)$, tenemos que $q = (q_1(\theta), q_2(\theta)) = \left(\frac{1}{\theta}, -\frac{1}{2\theta^2} \right)$. Entonces,

$$q_2(\theta) = -\frac{1}{2} q_1(\theta)^2, \quad \forall \theta > 0.$$

Al tratarse de una rama de una parábola, tenemos que no contiene ningún abierto de $\mathbb{R}^2$.

Teorema 3.5 (Teorema de Basu). Si $T = T(X_1, \dots, X_n)$ es un estadístico suficiente y completo, y $U = U(X_1, \dots, X_n)$ es un estadístico ancilar, entonces T y U son independientes.

Demostración. Como $T = T(X_1, \dots, X_n)$ es suficiente, tenemos que $f(x_1, \dots, x_n|t)$ es independiente de θ . Así, tenemos que

$$f(u|t) = \sum_{(x_1, \dots, x_n) : U(x_1, \dots, x_n) = u} f(x_1, \dots, x_n|t)$$

es independiente de θ . Además, como $T = T(X_1, \dots, X_n)$ es completo y la función $h(t) = f(u|t) - f(u)$ tiene media 0, $\forall \theta \in \Theta$, tendremos que respecto a la distribución de $T \sim f_\theta(t)$, $f(u|t) \stackrel{cs}{=} f(u)$. $\square$

Ejemplo. Si $X \sim U(0, \theta)$, entonces $X_{(n)}$ y $\frac{X_{(1)}}{X_{(n)}}$ son independientes.

3.4. Principio de reducción de datos

Sea $(\Omega, \mathcal{A}, P)$ es espacio probabilístico asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X : \Omega \rightarrow \mathbb{R}$ y su modelo estadístico asociado $(\chi, \mathcal{B}, F_\theta)_{\theta \in \Theta \subset \mathbb{R}^l}$, $\mathcal{B} = \mathcal{B}(\mathbb{R})$, y $(X_1, \dots, X_n)$ una m.a.s. (n) .

La idea es considerar la distribución de probabilidad de la muestra, no como función de $(x_1, \dots, x_n)$, sino como función del parámetro desconocido θ .

Definición 3.9 (Función de verosimilitud). Supuesto que se ha observado un valor muestral $(x_1, \dots, x_n)$, la función θ definida mediante $L(\theta|x_1, \dots, x_n) := f(x_1, \dots, x_n|\theta)$, se llama **función de verosimilitud**, siendo $f(x_1, \dots, x_n|\theta)$ la función de densidad de la muestra.

Definición 3.10 (Principio de verosimilitud). Si $\vec{x} = (x_1, \dots, x_n)$ e $\vec{y} = (y_1, \dots, y_n)$ son dos puntos muestrales, tales que existe una constante $c(\vec{x}, \vec{y})$ verificando que $L_1(\theta|\vec{x}) = c(\vec{x}, \vec{y}) L_2(\theta|\vec{y})$, entonces la evidencia estadística que suministran ambos puntos debe ser idéntica.

Observación. Podemos observar varias cosas:

- La evidencia estadística se toma en un sentido amplio y no se define, así esta puede ser un estadístico muestral, un estadístico suficiente, un intervalo de confianza, etc.
- Las dos funciones de verosimilitud no tienen por qué estar definidas en el mismo espacio muestral.
- Realmente la evidencia estadística depende del experimento bajo estudio E y del punto observado, por lo que puede expresarse como $Ev(E, \vec{x})$, con $E = (\chi^n, f(\vec{x}|\theta))_{\theta \in \Theta \subset \mathbb{R}^t}$.

Ejemplo. La evidencia que se obtiene de un modelo *Binomial* (n, θ) sobre θ , cuando se observan t éxitos en n repeticiones, es la misma que la obtenida de un modelo binomial negativo *BN* (n, θ) , siempre que se suponga que se han realizado n repeticiones hasta obtener t éxitos. En efecto, tenemos que en el primer caso

$$f(t|\theta) = \binom{n}{t} \theta^t (1 - \theta)^{n-t}.$$

En el segundo caso tenemos que

$$g(n|\theta) = \binom{n-1}{t-1} \theta^t (1 - \theta)^{n-t}.$$

Así, podemos aplicar el principio de verosimilitud con $c(t, n) = \frac{n}{t}$.

Ejemplo. Los procedimientos bayesianos, por estar basados en la distribución de probabilidad final o a posteriori, satisfacen el principio de verosimilitud, ya que si $\vec{x} = (x_1, \dots, x_n)$ e $\vec{y} = (y_1, \dots, y_n)$ satisfacen el principio de verosimilitud, entonces $\pi_1(\theta|\vec{x}) = \pi_2(\theta|\vec{y})$.

Definición 3.11 (Principio de suficiencia). En un experimento $E = (\chi^n, f(\vec{x}|\theta))_{\theta \in \Theta \subset \mathbb{R}^t}$, si $T = T(X)$ es un estadístico suficiente para θ y se tiene que $T(\vec{x}) = T(\vec{y})$, entonces $Ev(E, \vec{x}) = Ev(E, \vec{y})$.

Ejemplo. En un experimento consistente en la repetición de n pruebas de Bernoulli, la evidencia estadística que se obtiene de dos puntos muestrales con el mismo número de éxitos es la misma.

Definición 3.12 (Principio de condicionalidad). Dados dos experimentos $E_1 = (\chi^n, f_1(\vec{x}|\theta))_{\theta \in \Theta \subset \mathbb{R}^l}$ y $E_2 = (\chi^m, f_2(\vec{y}|\theta))_{\theta \in \Theta \subset \mathbb{R}^l}$, considérese el experimento mixto, en el que dependiendo de una v.a. J , que toma valor 1 o 2 con probabilidad $\frac{1}{2}$, se observa el experimento $E = (\chi^n \cup \chi^m \times \{1, 2\}, f(\vec{x}, j|\theta))_{\theta \in \Theta \subset \mathbb{R}^l}$ representado por la v.a. (Z, J) tal que

$$Z = \begin{cases} X, & J = 1 \\ Y, & J = 2 \end{cases}, \quad f(\vec{x}, 1|\theta) = \frac{1}{2}f_1(\vec{x}|\theta) \quad \text{y} \quad f(\vec{y}, 2|\theta) = \frac{1}{2}f_2(\vec{y}|\theta).$$

Entonces $Ev(E, (\vec{x}, 1)) = Ev(E_1, \vec{x})$ y $Ev(E, (\vec{y}, 2)) = Ev(E_2, \vec{y})$.

Observación. El principio de condicionalidad dice algo bastante intuitivo: los mecanismos aleatorios que no dependen del valor a determinar, θ , no proporcionan evidencia sobre él. Por otro lado, el valor $\frac{1}{2}$ (probabilidad con la que toma valores la v.a. J) puede ser sustituido por otro cualquiera sin modificar el significado del principio de condicionalidad; lo sustancial es que la distribución de la v.a. no dependa de θ .

Teorema 3.6 (Teorema de Birnbaum). El principio de verosimilitud es equivalente a los principios de suficiencia y condicionalidad.

Observación. El teorema de Birnbaum es importante desde el punto de vista de los fundamentos de la Estadística. Muchos de los procedimientos estadísticos usuales violan el principio de verosimilitud, en concreto los procedimientos que se basan en la distribución en el muestreo de un estadístico pueden hacerlo.

Por ejemplo, si se pasa de un modelo binomial a uno binomial negativo, la función de masa cambia y por tanto las propiedades del estimador también pueden cambiar. Sin embargo, a la luz del teorema esto significa contradecir el principio de suficiencia, que es compartido por toda aproximación a la inferencia, o el principio de condicionalidad, que parece bastante aséptico.

El teorema de Birnbaum constituye uno de los motivos por los que el principio de verosimilitud no es universalmente aceptado, a pesar de que como se verá, la función de verosimilitud posee muchas buenas propiedades estadísticas.

Capítulo 4

Estimación puntual paramétrica

4.1. Propiedades de los estimadores

Sea $(\Omega, \mathcal{A}, P)$ el espacio probabilístico asociado a un experimento aleatorio $\mathcal{E}$, una variable aleatoria observable $X : \Omega \rightarrow \mathbb{R}$ y su modelo estadístico asociado $(\chi, \mathcal{B}, F_\theta)_{\theta \in \Theta \subset \mathbb{R}^t}$, $\mathcal{B} = \mathcal{B}(\mathbb{R})$ y $(X_1, \dots, X_n)$ una m.a.s. (n) de X .

Definición 4.1 (Estimador). Un **estimador** del parámetro θ es un estadístico $T = T(X_1, \dots, X_n) : \chi^n \rightarrow \Theta$ que se utiliza para determinar el valor desconocido θ .

4.1.1. Estimadores centrados

Definición 4.2 (Estimador centrado). Decimos que un estadístico $T = T(X_1, \dots, X_n) : \chi^n \rightarrow \Theta$ es un **estimador centrado** para θ cuando $E_\theta[T] = \theta$.

Definición 4.3 (Sesgo). En general, se llama **sesgo** de un estimador a la diferencia $b(T, \theta) = E_\theta[T] - \theta$.

Observación. En el caso de los estimadores centrados tendremos que el sesgo es $b(T, \theta) = 0$.

Ejemplo. Es fácil comprobar que $(\bar{X}, S^2)$ es un estimador centrado de $\theta = (\mu, \sigma^2)$.

Ejemplo. Es fácil ver que $\sigma_n^2 = b_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ es un estimador centrado de $h(\theta) = \frac{n-1}{n} \sigma^2$ y $b(\sigma_n^2, \sigma^2) = -\frac{\sigma^2}{n}$.

Observación. Podemos hacer un par de observaciones.

1. Puede que no exista un estimador centrado de θ . En efecto, para muestras de tamaño uno de una población *Bernoulli* (θ) con $\theta \in (0, 1)$, no existe estimador centrado para $h(\theta) = \theta^2$. Si lo hubiera, tendríamos que

$$T(1)\theta + T(0)(1-\theta) = \theta^2, \forall \theta \in \Theta$$

lo que es imposible puesto que un polinomio de grado dos puede tener como mucho dos raíces distintas.

2. Si T es un estimador centrado para θ , en general $h(T)$, con h medible, no tiene por qué ser centrado para $h(\theta)$. En efecto, para muestras de tamaño uno de una población de $Bernoulli(\theta)$, con $\theta \in [0, 1]$, existe un estimador centrado para $h(\theta) = \theta$. Como este debe ser

$$T(1)\theta + T(0)(1 - \theta) = \theta, \quad \forall \theta \in \Theta,$$

tendremos que $T(0) = 0$ y $T(1) = 1$. Este ejemplo y el anterior demuestran lo deseado.

3. A pesar de que exista un estimador centrado para θ , puede ser que no tenga sentido. En efecto, para una población de $Poisson(\theta)$, con $\theta \in (0, \infty)$, si se quiere estimar la función $h(\theta) = e^{-3\theta}$ con muestras de tamaño uno mediante un estimador centrado T , este debe cumplir

$$\sum_{i=0}^{\infty} e^{-\theta} \frac{\theta^i}{i!} T(i) = e^{-3\theta} \iff \sum_{i=0}^{\infty} \frac{\theta^i}{i!} T(i) = \sum_{i=0}^{\infty} \frac{\theta^i}{i!} (-2)^i.$$

Así, tenemos que $T(i) = (-2)^i$ es el estimador centrado, pero este es negativo para los valores impares de i , por lo que no es un estimador de $h(\theta)$.

4. A pesar de que exista un estimador centrado para θ , puede que su varianza sea muy grande y no sea adecuado para la estimación.

Observación. Si T_j para $j \in \mathbb{N}$ es una sucesión de estimadores centrados para θ , entonces $\bar{T}_k = \frac{1}{k} = \frac{1}{k} \sum_{j=1}^k T_j$ es un estimador centrado para θ . Si además los estimadores T_j son independientes y $V_{\theta}(T_j) < \sigma^2 < \infty, \forall j \in \mathbb{N}$, entonces

$$V_{\theta}(\bar{T}_k) \leq \frac{\sigma^2}{k} \xrightarrow{k \rightarrow \infty} 0 \Rightarrow \bar{T}_k \xrightarrow{P, k \rightarrow \infty} \theta \text{ (Teorema de Markov).}$$

4.1.2. Estimadores consistentes

Definición 4.4 (Estimadores consistentes). Una sucesión de estimadores $T_n = T(X_1, \dots, X_n)$ es **consistente** para el parámetro θ si $T_n \xrightarrow{P} \theta, \forall \theta \in \Theta$, es decir

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P_{\theta}(|T_n - \theta| \leq \varepsilon) = 1, \quad \forall \theta \in \Theta.$$

Ejemplo. Si el parámetro θ es el momento poblacional respecto al origen de orden k , es decir $\theta = \alpha_k$, entonces el momento muestral respecto al origen de orden k , $a_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ es un estimador consistente.

Proposición 4.1 (Condición suficiente). Si $T_n = T(X_1, \dots, X_n)$ es una sucesión de estimadores tales que $\forall \theta \in \Theta, E_{\theta}[T_n] \xrightarrow{n \rightarrow \infty} \theta$ y $V_{\theta}(T_n) \xrightarrow{n \rightarrow \infty} 0$, entonces T_n es consistente para θ .

Demostración. Ya que para $\forall \varepsilon > 0$ tenemos que

$$P_{\theta} (|T_n - \theta| > \varepsilon) \leq \varepsilon^{-2} E_{\theta} \left[(T_n - \theta)^2 \right],$$

y sumando y restando $E_{\theta} [T_n]$ en la expresión del cuadrado del segundo miembro obtenemos que

$$P_{\theta} (|T_n - \theta| > \varepsilon) \leq \varepsilon^{-2} \left[V_{\theta} (T_n) + (E_{\theta} [T_n] - \theta)^2 \right] \xrightarrow{n \rightarrow \infty} 0.$$

□

Observación. Las hipótesis de la proposición anterior son equivalentes a decir que $\lim_{n \rightarrow \infty} ECM (T_n) = 0$. En efecto, tenemos que

$$E_{\theta} \left[(T_n - \theta)^2 \right] = V_{\theta} (T_n) + (E_{\theta} [T_n] - \theta)^2.$$

Ejemplo. Con una m.a.s. (n) de una población *Bernoulli* (θ) , el estimador

$$T_n = \frac{1}{n+2} \left(\sum_{i=1}^n X_i + 1 \right),$$

es consistente para θ . En efecto, tenemos que

$$\lim_{n \rightarrow \infty} E_{\theta} [T_n] = \lim_{n \rightarrow \infty} \frac{n\theta + 1}{n+2} = \theta \quad \text{y} \quad \lim_{n \rightarrow \infty} V (T_n) = \lim_{n \rightarrow \infty} \frac{n\theta(1-\theta)}{(n+2)^2} = 0.$$

Por la proposición anterior tenemos que es consistente.

4.1.3. Estimadores bayesianos

En la aproximación bayesiana θ es una variable aleatoria con distribución inicial (o a priori) dada por una función de masa o de densidad $\pi(\theta)$. Cuando se observa una muestra se calcula la distribución final (o a posteriori),

$$\pi(\theta|x_1, \dots, x_n) = \frac{\pi(\theta) f(x_1, \dots, x_n|\theta)}{m(x_1, \dots, x_n)} \quad \text{con} \quad m(x_1, \dots, x_n) = \int_{\Theta} \pi(\theta) f(x_1, \dots, x_n|\theta) d\theta,$$

donde decimos que m es la **distribución predictiva**. La idea es que antes de tomar la muestra, la información sobre θ viene dada por $\pi(\theta)$ y tras la experimentación se debe utilizar $\pi(\theta|x_1, \dots, x_n)$. El **estimador bayesiano** de θ es toda la distribución final y por extensión cualquier medida de centralización correspondiente a esta distribución.

Ejemplo (Familias conjugadas). Si $(X_1, \dots, X_n)$ es una m.a.s. (n) de $X \sim \text{Bin}(1, \theta)$ y $\theta \sim U(0, 1)$, entonces tendremos que

$$\pi(\theta|x_1, \dots, x_n) = \frac{\theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i} I_{(0,1)}(\theta)}{\int_0^1 \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i} d\theta} = \frac{\theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i} I_{(0,1)}(\theta)}{B(\sum_{i=1}^n x_i + 1, n - \sum_{i=1}^n x_i + 1)}.$$

Así, tenemos que $\pi(\theta|x_1, \dots, x_n) \sim \text{Beta}\left(\sum_{i=1}^n x_i + 1, n - \sum_{i=1}^n x_i + 1\right)$. En general se tiene que

$$\pi(\theta|x_1, \dots, x_n) \sim \text{Beta}\left(\sum_{i=1}^n x_i + \alpha, n - \sum_{i=1}^n x_i + \beta\right)$$

si $(X_1, \dots, X_n)$ es una m.a.s. (n) de $X \sim \text{Bin}(1, \theta)$ y $\theta \sim \text{Beta}(\alpha, \beta)$. En este caso, se dice que la familia de distribuciones iniciales $\text{Beta}(\alpha, \beta)$ es **conjugada** de la familia de distribuciones de probabilidad $X \sim \text{Bin}(1, \theta)$. Además,

$$E[\theta|x_1, \dots, x_n] = \frac{\sum_{i=1}^n x_i + \alpha}{n + \alpha + \beta} = \frac{n}{n + \alpha + \beta} \bar{x} + \frac{\alpha + \beta}{n + \alpha + \beta} \frac{\alpha}{\alpha + \beta}.$$

Con frecuencia suele ocurrir que la información muestral domina a la información inicial, cuando n es suficientemente grande.

Ejemplo. Si $(X_1, \dots, X_n)$ es una m.a.s. (n) de $X \sim N(\theta, \sigma)$ con σ conocida y $\theta \sim N(\mu_0, \sigma_0)$, entonces $\pi(\theta|x_1, \dots, x_n) \sim N(\mu_1, \sigma_1)$ con

$$\mu_1 = \frac{\frac{\mu_0}{\sigma_0^2} + \frac{\bar{x}}{\frac{\sigma^2}{n}}}{\frac{1}{\sigma_0^2} + \frac{1}{\frac{\sigma^2}{n}}} = \frac{\sigma^2}{\sigma^2 + n\sigma_0^2} \mu_0 + \frac{n\sigma_0^2}{\sigma^2 + n\sigma_0^2} \bar{x} \quad \text{y} \quad \sigma_1 = \sqrt{\frac{1}{\frac{1}{\sigma_0^2} + \frac{1}{\frac{\sigma^2}{n}}}}.$$

Apéndice A

Convergencia de variables aleatorias

A.1. Convergencia en probabilidad

Definición A.1 (Convergencia en probabilidad). Dada una sucesión de variables aleatorias $\{X_n\}_{n \in \mathbb{N}}$ definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$, diremos que $\{X_n\}_{n \in \mathbb{N}}$ **converge en probabilidad** hacia la variable aleatoria X , definida en el mismo espacio de probabilidad, si

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon) = 0.$$

Observación. Una definición equivalente es

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(\omega \in \Omega : |X_n(\omega) - X(\omega)| \leq \varepsilon) = 1.$$

Notación. Si una sucesión $\{X_n\}_{n \in \mathbb{N}}$ converge en probabilidad a X lo escribiremos

$$X_n \xrightarrow{P} X.$$

Proposición A.1 (Propiedades). Si $X_n \xrightarrow{P} X$,

- $X_n - X \xrightarrow{P} 0$.
- Si $c \in \mathbb{R}/\{0\}$, $cX_n \xrightarrow{P} cX$.
- Si Y es una variable aleatoria, $X_n Y \xrightarrow{P} XY$.
- Si $g : \mathbb{R} \rightarrow \mathbb{R}$ es continua, $g(X_n) \xrightarrow{P} g(X)$.
- Si $k \in \mathbb{R}^+$, $X_n^k \xrightarrow{P} X^k$.

Si $X_n \xrightarrow{P} X$ y $Y_n \xrightarrow{P} Y$,

- $X_n \pm Y_n \xrightarrow{P} X \pm Y$.
- $X_n Y_n \xrightarrow{P} XY$.
- Si $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ es real y continua, $g(X_n, Y_n) \xrightarrow{P} g(X, Y)$.
- Si $k, h \in \mathbb{R}^+$, $X_n^k Y_n^h \xrightarrow{P} X^k Y^h$.

Si $X_n \xrightarrow{P} X$ y $X_n \xrightarrow{P} Y$, se tiene que $P(X = Y) = 1$.

Si $X_n \xrightarrow{P} a$ e $Y_n \xrightarrow{P} b$ con $a, b \in \mathbb{R}$,

- $X_n Y_n \xrightarrow{P} ab$.
- $\frac{X_n}{Y_n} \xrightarrow{P} \frac{a}{b}$, si $b \neq 0$.

A.2. Convergencia casi segura

Definición A.2 (Convergencia casi segura). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias, definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$. Diremos que $\{X_n\}_{n \in \mathbb{N}}$ **converge casi seguro** a la variable aleatoria X , definida en el mismo espacio de probabilidad, si

$$P\left(\omega \in \Omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right) = 1.$$

Notación. Si la sucesión $\{X_n\}_{n \in \mathbb{N}}$ converge casi seguro a X , escribimos

$$X_n \xrightarrow{cs} X.$$

Proposición A.2 (Propiedades). Si $X_n \xrightarrow{cs} X$,

- $X_n - X \xrightarrow{cs} 0$.
- Si $c \in \mathbb{R}/\{0\}$, $cX_n \xrightarrow{cs} cX$.
- Si $g : \mathbb{R} \rightarrow \mathbb{R}$ es continua, $g(X_n) \xrightarrow{cs} g(X)$.
- Si $k \in \mathbb{R}^+$, $X_n^k \xrightarrow{cs} X^k$.

Si $X_n \xrightarrow{cs} X$ e $Y_n \xrightarrow{cs} Y$,

- $X_n \pm Y_n \xrightarrow{cs} X \pm Y$.
- $X_n Y_n \xrightarrow{cs} XY$.
- Si $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ es continua, $g(X_n, Y_n) \xrightarrow{cs} g(X, Y)$.
- Si $k, h \in \mathbb{R}^+$, $X_n^k Y_n^h \xrightarrow{cs} X^k Y^h$.
- $\frac{X_n}{Y_n} \xrightarrow{cs} \frac{X}{Y}$, siempre que los cocientes estén bien definidos.

Teorema A.1. Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión estrictamente creciente de variables aleatorias positivas y supongamos que $X_n \xrightarrow{P} 0$, entonces $X_n \xrightarrow{cs} 0$.

Teorema A.2. Si $X_n \xrightarrow{cs} X$, entonces $X_n \xrightarrow{P} X$.

Teorema A.3. Si $\{X_n\}_{n \in \mathbb{N}} \xrightarrow{P} X$, existe $\{X_{n_j}\}_{j \in \mathbb{N}}$ subsucesión tal que $X_{n_j} \xrightarrow{cs} X$.

A.3. Convergencia en ley

Definición A.3 (Convergencia en ley). Dada una sucesión de variables aleatorias $\{X_n\}_{n \in \mathbb{N}}$, definidas sobre el mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$, diremos que $\{X_n\}_{n \in \mathbb{N}}$ **converge en ley** a la variable aleatoria X , definida sobre el mismo espacio de probabilidad, si la correspondiente sucesión de funciones de distribución de las X_n , $\{F_n\}_{n \in \mathbb{N}}$ converge puntualmente hacia la función de distribución F de X en todo punto de continuidad de la función. Es decir,

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

para todos los puntos de continuidad de F .

Observación. La convergencia puntual de F_n a F no es suficiente para garantizar la convergencia, es necesario ver que la función límite sea función de distribución.

Notación. Si la sucesión $\{X_n\}_{n \in \mathbb{N}}$ converge en ley a X , lo escribimos

$$X_n \xrightarrow{d} X \quad \text{o} \quad X_n \xrightarrow{\mathcal{L}} X.$$

Proposición A.3 (Propiedades). Si $X_n \xrightarrow{\mathcal{L}} X$,

- $X_n - X \xrightarrow{\mathcal{L}} 0$.
- Si $c \in \mathbb{R} / \{0\}$, $cX_n \xrightarrow{\mathcal{L}} cX$.
- Si $c \in \mathbb{R}$, $X_n + c \xrightarrow{\mathcal{L}} X + c$.
- Si $g : \mathbb{R} \rightarrow \mathbb{R}$ es continua, $g(X_n) \xrightarrow{\mathcal{L}} g(X)$.

Si $X_n \xrightarrow{\mathcal{L}} X$ e $Y_n \xrightarrow{P} c$, con $c \in \mathbb{R}$,

- $X_n \pm Y_n \xrightarrow{\mathcal{L}} X \pm c$.
- Si $c \neq 0$, $X_n Y_n \xrightarrow{\mathcal{L}} cX$.
- Si $c = 0$, $X_n Y_n \xrightarrow{P} 0$.
- Si $c \neq 0$, $\frac{X_n}{Y_n} \xrightarrow{\mathcal{L}} \frac{X}{c}$.

Teorema A.4. Si $X_n \xrightarrow{P} X$, entonces $X_n \xrightarrow{\mathcal{L}} X$.

Teorema A.5. Si $k \in \mathbb{R}$ y $X_n \xrightarrow{\mathcal{L}} k$, entonces $X_n \xrightarrow{P} X$.

Observación (Convergencia de las funciones características). Sabemos que las funciones características proporcionan otro medio para determinar la distribución de una variable aleatoria. También se cumple que

$$X_n \xrightarrow{\mathcal{L}} X \Rightarrow \lim_{n \rightarrow \infty} \varphi_n(t) = \varphi(t), \quad \forall t \in \mathbb{R}.$$

Recíprocamente, si $\lim_{n \rightarrow \infty} \varphi_n(t) = \varphi(t)$, $\forall t \in \mathbb{R}$ y $\varphi(t)$ es continua en el 0, entonces $X_n \xrightarrow{\mathcal{L}} X$ y $\varphi(t)$ es la función característica de X .

A.4. Convergencia en media de orden r

Definición A.4 (Convergencia en media de orden r). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias, diremos que **converge en media de orden r** a la variable aleatoria X si

$$\lim_{n \rightarrow \infty} E(|X_n - X|^r) = 0,$$

siendo $E(|X_n|^r)$ y $E(|X|^r)$ finitas.

Notación. Denotaremos la convergencia en orden r como

$$X_n \xrightarrow{mr} X.$$

Cuando $r = 2$, hablamos de **convergencia en media cuadrática** y escribimos

$$X_n \xrightarrow{mc} X.$$

Observación. Si existe el momento de orden r , sabemos que existen todos los momentos de orden inferior. De esta forma, si $s \leq r$,

$$X_n \xrightarrow{mr} X \Rightarrow X_n \xrightarrow{ms} X.$$

Proposición A.4 (Propiedades). Algunas propiedades son:

- Si $X_n \xrightarrow{mc} X$, entonces $E(X_n) \xrightarrow{mc} E(X)$ y $E(X_n^2) \xrightarrow{mc} E(X^2)$. De ambas se deduce que $V(X_n) \xrightarrow{mc} V(X)$.
- La sucesión $\{X_n\}_{n \in \mathbb{N}}$ converge en media cuadrática a una constante c si y solo si se verifica que $\lim_{n \rightarrow \infty} E(X_n) = c$ y $\lim_{n \rightarrow \infty} V(X_n) = 0$.
- Si $X_n \xrightarrow{mc} X$ e $Y_n \xrightarrow{mc} Y$,
 - $E(X_n Y_n) \xrightarrow{mc} E(XY)$.
 - De esta propiedad y la primera se tiene que $\text{Cov}(X_n, Y_n) \xrightarrow{mc} \text{Cov}(X, Y)$.

Teorema A.6. Si $X_n \xrightarrow{mc} X$, entonces $X_n \xrightarrow{P} X$.

A.5. Leyes de los grandes números

A.5.1. Ley débil de los grandes números

Teorema A.7 (Ley débil de los grandes números). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias, definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$. Diremos que obedece la ley débil de los grandes números si existen dos sucesiones $\{A_n\}_{n \in \mathbb{N}}, \{B_n\}_{n \in \mathbb{N}} \subset \mathbb{R}$ con $B_n > 0$ y $B_n \rightarrow \infty$ creciente, tales que

$$\frac{S_n - A_n}{B_n} \xrightarrow{P} 0, \quad n \rightarrow \infty,$$

donde $S_n = \sum_{i=1}^n X_i$.

Teorema A.8 (Teorema de Chebychev). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias independientes con $E(X_n) < \infty, \forall n \in \mathbb{N}$. Supongamos que existe $\gamma > 0$ tal que $V(X_n) \leq \gamma, \forall n \in \mathbb{N}$. Entonces,

$$\frac{S_n - E(S_n)}{n} \xrightarrow{P} 0.$$

Teorema A.9 (Teorema de Markov). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias con $\lim_{n \rightarrow \infty} V(\bar{X}_n) = 0$, donde $\bar{X}_n = \frac{S_n}{n}$. Entonces,

$$\frac{S_n - E(S_n)}{n} \xrightarrow{P} 0.$$

Teorema A.10 (Teorema de Khintchine). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas de media finita μ , entonces

$$\frac{S_n}{n} \xrightarrow{P} \mu.$$

Teorema A.11 (Teorema de Bernoulli). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes tales que $X_n \equiv B(1, p), \forall n \in \mathbb{N}$, entonces

$$\frac{S_n}{n} \xrightarrow{P} p.$$

A.5.2. Ley fuerte de los grandes números

Teorema A.12 (Ley fuerte de los grandes números). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$. Diremos que obedece la ley fuerte de los grandes números si existen $\{A_n\}_{n \in \mathbb{N}}, \{B_n\}_{n \in \mathbb{N}} \subset \mathbb{R}$ con $B_n > 0$ y $B_n \rightarrow \infty$ creciente tales que

$$\frac{S_n - A_n}{B_n} \xrightarrow{cs} 0.$$

Teorema A.13 (Teorema de Kolmogorov). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes con $E(X_n) = 0$ y $V(X_n) = \sigma_n^2$, $\forall n \in \mathbb{N}$, tales que

$$\sum_{i=1}^{\infty} \frac{\sigma_i^2}{i^2} < \infty,$$

entonces

$$\frac{S_n}{n} \xrightarrow{cs} 0.$$

Teorema A.14 (Teorema de Khintchine). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas de media finita μ , entonces

$$\frac{S_n}{n} \xrightarrow{cs} \mu.$$

A.6. Teorema central del límite

Teorema A.15 (Teorema central del límite). Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{A}, P)$, con media y varianzas finitas. Diremos que obedece el teorema central del límite si

$$Z_n = \frac{S_n - E(S_n)}{\sqrt{V(S_n)}} \xrightarrow{\mathcal{L}} N(0, 1).$$

Teorema A.16 (Teorema de Moivre). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas con distribución de Bernoulli de parámetro p , entonces

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{\mathcal{L}} N(0, 1).$$

Teorema A.17 (Teorema de Lévy-Lindeberg). Si $\{X_n\}_{n \in \mathbb{N}}$ es una sucesión de variables aleatorias independientes e idénticamente distribuidas con media μ y varianza σ^2 finitas, entonces

$$\frac{S_n - nm}{\sigma\sqrt{n}} \xrightarrow{\mathcal{L}} N(0, 1).$$