

Estadística

Victoria Torroja Rubio

Índice general

1. Estadística descriptiva	2
2. Estadísticos muestrales	3
2.1. Inferencia exacta bajo normalidad	3

Capítulo 1

Estadística descriptiva

Capítulo 2

Estadísticos muestrales

2.1. Inferencia exacta bajo normalidad

Para muchas variables, podemos asumir que su distribución pertenece a la familia Gaussiana $N(\mu, \sigma^2)$, donde los parámetros $\mu \in \mathbb{R}$ y $\sigma^2 > 0$, que determinan el punto de simetría y la anchura de la campana de Gauss, son desconocidos. Es decir,

$$\theta = (\mu, \sigma^2) \in \Theta = \mathbb{R} \times (0, \infty).$$

En esta sección asumiremos que la variable de interés satisface $X \sim N(\mu, \sigma^2)$, con $\sigma^2 > 0$.

Teorema 2.1 (Media muestral de v.a.'s normales). Si $(X_1, \dots, X_n)$ es una m.a.s. (n) de $X \sim N(\mu, \sigma^2)$ con $\sigma^2 > 0$, entonces

$$\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Demostración. Sabemos que $X_i \sim N(\mu, \sigma^2)$, $\forall i = 1, \dots, n$ y que

$$\varphi_X(t) = e^{it\mu - \frac{1}{2}t^2\sigma^2}.$$

Así, tendremos que

$$\begin{aligned}\varphi_{\bar{X}}(t) &= E\left[e^{it\frac{1}{n}\sum_{i=1}^n X_i}\right] = E\left[\prod_{i=1}^n e^{it\frac{1}{n}X_i}\right] = \prod_{i=1}^n \varphi_{X_i}\left(\frac{t}{n}\right) \\ &= \varphi_X^n\left(\frac{t}{n}\right) = e^{it\mu - \frac{1}{2}\frac{\sigma^2}{n}t^2}.\end{aligned}$$

Así, tenemos que $\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$, puesto que sus funciones características coinciden. $\square$

Definición 2.1 (Estadístico Z). El **estadístico** Z se obtiene estandarizando la media muestral

$$Z = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1).$$

Observación. Para ver que esto es cierto basta con aplicar la función característica.

Ejemplo (Contenido de las botellas). Se sabe que la cantidad de líquido (en onzas) que llena una m'quina en ciertas botellas sigue una $N(\mu, 1)$. De la producción de un cierto día, obtenemos una m.a.s. de $n = 9$ botellas y medimos la cantidad de líquido en cada una. Cuál es la probabilidad de que la media muestral esté a una distancia de como mucho 0,3 onzas de μ ?

Por lo que acabamos de ver la media muestral tiene una distribución normal $N\left(\mu, \frac{\sigma^2}{n}\right)$, por lo que tendremos que

$$\begin{aligned} P(|\bar{X} - \mu| \leq 0,3) &= P(-0,3 \leq \bar{X} - \mu \leq 0,3) = P\left(\frac{-0,3}{\frac{1}{\sqrt{n}}} \leq Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq \frac{0,3}{\frac{1}{\sqrt{n}}}\right) \\ &= 2P(Z \leq 0,3) - 1. \end{aligned}$$

Para obtener este valor basta con consultar la tabla de los valores de la normal tipificada.

Ahora, si usamos la media muestral para estimar μ , qué número de botellas n deberíamos muestrear para conseguir un error absoluto máximo de 0,3 onzas con probabilidad de 0,95?

Tendremos que la media muestral sigue la distribución $N\left(\mu, \frac{\sigma^2}{n}\right)$ y sabemos que $P(|\bar{X} - \mu| \leq 0,3) = 0,95$. De esta forma,

$$\begin{aligned} P(|\bar{X} - \mu| \leq 0,3) &= P(-0,3 \leq \bar{X} - \mu \leq 0,3) = P\left(\frac{-0,3}{\frac{1}{\sqrt{n}}} \leq Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq \frac{0,3}{\frac{1}{\sqrt{n}}}\right) \\ &= P(-0,3\sqrt{n} \leq Z \leq 0,3\sqrt{n}) = 2P(Z \leq 0,3\sqrt{n}) - 1 = 0,95. \end{aligned}$$

De esta forma, tenemos que $P(Z \leq 0,3\sqrt{n}) = 0,975$. Ahora basta con consultar con la tabla de la normal para ver qué valor de Z tiene esta probabilidad.

Definición 2.2 (Distribución Chi-cuadrado). Una **distribución Chi-cuadrado** con n grados de libertad, denotado χ_n^2 , es la distribución que resulta de la suma del cuadrado de n variables aleatorias independientes $Z_1, \dots, Z_n$ con distribución $N(0, 1)$. Es decir,

$$Y = \sum_{i=1}^n Z_i^2 \sim \chi_n^2.$$

Proposición 2.1. Se verifica $\chi_n^2 \sim \gamma\left(a = \frac{1}{2}, p = \frac{n}{2}\right)$.

Demostración. Como $Z \sim N(0, 1)$, tenemos que $\varphi_Z(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}t^2}$. En primer lugar, calculamos la distribución de Z^2 :

$$F_{Z^2}(y) = P(Z^2 \leq y) = P(-\sqrt{y} \leq Z \leq \sqrt{y}) = F_Z(\sqrt{y}) - F_Z(-\sqrt{y}) = 2F_Z(\sqrt{y}) - 1.$$

Así, tenemos que

$$f_{Z^2}(y) = 2f_Z(\sqrt{y}) \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y} y^{-\frac{1}{2}}.$$

Por tanto, tenemos que $Z^2 \sim \gamma\left(a = \frac{1}{2}, p = \frac{1}{2}\right)$. Así, tendremos que $\varphi_{Z^2}(t) = (1 - 2it)^{-\frac{1}{2}}$, por lo que

$$\varphi_{\chi_n^2}(t) = E\left[e^{it \sum_{i=1}^n Z_i^2}\right] = \prod_{i=1}^n \varphi_{Z_i^2}(t) = \varphi_{Z^2}^n(t) = (1 - 2it)^{-\frac{n}{2}}.$$

Por tanto, tenemos que $\chi_n^2 \sim \gamma\left(a = \frac{1}{2}, p = \frac{n}{2}\right)$. □

Observación (Propiedades de la distribución χ_n^2). Las siguientes propiedades son fáciles de comprobar:

- A partir de la proposición anterior es sencillo ver que la función de densidad de χ_n^2 será

$$f_{\chi_n^2}(x) = \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} e^{-\frac{1}{2}x} x^{\frac{n}{2}-1}, x > 0.$$

- Se tiene que $E[\chi_n^2] = n$ y $V(\chi_n^2) = 2n$.
- **Propiedad de aditividad.** Si $Y_i \sim \chi_{n_i}^2$, con $i = 1, \dots, k$, son independientes, entonces

$$Y = \sum_{i=1}^k Y_i \sim \chi_n^2, \quad n = \sum_{i=1}^k n_i.$$

- La distribución de $\frac{Y}{n} = \bar{X}$, donde $X_i = Z_i^2$ para $i = 1, \dots, n$, es

$$\frac{Y}{n} = \bar{X} \sim \gamma\left(p = \frac{n}{2}, a = \frac{n}{2}\right).$$

En efecto, basta con ver que

$$\varphi_{\bar{X}}(t) = E\left[e^{it\bar{X}}\right] = E\left[e^{it \frac{Y}{n}}\right] = \varphi_Y\left(\frac{t}{n}\right) = \frac{1}{\left(1 - 2i \frac{t}{n}\right)^{\frac{n}{2}}}.$$

Lema 2.1. Dada una m.a.s. (n) , $(X_1, \dots, X_n)$ de una población $N(0, \sigma^2)$, construimos las v.a.'s

$$Z_i := c_i^t \vec{X} = (c_{i1} \ \cdots \ c_{in}) \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}, \ i = 1, \dots, p,$$

con $p < n$ y $c_i^t c_j = \delta_{ij}$. La v.a. $Y = \sum_{i=1}^n X_i^2 - \sum_{i=1}^p Z_i^2$ verifica que $\frac{Y}{\sigma^2} \sim \chi_{n-p}^2$, siendo independiente de $Z_1, \dots, Z_p$.

Demostración. Seleccionamos $n-p$ vectores $c_{p+1}, \dots, c_n$ tales que $\{c_1, \dots, c_n\}$ es una base autonormal de $\mathbb{R}^n$. Definimos la matriz $C = \{c_1, \dots, c_n\}$, que por ser ortonormal verifica

$$C^t C = \begin{pmatrix} c_1^t \\ \vdots \\ c_n^t \end{pmatrix} \begin{pmatrix} c_1 \\ \cdots \\ c_n \end{pmatrix} = \begin{pmatrix} c_1^t c_1 & \cdots & c_1^t c_n \\ \vdots & & \vdots \\ c_n^t c_1 & \cdots & c_n^t c_n \end{pmatrix} = I_n.$$

Tomamos

$$\vec{Z} := C^t \vec{X} = \begin{pmatrix} c_1^t \\ \vdots \\ c_n^t \end{pmatrix} \vec{X} = \begin{pmatrix} c_1^t \vec{X} \\ \vdots \\ c_n^t \vec{X} \end{pmatrix} = \begin{pmatrix} Z_1 \\ \vdots \\ Z_n \end{pmatrix}.$$

Tendremos que $E[Z_i] = E[c_i^t \vec{X}] = c_i^t E[\vec{X}] = 0, \forall i = 1, \dots, n$. De la misma manera

$$V(Z_i) = V(c_i^t \vec{X}) = c_i^t V(\vec{X}) = \sigma^2 c_i^t c_i = \sigma^2, \forall i = 1, \dots, n.$$

Finalmente,

$$\text{Cov}(Z_i, Z_j) = \text{Cov}(c_i^t \vec{X}, c_j^t \vec{X}) = c_i^t V(\vec{X}) c_j = \sigma^2 c_i^t c_j = 0, \forall i \neq j.$$

Así, tenemos que $Z_i = c_i^t \vec{X} \sim N(0, \sigma^2)$ y son independientes e idénticamente distribuidas. Ahora, como $\vec{Z} = C^t \vec{X}$ tendremos que $\vec{X} = C \vec{Z}$, por lo que $\vec{X}^t \vec{X} = \vec{Z}^t C^t C \vec{Z} = \vec{Z}^t \vec{Z}$. Así,

$$Y = \vec{Z}^t \vec{Z} - \sum_{i=1}^p Z_i^2 = \sum_{i=1}^n Z_i^2 - \sum_{i=1}^p Z_i^2 = \sum_{i=p+1}^n Z_i^2.$$

Por tanto, $Y = \sum_{i=p+1}^n Z_i^2$ es independiente de $Z_1, \dots, Z_p$, y

$$\frac{Y}{\sigma^2} = \sum_{i=p+1}^n \left(\frac{Z_i}{\sigma} \right)^2 \sim \chi_{n-p}^2.$$

□

Teorema 2.2 (Teorema de Fisher). Sea $(X_1, \dots, X_n)$ una m.a.s. de una v.a. $N(\mu, \sigma^2)$, con μ y $\sigma^2 > 0$ desconocidas. Entonces, se verifica

1. $\bar{X}_n^2$ y S'^2 son independientes.
2. $\frac{(n-1)S'^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}_n}{\sigma} \right)^2 \sim \chi_{n-1}^2$.

Demostración. Tenemos que

$$(n-1)S'^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 = \sum_{i=1}^n X_i^2 - (\sqrt{n}\bar{X})^2 = \sum_{i=1}^n X_i^2 - c_1 X,$$

donde $c_1 = \frac{1}{n}\sqrt{n} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{\sqrt{n}} \\ \vdots \\ \frac{1}{\sqrt{n}} \end{pmatrix}$. Por tanto, $(n-1)S'^2 = S^2$ es independiente de $\bar{X}_n$

y

$$\frac{(n-1)S'^2}{\sigma^2} \sim \chi_{n-1}^2.$$

□

Observación (Interpretación de los grados de libertad). Notemos que las v.a.'s $X_1, \dots, X_n$ en la suma

$$\sum_{i=1}^n (X_i - \bar{X}_n)$$

no varían libremente puesto que deben satisfacer la restricción

$$X_1 + \dots + X_n = n\bar{X}_n.$$

Entonces, solo $n-1$ de ellos pueden variar libremente en lugar de n . Es decir, si dejamos a $X_2, \dots, X_n$ moverse libremente, entonces X_1 debe ser $X_1 = n\bar{X}_n - \sum_{i=2}^n X_i$. Así, los grados de libertad son el número de elementos del vector $(X_1, \dots, X_n)$ que son libres para moverse.

Por otro lado, al considerar

$$\frac{(n-1)S'^2}{\sigma^2} = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2} = \left(\frac{X_1 - \bar{X}}{\sigma} \right)^2 + \dots + \left(\frac{X_n - \bar{X}}{\sigma} \right)^2.$$

Si tomamos $\tilde{Z}_i := \frac{X_i - \bar{X}}{\sigma}$, podemos ver que $\tilde{Z}_1, \dots, \tilde{Z}_n$ no varían libremente, sólo $n-1$ de ellos lo hacen. En efecto,

$$\tilde{Z}_1 + \dots + \tilde{Z}_n = \sum_{i=1}^n \frac{X_i - \bar{X}_n}{\sigma} = 0,$$

de lo que se sigue

$$\tilde{Z}_n = -\tilde{Z}_1 - \dots - \tilde{Z}_{n-1}.$$

Así, hay $n - 1$ grados de libertad.

Ejemplo (Contenido de las botellas, continuación). Tomamos una m.a.s. de $n = 10$ botellas y calculamos S'^2 . Encontrar cotas b_1 y b_2 tales que

$$P(b_1 \leq S'^2 \leq b_2) = 0,9.$$

Por el teorema de Fisher tenemos que

$$9S'^2 \sim \chi_9^2.$$

Así, tendremos que

$$P(b_1 \leq S'^2 \leq b_2) = P(9b_1 \leq \chi_9^2 \leq 9b_2) = P(\chi_9^2 \leq 9b_2) - P(\chi_9^2 \leq 9b_1) = 0,9.$$

Hay infinitas soluciones. Sean $a_1 = 9b_1$ y $a_2 = 9b_2$. Para obtener una solución dividimos la probabilidad 0,1 restante entre 2, de forma que $P(\chi_9^2 \leq a_1) = 0,05$ y $P(\chi_9^2 \geq a_2) = 0,05$. De esta manera, consultando con los valores de la tabla de la distribución χ^2 para obtener los valores de a_1 y a_2 , y en consecuencia los de b_1 y b_2 .

Ejemplo. Sea $(X_1, \dots, X_n)$ una m.a.s. de $X \sim N(\mu, \sigma^2)$ con μ y $\sigma^2 > 0$ desconocidas. Calculemos la varianza y el ECM de S^2 y S'^2 como estimadores de σ^2 .

Definición 2.3 (Distribución t de Student). Sean $X \sim N(0, 1)$ e $Y \sim \chi_v^2$ independientes. La distribución de la v.a.

$$T = \frac{X}{\sqrt{\frac{Y}{v}}}$$

es una **t de Student** con v grados de libertad, denotada t_v .

Proposición 2.2. La función de densidad de $T \sim t_v$ es

$$f_T(t) = \frac{1}{\sqrt{v\pi}} \frac{\Gamma(\frac{v+1}{2})}{\Gamma(\frac{v}{2})} \left(1 + \frac{t^2}{v}\right)^{-\frac{v+1}{2}}, \quad t \in \mathbb{R}.$$

Demostración. Sabemos que $Y \sim \chi_v^2$ tiene por función de densidad

$$f_Y(y) = \frac{1}{2^{\frac{v}{2}} \Gamma(\frac{v}{2})} y^{\frac{v}{2}-1} e^{-\frac{y}{2}}, \quad y > 0.$$

Además, $Z \sim N(0, 1)$, por lo que $T = \frac{Z}{\sqrt{\frac{Y}{v}}}$. Aplicando transformación de variables con

$U = \sqrt{\frac{Y}{v}}$, obtenemos

$$f_U(u) = f_Y(vu^2) \left| \frac{2y}{2u} \right| = \frac{1}{2^{\frac{v}{2}} \Gamma(\frac{v}{2})} (vu^2)^{\frac{v}{2}-1} e^{-\frac{vu^2}{2}} v2u = \frac{1}{2^{\frac{v}{2}-1} \Gamma(\frac{v}{2})} v^{\frac{v}{2}} u^{v-1} e^{-v\frac{u^2}{2}}.$$

Como Z y U son independientes tendremos que su función de densidad conjunta será

$$\begin{aligned} f_{(Z,U)}(Z,U) &= f_Z(z) f_U(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \frac{1}{2^{\frac{v}{2}-1} \Gamma\left(\frac{v}{2}\right)} v^{\frac{v}{2}} u^{v-1} e^{-v\frac{u^2}{2}} \\ &= K u^{v-1} e^{-\frac{z^2+vu^2}{2}}, \quad K = \frac{v^{\frac{v}{2}}}{\sqrt{2\pi} \Gamma\left(\frac{v}{2}\right) 2^{\frac{v}{2}-1}}. \end{aligned}$$

Ahora, haciendo el cambio de variable $(Z,U) \rightarrow (W,T)$ con $W = U$ y $T = \frac{Z}{W}$, tenemos que el jacobiano correspondiente será

$$J = \begin{vmatrix} W & T \\ 0 & 1 \end{vmatrix} = W > 0.$$

Además, la función de densidad conjunta será

$$f_{(W,T)}(w,t) = f_{(Z,U)}(tw,w) w = K w^{v-1} e^{-\frac{t^2 w^2 + w w^2}{2}} w = K w^v e^{-(t^2+w)\frac{w^2}{2}}.$$

Integramos respecto de w con cambio de variable $s = w^2$, para de esta forma calcular la distribución marginal de T ,

$$\begin{aligned} f_T(t) &= K \int_0^\infty w^v e^{-(t^2+w)\frac{w^2}{2}} dw = K \int_0^\infty (w^2)^{\frac{v}{2}} e^{-(t^2+v)\frac{w^2}{2}} dw \\ &= K \int_0^\infty s^{\frac{v}{2}} e^{-\frac{(t^2+v)s}{2}} \frac{1}{2\sqrt{s}} ds = \frac{K}{2} \int_0^\infty s^{\frac{v-1}{2}} e^{-\frac{(t^2+v)s}{2}} ds = \frac{v^{\frac{v}{2}}}{2\sqrt{2\pi} \Gamma\left(\frac{v}{2}\right) 2^{\frac{v}{2}-1}} \frac{\Gamma\left(v + \frac{1}{2}\right)}{\left(\frac{t^2+v}{2}\right)^{\frac{v+1}{2}}} \\ &= \dots = \frac{1}{\sqrt{\pi v}} \frac{\Gamma\left(\frac{v+1}{2}\right)}{\Gamma\left(\frac{v}{2}\right)} \left(1 + \frac{t^2}{v}\right)^{-\frac{v+1}{2}}, \quad t \in \mathbb{R}. \end{aligned}$$

□

Observación. Podemos observar un par de cosas.

- La distribución t de Student es simétrica.
- La esperanza y varianza de $T \sim t_v$ son:

$$E(T) = 0 \quad \text{y} \quad V(T) = \frac{v}{v-2}.$$

- Para $v = 1$ grados de libertad, también se llama **distribución de Cauchy**.

Teorema 2.3 (Teorema de Student). Sea $(X_1, \dots, X_n)$ una m.a.s. de una v.a. $N(\mu, \sigma^2)$, con μ y $\sigma^2 > 0$ desconocidas. Entonces,

$$T = \frac{\bar{X}_n - \mu}{\frac{S'}{\sqrt{n}}} \sim t_{n-1},$$

y T es conocido como **estadístico T** .